Dissertação apresentada à Pró-Reitoria de Pós-Graduação do Instituto Tecnológico de Aeronáutica, como parte dos requisitos para obtenção do título de Mestre em Ciências no Programa de Pós-Graduação em Engenharia Eletrônica e Computação, Área de Sistemas e Controle.

**Benicio Barbosa Cruz**

# PLANEJAMENTO ÓTIMO DE TRAJETÓRIAS PARA NEUTRALIZAÇÃO DE AMEAÇAS AÉREAS COM SISTEMA MULTIDRONES E RECURSOS LIMITADOS

Dissertação aprovada em sua versão final pelos abaixo assinados:

Prof. Dr. Rubens Junqueira Magalhães Afonso
Orientador

Prof. Dr. Davi Antônio dos Santos
Coorientador

Campo Montenegro
São José dos Campos, SP - Brasil
2025

**Dados Internacionais de Catalogação-na-Publicação (CIP)**
**Divisão de Informação e Documentação**

Cruz, Benicio Barbosa
Planejamento Ótimo de Trajetórias para Neutralização de Ameaças Aéreas com Sistema Multidrones e Recursos Limitados / Benicio Barbosa Cruz.
São José dos Campos, 2025.
133f.

Dissertação de Mestrado – Curso de Engenharia Eletrônica e Computação. Área de Sistemas e Controle – Instituto Tecnológico de Aeronáutica, 2025. Orientador: Prof. Dr. Rubens Junqueira Magalhães Afonso. Coorientador: Prof. Dr. Davi Antônio dos Santos.

1. Sistemas Autônomos. 2. Sistemas Multi-Drone. 3. Planejamento de Trajetória. 4. Controle Preditivo. 5. Tomada de Decisão. 6. Engajamento Cooperativo de Ameaças. I. Instituto Tecnológico de Aeronáutica. II. Título.

## REFERÊNCIA BIBLIOGRÁFICA

CRUZ, Benicio Barbosa. **Planejamento Ótimo de Trajetórias para Neutralização de Ameaças Aéreas com Sistema Multidrones e Recursos Limitados**. 2025. 133f. Dissertação de Mestrado – Instituto Tecnológico de Aeronáutica, São José dos Campos.

## CESSÃO DE DIREITOS

NOME DO AUTOR: Benicio Barbosa Cruz
TITULO DO TRABALHO: Planejamento Ótimo de Trajetórias para Neutralização de Ameaças Aéreas com Sistema Multidrones e Recursos Limitados.
TIPO DO TRABALHO/ANO: Dissertação / 2025

É concedida ao Instituto Tecnológico de Aeronáutica permissão para reproduzir cópias desta dissertação e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta dissertação pode ser reproduzida sem a autorização do autor.

Benicio Barbosa Cruz
Praça Marechal Eduardo Gomes, 50 - Vila das Acácias
12228-900 – São José dos Campos-SP

# PLANEJAMENTO ÓTIMO DE TRAJETÓRIAS PARA NEUTRALIZAÇÃO DE AMEAÇAS AÉREAS COM SISTEMA MULTIDRONES E RECURSOS LIMITADOS

**Benicio Barbosa Cruz**

Composição da Banca Examinadora:

| | | | | |
|---|---|---|---|---|
| Prof. Dr. | Roberto Kawakami Harrop Galvão | Presidente | - | ITA |
| Prof. Dr. | Rubens Junqueira Magalhães Afonso | Orientador | - | ITA |
| Prof. Dr. | Davi Antônio dos Santos | Coorientador | - | ITA |
| Prof. Dr. | Marcos R. O. de A. Maximo | Membro interno | - | ITA |
| Profa. Dra. | Lucia Valeria Ramos de Arruda | Membro externo | - | UTFPR |

**ITA**

A força do Nordeste na luta incansável de seu povo pela educação, superando desafios com determinação e esperança para construir um futuro melhor.

# Agradecimentos

A realização deste trabalho é fruto de uma caminhada que não percorri sozinho. Por isso, deixo aqui meu sincero agradecimento a todas as pessoas que, direta ou indiretamente, contribuíram para que este momento se tornasse possível.

À minha família, por ser meu alicerce em todos os momentos. Pelo amor incondicional, apoio constante e incentivo nos dias difíceis, sem os quais eu não teria chegado até aqui.

Aos amigos e a todas as pessoas que estiveram ao meu lado ao longo desta jornada, oferecendo palavras de apoio, ensinamentos, escuta atenta e companhia nos momentos de descontração. Cada gesto de carinho e compreensão fez diferença nesse processo.

Ao meu orientador, Prof. Rubens Junqueira, e ao meu coorientador, Prof. Davi Santos, agradeço profundamente pela orientação dedicada, pela confiança em meu trabalho e por todas as valiosas contribuições ao longo do mestrado.

Ao Prof. Renan Lima, agradeço por toda a ajuda prestada durante essa trajetória. Sua disposição em compartilhar conhecimento e oferecer suporte técnico foi essencial para a minha evolução como pesquisador.

Ao Prof. Eduardo Lenz, agradeço pela constante colaboração e pelas enriquecedoras conversas que ajudaram a esclarecer muitas dúvidas ao longo do caminho. Sua generosidade e paciência foram fundamentais.

Aos colegas de laboratório no ITA, entre eles João Baldissera e Jorge Ricardo Jr., deixo meu agradecimento especial. Ao João, por ter sido o primeiro a me acolher no ambiente do laboratório, pela amizade, companheirismo e por tudo o que aprendi com ele nos meus primeiros passos na pesquisa. Ao Jorge, por toda a parceria nos desenvolvimentos acadêmicos, pelas discussões técnicas, pela amizade e apoio constante, que foram fundamentais para o meu crescimento como pesquisador.

Por fim, agradeço ao apoio financeiro que tornou este estudo possível: Este trabalho foi financiado em parte pela Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001. Agradeço à FINEP pelo apoio financeiro sob a concessão 01.22.0069.00.

*"A vida me ensinou a nunca desistir*
*Nem ganhar, nem perder, mas procurar evoluir*
*Podem me tirar tudo que tenho*
*Só não podem me tirar as coisas boas*
*Que eu já fiz pra quem eu amo"*
— Charlie Brown Jr.

# Resumo

Este trabalho apresenta uma abordagem integrada para o planejamento de trajetórias e tomada de decisão em sistemas autônomos cooperativos compostos por múltiplos drones, operando em ambientes tridimensionais com restrições dinâmicas e operacionais. O cenário envolve a interceptação de alvos móveis na presença de obstáculos estáticos, exigindo que os agentes executem suas missões de forma eficiente, segura e dentro dos limites físicos e energéticos da plataforma. A metodologia proposta é baseada em planejamento ótimo, respeitando as restrições de velocidade, aceleração, área de operação e prevenção de colisões, tanto com obstáculos quanto entre os próprios agentes. Um diferencial da abordagem é a integração da alocação dos drones aos alvos diretamente no problema de otimização, considerando níveis de energia remanescente. Restrições específicas, como a de velocidade terminal, asseguram que os drones alcancem os alvos de forma adequada para possíveis ações subsequentes, como acompanhamento ou manutenção da posição relativa. A validação da proposta foi realizada por meio de simulações em cenários com múltiplos agentes e obstáculos, além de experimentos em ambiente de realidade mista, integrando drones reais e simulados em uma operação coordenada. Os resultados demonstraram a eficácia do otimizador no planejamento de trajetórias viáveis e na tomada de decisões, assegurando o cumprimento dos objetivos da missão com otimização do uso de recursos e respeito às limitações operacionais.

Este trabalho apresenta uma abordagem integrada para o planejamento de trajetórias e tomada de decisão em sistemas autônomos cooperativos compostos por múltiplos drones, operando em ambientes tridimensionais com restrições dinâmicas e operacionais. O cenário envolve a interceptação de alvos móveis na presença de obstáculos estáticos, exigindo que os agentes executem suas missões de forma eficiente, segura e dentro dos limites físicos e energéticos da plataforma. A metodologia proposta é baseada em planejamento ótimo, respeitando as restrições de velocidade, aceleração, área de operação e prevenção de colisões, tanto com obstáculos quanto entre os próprios agentes. Um diferencial da abordagem é a integração da alocação dos drones aos alvos diretamente no problema de otimização, considerando níveis de energia remanescente. Restrições específicas, como a de velocidade terminal, asseguram que os drones alcancem os alvos de forma adequada para possíveis ações subsequentes, como acompanhamento ou manutenção da posição re-

lativa. A validação da proposta foi realizada por meio de simulações em cenários com múltiplos agentes e obstáculos, além de experimentos em ambiente de realidade mista, integrando drones reais e simulados em uma operação coordenada. Os resultados demonstraram a eficácia do otimizador no planejamento de trajetórias viáveis e na tomada de decisões, assegurando o cumprimento dos objetivos da missão com otimização do uso de recursos e respeito às limitações operacionais.

# Abstract

This work presents an integrated approach for trajectory planning and decision-making in cooperative autonomous systems composed of multiple drones, operating in three-dimensional environments with dynamic and operational constraints. The considered scenario involves the interception of moving targets in the presence of static obstacles, requiring agents to complete their missions efficiently, safely, and within the physical and energy limitations of the platform. The proposed methodology is based on optimal planning, respecting speed, acceleration, area of operation and collision avoidance restrictions, both with obstacles and between the agents themselves. A key feature of the approach is the integration of drone-to-target allocation directly into the optimization problem, taking into account remaining energy. Specific constraints, such as terminal velocity, ensure that drones reach their targets in a suitable way for possible follow-up actions, such as tracking or maintaining relative position. The proposed trajectory planner was validated through simulations in scenarios with multiple agents and obstacles, as well as experiments in a mixed reality environment, combining real and simulated drones in a coordinated operation. Results demonstrated the optimizer's effectiveness in planning feasible trajectories and making decisions, ensuring the mission objectives were met while optimizing resource use and respecting operational constraints.

# Lista de Figuras

FIGURA 1.1 – Drone da polícia militar do Distrito Federal (DEFESA, 2023). . . . . 28

FIGURA 2.1 – Ilustração do ambiente tridimensional de defesa aérea, com agentes (branco e verde) e alvos (vermelho). . . . . 36

FIGURA 4.1 – Representação esquemática do cenário adotado. . . . . 51

FIGURA 4.2 – Representação do ambiente com obstáculos e um agente. Os obstáculos $\mathcal{O}_1$ e $\mathcal{O}_2$, posicionados em $\mathbf{r}_o^1$ e $\mathbf{r}_o^2$, são modelados como poliedros convexos definidos por facetas planas. O drone $i$ está representado por sua posição $\mathbf{r}_a^i$ no referencial global $\mathcal{S}_g$. . . . . 54

FIGURA 4.3 – Exemplo de ativação e desativação das variáveis binárias associadas às facetas do obstáculo $\mathcal{O}_1$. . . . . 55

FIGURA 4.4 – Ilustração da restrição de anticolisão entre os drones $i$ e $i_o$, utilizando representação por politopos. As regiões cinza representam o volume ocupado por cada agente, e os planos de separação garantem que não haja interseção. . . . . 58

FIGURA 4.5 – Representação da área protegida com a zona crítica denominada *centro de atuação*. Os alvos são inicializados aleatoriamente fora do centro, mas dentro da área protegida. . . . . 59

FIGURA 4.6 – Ilustração da interação entre o agente $i$ e o alvo dinâmico $j$ na posição $\mathbf{r}_t^j$. O alvo se move seguindo a direção $\mathbf{d}_{vt}^j$ com velocidade $\mathbf{v}_t^j$. O politopo de adjacência $\mathcal{T}_j$ delimita a zona em que o agente é considerado próximo ao alvo. . . . . 60

FIGURA 6.1 – Visualização das posições do alvo e do agente para o cenário com um agente e um alvo. As três subfiguras mostram diferentes perspectivas do movimento do agente em direção ao alvo: (1) visão diagonal 3D, (2) visão lateral no plano $XZ$ e (3) visão superior no plano $XY$. A coloração ao longo das trajetórias representa a progressão temporal da missão em percentual do horizonte de predição (0 a 100%). O agente é inicializado na posição $(0,\ 0,\ 1)$ com velocidade inicial nula nos três eixos. Legenda: ○ Posição e ■ Alvo. . . . . 71

FIGURA 6.2 – Visualização das posições simuladas do alvo e dos agentes para o cenário com dois agentes e um único alvo. O Agente 1 parte da posição $(0,\ 0,\ 1)$ m, enquanto o Agente 2 inicia em $(0,\ -1,\ 1)$ m, ambos com velocidades iniciais nulas. Apenas o Agente 1 executa a movimentação até o alvo, enquanto o Agente 2 permanece estacionado durante toda a simulação, respeitando a restrição (4.27). A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 72

FIGURA 6.3 – Visualização das posições simuladas dos alvos e dos agentes para o cenário com dois agentes e dois alvos. Os agentes são inicializados com alturas iguais de um metro e velocidades iniciais nulas, sendo alocados automaticamente a alvos distintos pelo otimizador. Cada agente realiza o deslocamento até seu respectivo alvo, sem sobreposição entre as trajetórias. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 74

FIGURA 6.4 – Visualização das posições simuladas do alvo e dos agentes para o cenário com dois agentes e um alvo. O Agente 1 parte da posição $(0,\ 0,\ 1)$ m, enquanto o Agente 2 inicia em $(0,\ -1,\ 1)$ m, ambos com velocidades iniciais nulas. Ambos os agentes executam a movimentação até o mesmo alvo, respeitando a restrição (4.27), a qual teve o número de agentes alocados $a_j = 2$. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 75

FIGURA 6.5 – Visualização das posições simuladas dos agentes e dos alvos no cenário com três agentes e três alvos. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 76

FIGURA 6.6 – Posições simuladas para o cenário com um agente, um alvo e restrição de velocidade de $[-0{,}5,\ 0{,}5]$ m/s em cada eixo para o agente. O agente inicia em $(0,\ 0,\ 1)$ m com velocidades nulas e percorre a trajetória respeitando as restrições impostas de posição, velocidade e aceleração. A coloração ao longo da trajetória indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 78

FIGURA 6.7 – Velocidades, acelerações e ações de controle do agente durante a simulação com restrição de velocidade de $[-0{,}5,\ 0{,}5]$ m/s por eixo. Os gráficos mostram a resposta nos eixos $x$, $y$ e $z$, com os limites impostos destacados por linhas tracejadas. Todas as variáveis respeitaram os limites definidos. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições. . . . . 79

FIGURA 6.8 – Posições simulada para o cenário com um agente, um alvo e restrição de velocidade de $[-0{,}2,\ 0{,}2]$ m/s por eixo. O agente inicia em $(0,\ 0,\ 1)$ m com velocidades nulas e alcança o alvo respeitando os limites impostos. A coloração ao longo da trajetória indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 80

FIGURA 6.9 – Velocidades, acelerações e ações de controle durante a simulação com restrição de velocidade $[-0{,}2,\ 0{,}2]$ m/s por eixo. As curvas correspondem aos eixos $x$, $y$ e $z$, com os limites operacionais destacados por linhas tracejadas. O otimizador permaneceu dentro das restrições em todos os instantes. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições. . . . . 81

FIGURA 6.10 –Visualização do cenário com dois agentes e dois obstáculos fixos. Os agentes são inicializados nas posições $(4,\ 2,\ 1)$ m e $(4,\ 1,\ 1)$ m, com velocidades nulas, e cada um é designado a um alvo distinto. As trajetórias são calculadas de modo a evitar colisões com os obstáculos, representados por volumes em cinza. A coloração ao longo das trajetórias indica a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo. 83

FIGURA 6.11 –Cenário com três agentes e um obstáculo fixo. Os agentes partem de posições alinhadas no plano $XZ$, com velocidades nulas, e são direcionados a três alvos distintos. As trajetórias são planejadas de forma a evitar colisões com o obstáculo. A coloração ao longo das trajetórias representa a evolução temporal da simulação, expressa em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo. . . . . 84

FIGURA 6.12 –Cenário com três agentes e dois obstáculos fixos. Os agentes partem de posições alinhadas no plano $XZ$ e se deslocam até seus respectivos alvos, evitando dois obstáculos. As trajetórias são otimizadas para evitar colisões, e as diferentes perspectivas destacam a interação espacial entre agentes e obstáculos. A coloração ao longo das trajetórias representa a evolução temporal da simulação, expressa em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo. . . . . 85

FIGURA 6.13 –Cenário com três agentes e três obstáculos fixos. As trajetórias são planejadas de forma a garantir a interceptação dos alvos enquanto evitam colisões com os obstáculos distribuídos no ambiente. A coloração ao longo das trajetórias representa a evolução temporal da simulação, expressa em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo. . . . . 85

FIGURA 6.14 –Simulação com três agentes em ambiente tridimensional, sob restrição de anticolisão com separação mínima de $2d_a^{i_o} = 0{,}1\,\mathrm{m}$. A trajetória de cada agente respeita a separação entre os volumes poliedrais, mesmo em regiões críticas. Legenda: ■ Agente, ○ Posição, ■ Alvo, ■ Obstáculo. . . . . 87

FIGURA 6.15 –Distância entre os centros de massa dos agentes durante a missão. Embora a restrição de anticolisão seja formulada sobre os contornos dos politopos, o monitoramento da distância entre posições ajuda a verificar o afastamento geral entre os agentes. Nenhuma trajetória levou a sobreposição, conforme validado pela formulação. Legenda: — Agente 1 – Agente 2, — Agente 1 – Agente 3, — Agente 2 – Agente 3. . . . . 87

FIGURA 6.16 –Simulação com três agentes e três obstáculos fixos, sob restrição de separação entre volumes de $2d_a^{io} = 0{,}3\,\text{m}$. As trajetórias planejadas respeitam a restrição poliedral de anticolisão, mesmo em regiões críticas. A coloração representa o avanço no tempo dentro do horizonte de predição. Legenda: ■ Agente, ○ Posição, ■ Alvo, ■ Obstáculo. 88

FIGURA 6.17 –Distância entre os centros de massa dos agentes durante a simulação com separação poliedral mínima de $2d_a^{io} = 0{,}3$ m. A linha tracejada representa esse limite. Nenhuma violação foi observada. Legenda: — Agente 1 – Agente 2, — Agente 1 – Agente 3, — Agente 2 – Agente 3. . . . . 89

FIGURA 6.18 –Simulação com três agentes e três obstáculos fixos, sob restrição poliedral de $2d_a^{io} = 0{,}5\,\text{m}$. A separação mais exigente entre os volumes dos agentes resultou em trajetórias mais distribuídas e rotas conservadoras. A coloração representa a evolução temporal ao longo do horizonte de predição. Legenda: ■ Agente, ○ Posição, ■ Alvo, ■ Obstáculo. . . . . 90

FIGURA 6.19 –Distância entre os centros dos agentes com separação mínima poliedral de $2d_a^{io} = 0{,}5\,\text{m}$. As trajetórias foram planejadas de forma a respeitar a restrição de não interseção. Legenda: — Agente 1 – Agente 2, — Agente 1 – Agente 3, — Agente 2 – Agente 3. . . . . 90

FIGURA 6.20 –Visualização das posições simuladas do agente e do alvo. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. 91

FIGURA 6.21 –Evolução da carga remanescente da bateria ao longo da trajetória com um agente. O modelo considera o esforço de controle e o tempo de operação. Legenda: ○ Carga remanescente ao longo do tempo e --- Bateria inicial do agente. . . . . 92

FIGURA 6.22 –Visualização das posições simuladas dos dois agentes e dos dois alvos. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 92

FIGURA 6.23 –Carga remanescente dos dois agentes durante a execução da missão. O Agente 1 inicia com $c_1 = 100\%$ e o Agente 2 com $c_2 = 80\%$ de carga disponível. Legenda: ○ Carga remanescente do agente 1, --- Bateria inicial do agente 1, ○ Carga remanescente do agente 2 e --- Bateria inicial do agente 2. . . . . 93

FIGURA 6.24 –Visualização das posições simuladas dos três agentes e dos três alvos. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo. . . . . 93

FIGURA 6.25 –Carga remanescente dos três agentes com diferentes condições iniciais. O otimizador adapta o planejamento de cada trajetória conforme a disponibilidade energética individual. Legenda: ○ Carga remanescente do agente 1,--- Bateria inicial do agente 1, ○ Carga remanescente do agente 2, --- Bateria inicial do agente 2, ○ Carga remanescente do agente 3 e --- Bateria inicial do agente 3. . . . . 94

FIGURA 6.26 –Posições simuladas do agente e do alvo no cenário em que o alvo segue uma trajetória diagonal à frente do agente. O agente deve interceptá-lo com alinhamento vetorial de velocidade. A coloração ao longo das trajetórias representa a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição simulada, ■ Alvo. . . . . 95

FIGURA 6.27 –Evolução da norma da diferença entre a velocidade do agente $\mathbf{v}_a^i$ e a do alvo $\mathbf{v}_t^j$ ao longo do horizonte de planejamento. O controle busca minimizar essa diferença no instante final, promovendo interceptação com velocidade terminal compatível. . . . . 96

FIGURA 6.28 –Posições simuladas do agente e do alvo em um cenário em que o alvo cruza a região central da zona protegida por cima, no eixo $z$. O agente reposiciona-se para interceptá-lo com alinhamento de velocidades. A coloração ao longo das trajetórias representa a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição simulada, ■ Alvo. . . . . 97

FIGURA 6.29 –Evolução da norma da diferença entre a velocidade do agente $\mathbf{v}_a^i$ e a do alvo $\mathbf{v}_t^j$ no cenário em que o alvo cruza a região protegida superiormente. O controle reduz essa diferença ao final da trajetória. 97

FIGURA 6.30 –Posições simuladas do agente e do alvo em um cenário onde o alvo atravessa a região protegida por cima. O agente, posicionado abaixo, intercepta o alvo após o cruzamento, ajustando sua velocidade à do alvo. A coloração ao longo das trajetórias representa a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição simulada, ■ Alvo. . . . . 98

FIGURA 6.31 –Evolução da norma da diferença entre a velocidade do agente $\mathbf{v}_a^i$ e a do alvo $\mathbf{v}_t^j$ no cenário com interceptação após o cruzamento. O controle ajusta a velocidade terminal do agente para garantir alinhamento. . . . . 98

FIGURA 6.32 –Cenário considerando alocação baseada em tempo de missão e nível de bateria. Missão com três agentes e três alvos. Legenda: ○ Posição e ■ Alvo. . . . . 100

FIGURA 6.33 –Evolução da carga remanescente da bateria ao longo da trajetória para cada agente. Legenda: ○ Carga remanescente ao longo do tempo e --- Bateria inicial do agente. . . . . 100

FIGURA 6.34 –Cenário do caso 2 considerando alocação baseada em tempo de missão e nível de bateria, com ajuste da carga inicial $c_3 = 45\%$. Missão com três agentes e três alvos. Legenda: ○ Posição e ■ Alvo. . . . . 101

FIGURA 6.35 –Evolução da carga remanescente da bateria ao longo da trajetória para cada agente do caso 2. Legenda: ○ Carga remanescente ao longo do tempo e --- Bateria inicial do agente. . . . . 101

FIGURA 7.1 – Diagrama da estrutura de software da arena experimental em realidade mista. A arquitetura modular permite alternar entre os modos de simulação pura e realidade mista com facilidade (CRUZ *et al.*, 2024).103

FIGURA 7.2 – Visualização da arena no ambiente Unity 3D. Drones pretos representam os agentes guiados, enquanto os drones azuis representam obstáculos virtuais (CRUZ *et al.*, 2024). . . . . 103

FIGURA 7.3 – Ilustração da configuração física da arena experimental (CRUZ *et al.*, 2024). . . . . 104

FIGURA 7.4 – Drone Crazyflie com marcadores reflexivos utilizados para rastreamento de corpo rígido via OptiTrack (BITCRAZE, 2013). . . . . 104

FIGURA 7.5 – Posições reais e otimizadas do agente na arena de voo para o experimento com um único drone. A trajetória real executada é comparada com a sequência de posições do agente gerada pela otimização. A coloração das trajetórias indica a evolução temporal da missão, de 0% a 100%. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo. . . . . 107

FIGURA 7.6 – Velocidades, acelerações e ações de controle do agente, obtidos durante a simulação do planejamento de trajetória offline. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições. Todos os valores permaneceram dentro dos limites definidos pelas restrições. . . . . 108

FIGURA 7.8 – Posições e velocidades do agente registradas pelo sistema de captura de movimento. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Comandos de posição gerados a partir dos estados de posição obtidos na solução do problema de otimização (Eq. (4.31)) e transmitidos aos drones por meio da arena experimental. A região sombreada em vermelho destaca o intervalo em que as posições otimizadas foram efetivamente aplicadas; os demais segmentos correspondem às fases de decolagem e pouso fora do planejamento. . . . . 108

FIGURA 7.7 – Carga remanescente da bateria do agente com o modelo de bateria no planejamento de trajetória. Legenda: ○ Carga remanescente da bateria ao longo do tempo e --- Bateria inicial do agente. É possível observar a redução contínua da carga com base nas ações realizadas. 109

FIGURA 7.9 – Posições reais e otimizadas dos agentes na arena de voo para o experimento com dois drones. As trajetórias reais são comparadas com as posições geradas pela otimização, enquanto as posições dos alvos ao longo do tempo também são exibidas. A coloração das trajetórias indica a evolução temporal da missão, expressa em porcentagem de 0% a 100%. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo. . . . . 110

FIGURA 7.10 –Posições individuais de cada agente e alvo, apresentando uma visão mais próxima do cenário com dois agentes. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo. . . . . 110

FIGURA 7.11 –Velocidades, acelerações e ações de controle dos dois agentes, obtidas durante o planejamento de trajetória. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições. Todos os valores permaneceram dentro dos limites definidos pelas restrições. . . . . 111

FIGURA 7.12 –Carga remanescente da bateria dos agentes com o modelo de bateria implementado no planejamento de trajetória. Legenda: ○ Carga remanescente da bateria ao longo do tempo e --- Bateria inicial do agente. . . . . 112

FIGURA 7.13 –Posições e velocidades dos agentes registradas pelo sistema de captura de movimento. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Referência gerada a partir dos estados de posição do problema de otimização (Eq. (4.31)) e aplicada via arena experimental. A faixa sombreada em vermelho indica o intervalo de aplicação das posições otimizadas; os demais trechos referem-se ao deslocamento inicial e ao retorno final. . . . . 113

FIGURA 7.14 –Distância relativa entre o Agente 1 e o Agente 2 ao longo do tempo. Legenda: — Distância medida durante o voo. . . . . 114

FIGURA 7.15 –Posições reais e otimizadas dos agentes na arena de voo, para o experimento usando dois agentes reais e um agente simulado (Agente 3), atuando de forma cooperativa em um ambiente em realidade mista, bem como a posição simulada do alvo ao longo do tempo. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo. . . . . 115

FIGURA 7.16 –Posições individuais de cada um dos três agentes e alvos no cenário com dois agentes reais e um agente simulado (Agente 3). Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo. . . . . 116

FIGURA 7.17 –Velocidades, acelerações e ações de controle dos Agentes 1 e 2 durante o planejamento de trajetória. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições. . . . . 117

FIGURA 7.18 –Velocidade, aceleração e ações de controle do Agente 3 durante o planejamento de trajetória. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições. . . . . 118

FIGURA 7.19 –Carga remanescente da bateria dos três agentes com o modelo de bateria implementado. Legenda: ○ Carga remanescente da bateria ao longo do tempo e --- Bateria inicial do agente. . . . . 119

FIGURA 7.20 –Posições e velocidades de cada um dos três agentes registradas pelo OptiTrack. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Referência gerada a partir dos estados de posição do problema de otimização (Eq. (4.31)) e aplicada via arena experimental. A faixa sombreada em vermelho indica o intervalo de aplicação das posições otimizadas; os demais trechos referem-se ao deslocamento inicial e ao retorno final. . . . . 120

FIGURA 7.21 –Distância relativa entre os agentes durante o experimento. — Agente 1 – Agente 2, — Agente 1 – Agente 3 e — Agente 2 – Agente 3. . 121

FIGURA 7.22 –Posições reais e planejadas dos agentes na arena de voo, para o experimento usando três agentes reais e a posição simulada do alvo ao longo do tempo. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo. . . . . 122

FIGURA 7.23 –Posições individuais de cada um dos três agentes reais e alvos simulados. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo. . . 123

FIGURA 7.24 –Posições e velocidades de cada um dos três agentes registradas pelo OptiTrack. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Referência gerada a partir dos estados de posição do problema de otimização (Eq. (4.31)) e aplicada via arena experimental. A faixa sombreada em vermelho indica o intervalo em que as referências obtidas a partir da solução do problema de otimização foram aplicadas. 124

# Lista de Abreviaturas e Siglas

| | |
|---|---|
| CMAS | Sistemas Cooperativos Multi-Agente |
| DMPC | Controle Preditivo Distribuído |
| MAS | Sistemas Multi-Agente |
| MAV | Veículos Aéreos em Miniatura |
| MILP | Programação Linear Inteira Mista |
| MIP | Programação Inteira Mista |
| MIQP | Programação Quadrática Inteira Mista |
| MPC | Controle Preditivo Baseado em Modelo |
| NMPC | Controle Preditivo Não-Linear |
| NLP | Programação Não Linear |
| OOP | Programação Orientada a Objetos |
| QP | Programação Quadrática |
| RMPC | Controle Preditivo Robusto |
| UAV | Veículo Aéreo Não Tripulado |
| ZOH | Retentor de Ordem Zero |

# Lista de Símbolos

| | |
|---|---|
| $\mathbb{N}$ | Conjunto dos números naturais incluindo zero |
| $\mathbb{R}$ | Conjunto dos números reais |
| $\mathbb{N}^*$ | Conjunto dos números naturais |
| $\mathbb{R}^*$ | Conjunto dos números reais excluindo zero |
| $\mathbb{R}_+$ | Conjunto dos números reais não-negativos |
| $\mathbb{R}_+^*$ | Conjunto dos números reais positivos |
| $I_n$ | Matriz identidade de tamanho $n \times n$ |
| $n_a \in \mathbb{N}^*$ | Número de agentes |
| $u_\bullet \in \mathbb{R}$ | variável de controle no eixo $\bullet = x, y$ ou $z$ |
| $r_\bullet \in \mathbb{R}$ | Posição do agente em um eixo $\bullet = x, y$ ou $z$ |
| $\zeta \in \mathbb{R}_+^*$ | Fator de amortecimento |
| $\omega_n \in \mathbb{R}_+^*$ | Frequência natural do sistema |
| $t_a \in \mathbb{R}_+^*$ | Tempo de acomodação |
| $\mathbf{x} \in \mathbb{R}^{n_\xi}$ | Vetor de estado do agente |
| $\mathbf{u} \in \mathbb{R}^{n_u}$ | Vetor de controle do agente |
| $\mathbf{y} \in \mathbb{R}^{n_y}$ | Vetor de saídas do agente |
| $n_\xi \in \mathbb{N}^*$ | Dimensão do vetor de estado do agente |
| $n_u \in \mathbb{N}^*$ | Dimensão do vetor de controle do agente |
| $n_y \in \mathbb{N}^*$ | Dimensão do vetor de saída |
| $n_{y_p} \in \mathbb{N}^*$ | Dimensão de cada componente da saída (posição, velocidade ou aceleração) |
| $\mathbf{A} \in \mathbb{R}^{n_\xi \times n_\xi}$ | Matriz de transição de estados do agente |
| $\mathbf{B} \in \mathbb{R}^{n_\xi \times n_u}$ | Matriz de controle do agente |
| $\mathbf{A}^{\mathrm{T}}$ | Transposta de uma matriz $\mathbf{A}$ |
| $\mathbf{A_d} \in \mathbb{R}^{n_\xi \times n_\xi}$ | Matriz discreta de transição de estados do agente |
| $\mathbf{B_d} \in \mathbb{R}^{n_\xi \times n_u}$ | Matriz discreta de controle do agente |
| $\mathbf{C_d} \in \mathbb{R}^{n_y \times n_\xi}$ | Matriz discreta de observação do agente |
| $\mathbf{D_d} \in \mathbb{R}^{n_y \times n_u}$ | Matriz discreta de transmissão direta do agente |
| $\mathbf{x}_i(k) \in \mathbb{R}^{n_\xi}$ | Vetor de estado do $i$-ésimo agente no instante $k$ |
| $\mathbf{u}_i(k) \in \mathbb{R}^{n_u}$ | Vetor de controle do $i$-ésimo agente no instante $k$ |

| | |
|---|---|
| $\mathbf{C}_p \in \mathbb{R}^{n_{yp} \times n_\xi}$ | Matriz que extrai a posição do vetor de estado |
| $\mathbf{C}_v \in \mathbb{R}^{n_{yp} \times n_\xi}$ | Matriz que extrai a velocidade do vetor de estado |
| $\mathbf{C}_a \in \mathbb{R}^{n_{yp} \times n_\xi}$ | Matriz que contribui para o cálculo da aceleração a partir do estado |
| $\mathbf{D}_a \in \mathbb{R}^{n_{yp} \times n_u}$ | Matriz que contribui para o cálculo da aceleração a partir do controle |
| $t_c \in \mathbb{R}_+$ | Tempo de solução computacional |
| $t_s \in \mathbb{R}_+$ | Tempo de amostragem |
| $k \in \mathbb{R}_+$ | Amostra de tempo discreta |
| $\mathcal{S}_g$ | Referencial global do plano tridimensional |
| $\mathbf{r}_a^i(k) \in \mathbb{R}^3$ | Posição do $i$-ésimo agente no instante $k$ em relação a $\mathcal{S}_g$ |
| $\mathbf{v}_a^i(k) \in \mathbb{R}^3$ | Velocidade do $i$-ésimo agente no instante $k$ |
| $\mathbf{a}_a^i(k) \in \mathbb{R}^3$ | Aceleração do $i$-ésimo agente no instante $k$ |
| $\mathbf{x}_{\min} \in \mathbb{R}^{n_\xi}$ | Limite inferior das variáveis de estado |
| $\mathbf{x}_{\max} \in \mathbb{R}^{n_\xi}$ | Limite superior das variáveis de estado |
| $\mathbf{u}_{\min} \in \mathbb{R}^{n_u}$ | Limite inferior das variáveis de controle |
| $\mathbf{u}_{\max} \in \mathbb{R}^{n_u}$ | Limite superior das variáveis de controle |
| $\mathbf{r}_{a,\min} \in \mathbb{R}^3$ | Limite inferior da posição tridimensional do agente |
| $\mathbf{r}_{a,\max} \in \mathbb{R}^3$ | Limite superior da posição tridimensional do agente |
| $\mathbf{v}_{\min} \in \mathbb{R}^3$ | Limite inferior da velocidade do agente |
| $\mathbf{v}_{\max} \in \mathbb{R}^3$ | Limite superior da velocidade do agente |
| $\mathbf{a}_{\min} \in \mathbb{R}^3$ | Limite inferior da aceleração do agente |
| $\mathbf{a}_{\max} \in \mathbb{R}^3$ | Limite superior da aceleração do agente |
| $c_i \in \mathbb{R}_+$ | Capacidade energética do $i$-ésimo agente |
| $e_i \in \mathbb{R}_+$ | Consumo de energia do $i$-ésimo agente |
| $\gamma \in \mathbb{R}_+$ | Constante de penalização do tempo sobre o consumo de energia |
| $\nabla\lambda(\cdot)$ | Gradiente da função $\lambda$ em relação a $\cdot$ |
| $\dot{\lambda}(\cdot)$ | Derivada de $\lambda$ em relação a $\cdot$ |
| $\|\cdot\|_\alpha$ | A norma $\alpha$ de $\cdot$, se $\alpha$ for omitido, então $\alpha = 2$ |
| $x^*$ | Ponto ótimo |
| $\rho \in \mathbb{R}_+^*$ | Parâmetro de penalização |
| $\mathbf{Q} \in \mathbb{R}^{n_\xi \times n_\xi}$ | Matriz de ponderação do estado, semidefinida positiva |
| $\mathbf{R} \in \mathbb{R}^{n_u \times n_u}$ | Matriz de ponderação do controle, definida positiva |
| $b \in \{0, 1\}$ | Variável binaria |
| $M \in \mathbb{R}_+$ | Constante "Big-M" |
| $b_t \in \{0, 1\}$ | Impõe que a posição do $i$-ésimo agente está dentro do $j$-ésimo conjunto de destino no instante $k + 1$ |
| $n \in \mathbb{N}^*$ | Horizonte variável |

| | |
|---|---|
| $n^* \in \mathbb{N}^*$ | Horizonte ótimo |
| $n_{\max}$ | Horizonte de predição |
| $n_t \in \mathbb{N}^*$ | Número de alvos |
| $\mathbf{r}_t^j(k) \in \mathbb{R}^3$ | Posição do $j$-ésimo alvo no instante $k$ em relação a $\mathcal{S}_g$ |
| $\mathbf{d}_{vt}^j \in \mathbb{R}^3$ | Direção de movimento do $j$-ésimo alvo |
| $\mathbf{v}_t^j \in \mathbb{R}^3$ | Velocidade do $j$-ésimo alvo |
| $v_t^j \in \mathbb{R}$ | Magnitude de velocidade do $j$-ésimo alvo |
| $s_t^j \in \mathbb{R}$ | Comprimento da aresta do poliedro $\mathcal{T}_j$. |
| $\mathbf{r}_c \in \mathbb{R}^3$ | Posição do centro da operação |
| $\mathcal{T}_j$ | Polítopo do $j$-ésimo alvo |
| $n_t^s \in \mathbb{N}$ | Número de facetas (semi-planos) do $j$-ésimo alvo |
| $\mathbf{P}_t^j \in \mathbb{R}^{n_t^s \times 3}$ | Matriz constante contendo as normais dos planos delimitadores do $j$-ésimo alvo definindo $\mathcal{T}_j$ |
| $\mathbf{d}_t^j \in \mathbb{R}^{n_t^s}$ | Vetor constante contendo as distâncias máximas permitidas do $j$-ésimo alvo definindo $\mathcal{T}_j$ |
| $\mathbf{r}_{t,\min}^j \in \mathbb{R}^3$ | Limite inferior da dimensão tridimensional do $j$-ésimo alvo |
| $\mathbf{r}_{t,\max}^j \in \mathbb{R}^3$ | Limite superior da dimensão tridimensional do $j$-ésimo alvo |
| $b_{\mathcal{T},i}(k) \in \{0,1\}$ | Variável binária associada à entrada do $i$-ésimo agente na zona de captura do $j$-ésimo $\mathcal{T}_j$ no instante $k$ |
| $\delta \in \mathbb{R}_+$ | Constante de tolerância para pequenas variações da restrição |
| $n_o \in \mathbb{N}$ | Número de obstáculos |
| $\mathcal{O}_\ell$ | Polítopo do obstáculo |
| $\mathbf{r}_o^\ell \in \mathbb{R}^3$ | Posição do $\ell$-ésimo obstáculo |
| $n_o^s \in \mathbb{N}$ | Número de facetas (meios-planos) do $\ell$-ésimo obstáculo |
| $\mathbf{P}_o^\ell \in \mathbb{R}^{n_o^s \times 3}$ | Matriz constante contendo as normais dos planos delimitadores do $\ell$-ésimo obstáculo definindo $\mathcal{O}_\ell$ |
| $\mathbf{d}_o^\ell \in \mathbb{R}^{n_o^s}$ | Vetor constante contendo as distâncias máximas permitidas do $\ell$-ésimo obstáculo definindo $\mathcal{O}_\ell$ |
| $b_{\mathcal{O},h,\ell,i} \in \{0,1\}$ | Impõe que a posição do $i$-ésimo agente no instante $k$ está fora do lado externo do $h$-ésimo semi-plano do obstáculo $\mathcal{O}_\ell$ |
| $\mathbf{p}_{o,h}^\ell \in \mathbb{R}^3$ | $h$-ésima linha da matriz $\mathbf{P}_o^\ell$ |
| $d_{o,h}^\ell \in \mathbb{R}^3$ | Limite escalar associado a $h$-ésima faceta |
| $\epsilon \in \mathbb{R}_+$ | Distancia mínima do obstáculo |
| $\mathcal{P}$ | Politopo tridimensional representando o volume ocupado pelo agente |
| $n_f^a \in \mathbb{N}$ | Número de faces do politopo que representa o agente |
| $\mathbf{G}_a^i \in \mathbb{R}^{n_f^a \times 3}$ | Matriz contendo os vetores normais às $n_f^a$ faces do politopo do agente $i$ |

| | |
|---|---|
| $\mathbf{d}_a^i \in \mathbb{R}^{n_f^a}$ | Vetor com os deslocamentos escalares associados às faces do politopo do agente $i$ |
| $b_{f,i,i_o}(k) \in \{0,1\}$ | Variável binária que indica a ativação da restrição de separação na face $f$ do agente $i_o$, em relação ao agente $i$, no instante $k$ |
| $\mathbf{g}_{a,f}^{i_o} \in \mathbb{R}^3$ | Vetor normal da face $f$ do politopo do agente $i_o$ |
| $d_a^{i_o} \in \mathbb{R}$ | Deslocamento escalar associado à face $f$ do politopo do agente $i_o$ |
| $b_{i,j} \in \{0,1\}$ | Variável binária que impõe a alocação do agente $i$ ao alvo $j$ |
| $a_j \in \mathbb{N}$ | Quantidade de agentes requerida para o alvo $j$ |
| $J \in \mathbb{R}$ | Função de custo utilizada no problema de otimização |
| $\alpha \in \mathbb{R}_+$ | Peso do termo de esforço de controle da função de custo |
| $r_x^i \in \mathbb{R}$ | Posição do $i$-ésimo agente no eixo $x$ |
| $r_y^i \in \mathbb{R}$ | Posição do $i$-ésimo agente no eixo $y$ |
| $r_z^i \in \mathbb{R}$ | Posição do $i$-ésimo agente no eixo $z$ |
| $v_x^i \in \mathbb{R}$ | Velocidade do $i$-ésimo agente no eixo $x$ |
| $v_y^i \in \mathbb{R}$ | Velocidade do $i$-ésimo agente no eixo $y$ |
| $v_z^i \in \mathbb{R}$ | Velocidade do $i$-ésimo agente no eixo $z$ |
| $\mathbf{r}_a^i(0) \in \mathbb{R}^3$ | Posição inicial do $i$-ésimo agente, definida como $\mathbf{r}_a^i(0) = (r_x^i,\ r_y^i,\ r_z^i)$ metros |
| $\mathbf{v}_a^i(0) \in \mathbb{R}^3$ | Velocidade inicial do $i$-ésimo agente, $\mathbf{v}_a^i(0) = (v_x^i,\ v_y^i,\ v_z^i)$ m/s |
| $n_s \in \mathbb{N}^*$ | Número de pontos de posição calculados pelo otimizador. |
| $t_w \in \mathbb{R}_+^*$ | Tempo total da trajetória. |
| $t_d \in \mathbb{R}_+^*$ | Tempo de amostragem desejado. |

# Sumário


1 Introdução . . . . . 28

**1.1 Revisão da Literatura** . . . . . 29

**1.2 Contribuições** . . . . . 34

**1.3 Organização do Texto** . . . . . 35

2 Apresentação do Problema . . . . . 36

**2.1 Formulação do Problema Geral** . . . . . 36

**2.2 Modelo Dinâmico** . . . . . 38

**2.3 Variáveis de Saída do Modelo Dinâmico** . . . . . 39

3 Fundamentos para a Solução do Problema . . . . . 41

**3.1 Problemas de Otimização com Restrições** . . . . . 41

3.1.1 Problemas Convexos e Não Convexos . . . . . 42

3.1.2 Métodos de Solução para MILP/MIQP . . . . . 43

3.1.3 Software e Ferramentas de Resolução . . . . . 44

**3.2 Planejadores Ótimos** . . . . . 44

3.2.1 Princípios Fundamentais dos Planejadores Ótimos . . . . . 45

3.2.2 Modelagem do Sistema . . . . . 45

3.2.3 Restrições no Planejador Ótimo . . . . . 46

3.2.4 Resolução do Problema de Otimização . . . . . 46

3.2.5 Planejador Ótimo com Horizonte Variável . . . . . 47

**3.3 Variáveis Binárias e a Técnica Big-M no Planejador Ótimo** . . . . 48

3.3.1 Big-M no Planejador Ótimo . . . . . 48

3.3.2 Formulação do Problema de Otimização com Variáveis Binárias . . . 49

4 Formulações para Resolução do Problema . . . . . 51
**4.1 Restrições Operacionais** . . . . . 52
**4.2 Formulação dos Obstáculos** . . . . . 54
4.2.1 Modelagem das Restrições de Evitamento . . . . . 55
**4.3 Formulação das Restrições de Anticolisão entre Agentes** . . . . . 56
**4.4 Modelagem e Restrições de Alvos** . . . . . 58
4.4.1 Politopo de Adjacência e Restrições de Posição . . . . . 59
4.4.2 Restrições de Posição e Zona de Captura . . . . . 60
4.4.3 Tomada de Decisão e Alocação de Alvos . . . . . 62
**4.5 Problema de Otimização Integrado** . . . . . 63

5 Configuração da Simulação . . . . . 65
**5.1 Seleção e Análise dos Parâmetros do Planejador de Trajetória** . . 65
5.1.1 Tempo de Amostragem . . . . . 65
5.1.2 Parâmetros do Cenário . . . . . 66
5.1.3 Modelagem dos Obstáculos . . . . . 66
**5.2 Infraestrutura Algorítmica e Suporte Computacional** . . . . . 67

6 Avaliação Baseada em Simulação . . . . . 69
**6.1 Análise de Escalabilidade com Múltiplos Agentes e Alvos** . . . . . 70
**6.2 Impacto da Restrição de Velocidade nas Métricas de Desempenho** 77
**6.3 Avaliação em Cenário com Obstáculos** . . . . . 81
6.3.1 Obstáculos Fixos . . . . . 82
6.3.2 Restrição de Prevenção de Colisões entre Agentes . . . . . 86
**6.4 Modelagem do Consumo Energético** . . . . . 91
**6.5 Avaliação da Restrição de Velocidade Terminal na Interceptação de Alvos** . . . . . 95
**6.6 Avaliação em um Cenário de Defesa** . . . . . 99
6.6.1 Caso 1 – Passo Inicial . . . . . 99

6.6.2 Caso 2 – Efeito da Modificação do Nível de Bateria no Processo de Alocação . . . . . 100

7 Demonstração Experimental . . . . . 102

**7.1 Descrição do Aparato Experimental** . . . . . 102

**7.2 Resultados e Discussão** . . . . . 105

7.2.1 Demonstração com Um Drone Real . . . . . 105

7.2.2 Demonstração com Dois Drones Reais . . . . . 109

7.2.3 Demonstração com Três Drones . . . . . 114

8 Conclusão e Trabalhos Futuros . . . . . 125

**8.1 Trabalhos Futuros** . . . . . 125

Referências . . . . . 127

# 1 Introdução

Os drones destacam-se como uma das tecnologias mais inovadoras, com aplicações que abrangem missões militares de vigilância e reconhecimento, como ilustrado na Figura 1.1 e apresentado em (WALLACE; LOFFI, 2015). A capacidade desses veículos de operar de forma autônoma ou coordenada em enxames amplia suas possibilidades de uso, permitindo que sistemas multiagentes (*multi-agent systems* – MAS) trabalhem em conjunto para cumprir missões complexas e dinâmicas.



FIGURA 1.1 – Drone da polícia militar do Distrito Federal (DEFESA, 2023).

Atualmente, mais de 20.000 drones são empregados em sistemas de defesa aérea em mais de 80 países, número que continua a crescer rapidamente (ADMINISTRATION, 2024; PICKRELL, 2019). Esses drones desempenham funções estratégicas em vigilância, reconhecimento e combate, proporcionando uma vantagem operacional significativa. A utilização de enxames de drones, onde os MAS operam de forma coordenada, oferece flexibilidade e eficiência, com potencial para realizar missões complexas de forma precisa e segura, reduzindo o risco para operadores humanos (WALLACE; LOFFI, 2015).

Enxames de drones são particularmente promissores em operações de defesa, pois permitem a cobertura de grandes áreas, missões de busca e resgate, e operações ofensivas com maior precisão. Para maximizar o potencial dos sistemas cooperativos multiagentes (*cooperative multi-agent systems* – CMAS), o desenvolvimento de estratégias de controle

avançadas é essencial. Métodos como o planejamento ótimo são investigados para aprimorar a capacidade de resposta e a resiliência dos drones em ambientes dinâmicos e incertos (SORIA *et al.*, 2022). Além disso, a integração com tecnologias de realidade mista possibilita novas formas de monitorar e controlar esses enxames, proporcionando interfaces intuitivas para operadores e melhorando a tomada de decisão em tempo real (RICARDO JR; SANTOS, 2023).

## 1.1 Revisão da Literatura

Com o aumento do interesse em aplicações com múltiplos agentes aéreos, surge a necessidade de estratégias específicas para o planejamento de trajetórias em MAS. Nessas aplicações, além de evitar colisões com obstáculos, é necessário lidar com restrições adicionais, como coordenação entre os agentes e escalabilidade. Diferente dos planejadores tradicionais, que focam em trajetórias individuais, abordagens voltadas para MAS devem considerar interações simultâneas entre múltiplos veículos, exigindo arquiteturas de controle e planejamento, sejam distribuídas ou centralizadas, capazes de manter desempenho mesmo com grande número de agentes.

Com o objetivo de calcular trajetórias viáveis e ótimas considerando diferentes critérios, como eficiência energética, tempo de execução, e segurança, torna-se fundamental integrar esses aspectos no processo de planejamento. Ao combinar otimização com restrições de coordenação entre os agentes, é possível garantir que as soluções atendam simultaneamente a todos esses requisitos, maximizando a performance geral do sistema e garantindo a viabilidade das missões mesmo em cenários complexos.

Nesse contexto, o trabalho de (PREISS *et al.*, 2017) apresenta uma arquitetura para controle de enxames de microveículos aéreos (*micro aerial vehicles* – MAVs) baseada no quadricóptero Crazyflie, permitindo operações com até 49 drones em ambientes internos. A solução inclui infraestrutura de comunicação otimizada, estimativa de estado precisa via captura de movimento e planejamento de trajetória a bordo dos veículos. O sistema utiliza polinômios segmentados para gerar trajetórias suaves em tempo real e modos interativos de evitamento de obstáculos, demonstrando robustez e escalabilidade em experimentos práticos.

Complementando essa linha de pesquisa, (PICHIERRI *et al.*, 2023) propõem o CRAZYCHOIR, uma estrutura modular baseada em um sistema operacional para robôs (*robot operating system* – ROS) 2 voltada à simulação e controle cooperativo de enxames de nano-quadricópteros Crazyflie. A plataforma integra funções de controle, planejamento e comunicação distribuída, permitindo experimentos em tarefas como formação, coleta, entrega, e rastreamento de trajetórias. A modularidade da arquitetura permite executar

processos independentes por drone, melhorando a tolerância a falhas e facilitando o escalonamento para enxames maiores. As simulações em *Webots* e os testes reais reforçam a aplicabilidade da ferramenta para desenvolvimento e validação de algoritmos cooperativos.

Em controle de formação para sistemas multiagentes, (CHEN; WANG, 2005) revisa conceitos de estabilidade, como *string*, *mesh* e *leader-to-formation stability*, e discute estratégias clássicas, incluindo leader-follower, estruturas virtuais, campos potenciais e o uso de teoria dos grafos. O trabalho aborda ainda os efeitos da comunicação imperfeita e sugere avanços com padrões morfológicos adaptativos, servindo de base para a evolução de métodos mais avançados como o controle preditivo baseado em modelo (*model predictive control* – MPC).

Com o avanço das aplicações com múltiplos veículos autônomos, cresce a demanda por soluções que considerem dinâmicas acopladas, restrições operacionais e coordenação segura entre agentes. Nesse contexto, o MPC destaca-se como abordagem promissora por permitir antecipar comportamentos futuros, otimizar trajetórias sob múltiplas restrições. Suas variantes, centralizada, distribuída e robusta, têm viabilizado o planejamento de trajetórias para MAS, permitindo operações cada vez mais complexas com múltiplos drones.

O trabalho de (VARGAS *et al.*, 2022) explora um esquema de MPC distribuído baseado em consenso para controle de formação de quadricópteros. A formulação considera agentes holonômicos e inclui restrições para evasão de colisões e manutenção da conectividade durante o deslocamento. Resultados experimentais com robôs reais confirmam que a integração de restrições suaves e rígidas no MPC melhora o desempenho na execução da formação desejada.

O trabalho de (LUIS *et al.*, 2020) propõem um algoritmo de controle preditivo distribuído (*distributed model predictive control* – DMPC), com replanejamento acionado por eventos, voltado para trajetórias em tempo real de múltiplos robôs. A estratégia adota otimização quadrática com evasão de colisão sob demanda, e se destaca em ambientes com alta densidade de agentes. Em linha com esse avanço, (SORIA *et al.*, 2022) apresenta uma aplicação do DMPC à navegação de enxames de drones em ambientes obstruídos, como florestas. O modelo é escalável e foi validado com até 16 drones operando em tempo real. Mesmo com medições ruidosas, os agentes mantêm distância segura e conectividade, demonstrando a eficácia da abordagem em ambientes complexos.

Focado em veículos aéreos não tripulados (*unmanned aerial vehicles* – UAVs) de asa fixa, (KONG *et al.*, 2023) propõe o uso de controle preditivo não linear (*nonlinear model predictive control* – NMPC) distribuído para manter agrupamento (*flocking*) e evitar obstáculos em cenários densamente obstruídos. O modelo incorpora regras de coesão, separação e migração, e distribui a carga computacional entre os agentes. As simulações

com 21 UAVs e oito obstáculos comprovam que o NMPC é eficaz para manter o arranjo coeso e seguro ao longo do trajeto.

Além disso, (SANTOS; LAGOA, 2022) trata do uso de controle preditivo robusto (*robust model predictive control* – RMPC) para guiar MAVs em ambientes sujeitos a perturbações e ruídos de medição. A solução hierárquica proposta combina leis estabilizadoras internas com um guia externo baseado em conjuntos de *waysets*. O modelo simplificado permite execução em tempo real e maior escalabilidade, validando sua aplicação com simulações de quadricópteros realistas.

À medida que os desafios de coordenação em MAS se tornam mais complexos, cresce a necessidade de abordagens que integrem planejamento, controle e tomada de decisão sob múltiplas restrições operacionais. O MPC com programação inteira mista (*mixed-integer programming* – MIP) tem se mostrado uma estratégia eficaz para lidar com esse cenário, ao permitir a inclusão simultânea de dinâmicas contínuas, decisões lógicas e restrições de segurança, como conectividade, evasão de obstáculos e alocação de alvos.

Nesse contexto, o trabalho de (BELLINGHAM *et al.*, 2002) apresenta uma das primeiras aplicações relevantes dessa integração, utilizando MPC com programação linear inteira mista (*mixed-integer linear programming* – MILP) para o planejamento de trajetória de veículos aéreos autônomos com restrições dinâmicas, zonas proibidas e obstáculos. A proposta resolve o problema em um horizonte retrocedente, utilizando estimativas heurísticas com base em grafos de visibilidade para guiar o veículo até o destino. Essa formulação permitiu alcançar desempenho próximo do ótimo, com custo computacional reduzido, mesmo em ambientes complexos.

No campo da alocação de tarefas para múltiplos UAVs, (BETHKE *et al.*, 2008) propõem uma abordagem baseada em MIP que integra informações de saúde dos veículos ao processo de atribuição de tarefas. O método utiliza monitoramento do estado do combustível, sensores e propulsão para adaptar dinamicamente as decisões de missão. Os resultados experimentais mostram que considerar o estado de saúde dos UAVs aumenta a robustez e reduz perdas de veículos, tornando o sistema mais eficiente em operações persistentes. Expandindo esse conceito, (KUWATA *et al.*, 2009) propõe um sistema de planejamento hierárquico em tempo real para veículos urbanos autônomos, com base em MPC e MIP. O sistema opera em dois níveis: o superior realiza o planejamento de rota em larga escala, enquanto o inferior executa ajustes finos de trajetória para respeitar regras de trânsito, limites de velocidade e obstáculos móveis. A solução foi validada experimentalmente, demonstrando viabilidade em tempo real sem comprometer a segurança da navegação.

Voltando-se para a robustez, (RICHARDS; HOW, 2006) introduz o conceito de MPC com horizonte variável robusto (*robust variable horizon model predictive control* — RVH-MPC), que ajusta dinamicamente o horizonte de predição em resposta a incertezas do

ambiente. Utilizando conjuntos de alcance (*reachable sets*) e formulação MIP, o método assegura viabilidade mesmo sob perturbações externas e variações de modelo, com bom desempenho computacional.

No planejamento de trajetórias em cenários dinâmicos, (BALLESTEROS-TOLOSANA *et al.*, 2017) e (MUKAI *et al.*, 2017) demonstram que formulações MIP podem ser aplicadas com eficiência para gerar trajetórias seguras em rodovias, abrangendo desde ultrapassagens e mudanças de faixa até operações de fusão. Ambos utilizam variáveis binárias para lidar com restrições de colisão e pista, além de técnicas que viabilizam soluções em tempo real mesmo em tráfego denso. Complementarmente, (CHEN *et al.*, 2016) abordam a evasão de colisão em sistemas multiagentes por meio de uma abordagem híbrida que combina análise de alcance baseada em Hamilton-Jacobi com MIP, superando limitações do controle par-a-par e permitindo coordenação eficiente e segura para múltiplos veículos.

Voltado para ambientes altamente obstruídos, (DEITS; TEDRAKE, 2015) propõem uma abordagem de planejamento de trajetórias para UAVs baseada em MIP, utilizando a segmentação do espaço livre em grandes regiões convexas. Ao invés de representar obstáculos pelas faces individuais, a técnica emprega o algoritmo IRIS para pré-calcular regiões convexas de espaço seguro, reduzindo o número de variáveis binárias necessárias e acelerando a otimização. O método também garante que as trajetórias polinomiais sejam inteiramente livres de colisão ao longo de todo o percurso, não apenas em pontos amostrados, aplicando técnicas de programação soma de quadrados (SOS). Resultados mostram que é possível encontrar trajetórias globais ótimas mesmo em cenários com múltiplos obstáculos, viabilizando aplicações em tempo real para UAVs em ambientes complexos.

De modo relacionado, (MAIA; GALVAO, 2009) mostram que, em formulações MILP clássicas, a simples imposição das restrições nos instantes de amostragem pode permitir violações de obstáculos entre os pontos. Para evitar esse problema, tanto eles quanto (RICHARDS; TURNBULL, 2015) propõem restrições adicionais para garantir a segurança ao longo dos segmentos de trajetória, sendo que este último apresenta uma abordagem simples e eficiente que também trata trajetórias curvas e reduz a necessidade de amostragens densas. Ainda nesse contexto de UAVs com dinâmicas complexas e obstáculos não convexos, (JANEČEK *et al.*, 2017) apresentam a toolbox OPTIPLAN, que automatiza a formulação e simulação de problemas de evasão de obstáculos com MPC, permitindo tratar restrições não convexas tanto via MIP, com variáveis binárias, quanto via restrições convexas dependentes do tempo. A ferramenta facilita a aplicação e a avaliação de estratégias avançadas de MPC em cenários realistas, mostrando a viabilidade dos métodos em ambientes dinâmicos e com múltiplos obstáculos.

No domínio dos sistemas híbridos, (PRODAN *et al.*, 2013) propõem uma estrutura geral de MPC baseada em modelos lógicos dinâmicos mistos (*mixed logical dynamical* – MLD), na qual requisitos de segurança e comportamento desejado são expressos como fórmulas

temporais lineares (*linear temporal logic* – LTL) e incorporados diretamente no problema de otimização MIP. Essa integração entre controle preditivo e especificações formais permite que sistemas reativos operem de forma segura e lógica, mesmo sob incertezas. Esse arcabouço teórico é aprofundado por (PRODAN *et al.*, 2016), que apresentam uma revisão abrangente sobre problemas de controle envolvendo decisões mistas. O capítulo discute formulações MIP, propriedades de estabilidade, viabilidade e aplicação em sistemas com dinâmica contínua e lógica discreta. Exemplos incluem robótica, sistemas industriais e veículos autônomos, destacando a relevância do controle híbrido para aplicações complexas. Uma revisão mais recente sobre essa abordagem é apresentada por (IOAN *et al.*, 2021), que detalham o uso de MIP no planejamento de movimento, incluindo desafios computacionais, propriedades de estabilidade e exemplos aplicados a sistemas multiagentes, sistemas híbridos e outras aplicações críticas.

No contexto de MAS, (AFONSO *et al.*, 2020) aplicam MPC com MILP para coordenar múltiplos agentes em tarefas de alocação de alvos, evitando colisões e mantendo a conectividade da rede. A formulação considera restrições de comunicação e dinâmicas individuais dos agentes, mostrando viabilidade em tempo real para cenários dinâmicos. Dando continuidade, (SOUZA, 2023) explora a manutenção de conectividade em MAS com restrições de comunicação *k-hop*, utilizando uma abordagem baseada em programação não linear (*nonlinear programming* – NLP). O autor introduz variáveis binárias para modelar ligações na topologia de comunicação, comparando com NLP para representar as restrições de conectividade de forma contínua. Já (AFONSO *et al.*, 2024) também aborda a manutenção de conectividade em MAS com restrições *k-hop*, porém com uma formulação baseada exclusivamente em MIP, sem recorrer ao uso de NLP. Esse trabalho avalia a capacidade de garantir a conectividade de maneira eficiente e robusta, mantendo a eficiência computacional.

Adicionalmente, (CAREGNATO-NETO *et al.*, 2023) propõem um modelo MIP voltado à garantia de linha de visada (*line-of-sight* – LOS) entre agentes em ambientes obstruídos. A proposta introduz uma checagem baseada em pontos intermediários no segmento entre os agentes, reduzindo a quantidade de variáveis binárias e, com isso, o tempo de otimização. As simulações demonstram que o método mantém conectividade visual de forma eficiente, com potencial para aplicações que exigem comunicação ininterrupta, como em missões cooperativas de drones e robôs móveis urbanos.

Esses trabalhos ilustram a evolução do uso de MPC com programação inteira mista, desde problemas isolados com veículos autônomos até sistemas multiagente altamente coordenados. As diferentes formulações demonstram flexibilidade para incorporar decisões lógicas, incertezas e restrições operacionais, consolidando-se como ferramentas-chave no planejamento de trajetória e controle em tempo real de sistemas complexos e distribuídos.

## 1.2 Contribuições

A presente dissertação contribui para a literatura sobre planejamento de trajetórias em CMAS ao propor uma abordagem integrada baseada em planejamento ótimo para ambientes tridimensionais sujeitos a restrições operacionais complexas. Entre as principais características do trabalho, destaca-se a integração da tomada de decisão ao próprio processo de otimização, permitindo a alocação dinâmica de agentes a alvos durante a execução da missão. Embora o planejador seja projetado para funcionar offline, ele permite a reavaliação das condições do cenário, como nível de energia e estado operacional dos agentes, promovendo um planejamento eficiente e adaptativo com base nas informações disponíveis antes da execução.

Outra contribuição relevante é a formulação de uma restrição de velocidade terminal, que assegura que os agentes não apenas alcancem seus alvos, mas o façam de maneira compatível com a dinâmica dos próprios alvos. Essa característica amplia as possibilidades de atuação cooperativa após a interceptação, viabilizando ações como perseguição ou manutenção de formação. A metodologia também avança ao considerar explicitamente as limitações energéticas e operacionais dos agentes, aproximando a modelagem das condições práticas enfrentadas em missões reais. Essa abordagem reforça a aplicabilidade do sistema em cenários nos quais a autonomia e a eficiência são fatores críticos.

Os resultados obtidos em ambiente de simulação demonstram a eficácia da proposta em cenários com múltiplos agentes, obstáculos e alvos móveis, validando a robustez da solução frente a desafios típicos de aplicações em defesa, vigilância e inspeção automatizada. Complementando essa validação, foi realizada uma demonstração prática em ambiente de realidade mista, envolvendo a operação coordenada de drones reais e agentes simulados. Esta experiência confirma a viabilidade da abordagem em contextos cooperativos, nos quais agentes físicos e virtuais interagem de forma integrada.

Com essas contribuições, o trabalho amplia o estado da arte em controle preditivo aplicado a sistemas autônomos cooperativos, oferecendo uma solução adaptativa, eficiente e alinhada às demandas de ambientes dinâmicos e restritos, com potencial de aplicação em diversas áreas estratégicas.

Parte dos resultados obtidos ao longo desta dissertação foi consolidada e submetida à comunidade científica por meio de artigos em eventos relevantes da área. O primeiro trabalho (CRUZ *et al.*, 2024), intitulado “A Mixed-Reality Experimental Indoor Testbed for Evaluation of Drone Flight Control Methods”, foi publicado nos anais do Congresso Brasileiro de Automática 2024 (CBA 2024) e descreve a plataforma experimental utilizada para validação dos algoritmos em ambiente indoor controlado, com integração entre simulação e execução física. O segundo trabalho (CRUZ *et al.*, 2025), ainda em processo de revisão, intitulado “Optimal Trajectory Planning for Aerial Threat Neutralization Using a Multi-

Drone System with Limited Resources", foi submetido ao 28th International Congress of Mechanical Engineering (COBEM 2025), e apresenta os aspectos teóricos e práticos do planejador de trajetória proposto, aplicando-o em cenários de defesa com restrições energéticas e coordenação multiagente.

## 1.3 Organização do Texto

Esta dissertação está organizada em sete capítulos, conforme descrito a seguir:

- **Capítulo 2:** Apresenta a contextualização detalhada do problema abordado, definindo o cenário, os desafios operacionais e as principais motivações para o desenvolvimento da solução proposta. São descritos os requisitos do sistema, as limitações enfrentadas e os objetivos a serem alcançados.
- **Capítulo 3:** Aborda a fundamentação teórica necessária para o entendimento da metodologia, incluindo conceitos de otimização com restrições e planejamento ótimo.
- **Capítulo 4:** Apresenta a formulação matemática detalhada do problema, contemplando a modelagem das restrições, dos objetivos e da dinâmica dos agentes.
- **Capítulo 5:** Descreve a implementação da metodologia proposta, detalhando as ferramentas utilizadas, a configuração do ambiente computacional, os algoritmos empregados e as estratégias adotadas para garantir a viabilidade computacional do sistema em tempo de execução.
- **Capítulo 6:** Apresenta os cenários de teste desenvolvidos em ambiente de simulação, bem como a análise dos resultados obtidos. São avaliados aspectos como eficiência energética, tempo de missão, segurança na navegação e desempenho da alocação dinâmica dos agentes.
- **Capítulo 7:** Apresenta a demonstração prática da metodologia em um ambiente de realidade mista, envolvendo a operação coordenada de drones reais e agentes simulados. São descritas as configurações do experimento, os desafios enfrentados e os resultados observados.
- **Capítulo 8:** Apresenta as principais conclusões da pesquisa, destacando as contribuições alcançadas e a eficácia da solução proposta. Além disso, discute possíveis aprimoramentos e direções para trabalhos futuros que possam expandir a aplicabilidade da metodologia desenvolvida.

# 2 Apresentação do Problema

O cenário considerado neste trabalho representa um espaço tridimensional, voltado para aplicações de defesa aérea. Trata-se de uma zona monitorada e delimitada, cujo objetivo é simular a proteção contra a aproximação de ameaças externas. Como ilustrado na Figura 2.1, os alvos são representados por drones na cor vermelha, enquanto os agentes defensores são identificados pelas cores branca e verde, codificação adotada exclusivamente para fins ilustrativos.

Os agentes devem se posicionar estrategicamente para interceptar os alvos antes que estes atinjam a região central, considerada crítica para a defesa. O cenário pode incluir obstáculos fixos, como edificações, zonas de exclusão ou fronteiras operacionais, que devem ser levados em conta no processo de planejamento das trajetórias.

A arquitetura adotada é centralizada, as posições e velocidades dos alvos são captadas por um radar fixo e transmitidas ao planejador de trajetórias. Este, por sua vez, coordena os agentes defensores por meio de um método de controle otimizado.

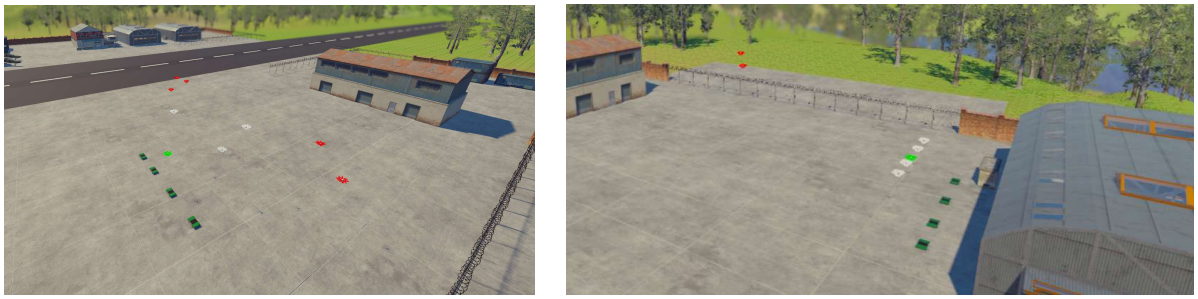


FIGURA 2.1 – Ilustração do ambiente tridimensional de defesa aérea, com agentes (branco e verde) e alvos (vermelho).

## 2.1 Formulação do Problema Geral

Este trabalho trata do controle de um CMAS, para sistemas aéreos autônomos em um espaço tridimensional com alvos móveis. O objetivo principal é planejar trajetórias seguras e otimizadas para os agentes, de forma que possam interceptar os alvos respeitando

restrições físicas (posição, velocidade e aceleração), evitando colisões e promovendo o uso eficiente dos recursos disponíveis.

A formulação parte da premissa de que os agentes operam em um ambiente compartilhado, onde múltiplos alvos podem surgir ao longo do tempo, exigindo decisões coordenadas. O planejador de trajetórias deve garantir:

- geração de trajetórias viáveis, suaves e fisicamente realizáveis, que levem os agentes até seus respectivos alvos dentro dos limites operacionais.
- interceptação eficiente dos alvos móveis, baseada em informações periódicas de posição e velocidade fornecidas por um radar, com alinhamento vetorial de velocidade para possibilitar ações subsequentes, caso necessário.
- evitamento de colisões, tanto entre agentes quanto com obstáculos fixos no ambiente.
- alocação dinâmica de tarefas, considerando critérios como tempo de missão e capacidade operacional de cada agente.

A complexidade do problema se intensifica devido aos seguintes fatores:

- restrições físicas impostas aos agentes, incluindo limites máximos e mínimos de posição, velocidade e aceleração nos três eixos.
- operação simultânea de múltiplos agentes em um espaço restrito, o que aumenta o risco de interferência mútua.
- necessidade de balancear objetivos concorrentes, como tempo de interceptação, consumo energético e segurança da operação.

Formalmente, o problema consiste em determinar, a cada instante de tempo discreto, a ação de controle ótima capaz de guiar os agentes no cumprimento de suas missões de rastreio e interceptação, maximizando a eficiência global da operação. Essa estratégia é formulada por meio de um planejador ótimo.

O uso desse planejador se justifica por sua capacidade de lidar explicitamente com restrições dinâmicas e operacionais, como limites de posição, velocidade, aceleração e segurança. Além disso, essa abordagem permite prever a evolução futura do sistema ao longo de um horizonte definido, otimizando as ações com base em informações atuais e antecipadas. Durante a execução, o controlador reavalia o plano a cada instante, ajustando dinamicamente as trajetórias frente a mudanças no ambiente, tornando-o particularmente adequado para cenários complexos e dinâmicos como os considerados neste trabalho.

## 2.2 Modelo Dinâmico

O comportamento de cada agente é modelado por um sistema dinâmico linear de segunda ordem criticamente amortecido. Essa escolha se justifica pela capacidade do modelo em representar a resposta de drones a comandos de referência em posição, proporcionando transições suaves e garantindo estabilidade assintótica, sem sobressinal. Essas características facilitam a previsão do comportamento futuro do sistema, o que é essencial para a aplicação do planejador, que depende da acurácia do modelo dinâmico para otimizar decisões ao longo do horizonte de planejamento.

A modelagem é feita individualmente para cada eixo do espaço tridimensional, com a posição de referência $u(t) \in \mathbb{R}$ como entrada. A dinâmica contínua em um eixo é descrita por uma equação diferencial de segunda ordem superamortecida

$$\ddot{r}(t) + a_1 \dot{r}(t) + a_0 r(t) = a_0 u(t), \tag{2.1}$$

onde $r(t)$ representa a posição e os coeficientes $a_1$ e $a_0$ são definidos com base no tempo de acomodação desejado $t_a$. Neste trabalho, adota-se $t_a = 2$ segundo, valor que garante uma resposta rápida, estável e bem amortecida, adequada para aplicações em ambientes com espaço limitado e necessidade de transições suaves. Com isso, define-se $\omega_n = \frac{4}{t_a}$, o que resulta em $a_1 = 2\omega_n$ e $a_0 = \omega_n^2$. A equação pode ser reescrita em forma de espaço de estados como

$$\dot{\mathbf{x}}(t) = \begin{bmatrix} 0 & 1 \\ -\omega_n^2 & -2\omega_n \end{bmatrix} \mathbf{x}(t) + \begin{bmatrix} 0 \\ \omega_n^2 \end{bmatrix} u(t), \tag{2.2}$$

onde o vetor de estado de um único eixo é

$$\mathbf{x}(t) = \begin{bmatrix} r(t) \\ \dot{r}(t) \end{bmatrix} \in \mathbb{R}^2. \tag{2.3}$$

O modelo tridimensional é obtido pela replicação dessa dinâmica para os eixos $x$, $y$ e $z$, formando um modelo contínuo com as seguintes matrizes ampliadas:

$$\mathbf{A} = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 \\ -\omega_n^2 & -2\omega_n & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & -\omega_n^2 & -2\omega_n & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & -\omega_n^2 & -2\omega_n \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 0 & 0 & 0 \\ \omega_n^2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & \omega_n^2 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & \omega_n^2 \end{bmatrix}. \tag{2.4}$$

Essas matrizes representam a evolução do vetor de estado completo $\mathbf{x}_i(t) \in \mathbb{R}^{n_\xi}$, com $n_\xi = 6$, e entradas de referência $\mathbf{u}_i(t) \in \mathbb{R}^{n_u}$, com $n_u = 3$, aplicadas independentemente

em cada eixo do agente $i$.

A discretização do modelo contínuo é realizada utilizando o método de retenção de ordem zero (*zero order hold* – ZOH), com tempo de amostragem $t_s = 0{,}2$ segundo. O modelo resultante em tempo discreto assume a forma

$$\mathbf{x}_i(k+1) = \mathbf{A}_d\mathbf{x}_i(k) + \mathbf{B}_d\mathbf{u}_i(k), \tag{2.5}$$

em que $\mathbf{x}_i(k) \in \mathbb{R}^{n_\xi}$ representa o vetor de estado do agente $i$, estruturado como uma sequência intercalada de posição e velocidade para cada eixo

$$\mathbf{x}_i(k) = \begin{bmatrix} r_x^i(k) & v_x^i(k) & r_y^i(k) & v_y^i(k) & r_z^i(k) & v_z^i(k) \end{bmatrix}^{\mathrm{T}}. \tag{2.6}$$

O vetor de entrada $\mathbf{u}_i(k) \in \mathbb{R}^{n_u}$ corresponde às posições de referência aplicadas nos eixos $x$, $y$ e $z$, utilizadas como sinal de controle pelo modelo dinâmico.

As matrizes discretas $\mathbf{A}_d \in \mathbb{R}^{n_\xi \times n_\xi}$ e $\mathbf{B}_d \in \mathbb{R}^{n_\xi \times n_u}$, obtidas a partir da discretização do modelo contínuo criticamente amortecido com $t_a = 2$ s, são dadas por

$$\mathbf{A}_d = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 \\ -4 & -4 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & -4 & -4 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & -4 & -4 \end{bmatrix}, \quad \mathbf{B}_d = \begin{bmatrix} 0 & 0 & 0 \\ 4 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 4 \end{bmatrix}. \tag{2.7}$$

## 2.3 Variáveis de Saída do Modelo Dinâmico

As variáveis de saída representam grandezas físicas observáveis ou derivadas a partir do modelo dinâmico dos agentes. Elas são essenciais tanto para o monitoramento do comportamento durante a execução quanto para a imposição de restrições dentro do esquema do otimizador. No modelo em tempo discreto, essas saídas são obtidas por meio da relação

$$\mathbf{y}_i(k) = \mathbf{C}_d\mathbf{x}_i(k) + \mathbf{D}_d\mathbf{u}_i(k), \tag{2.8}$$

onde $\mathbf{y}_i(k) \in \mathbb{R}^{n_y}$ representa o vetor de saídas do agente $i$, com $n_y = 9$, contendo as variáveis de posição, velocidade e aceleração nos três eixos. As matrizes $\mathbf{C}_d \in \mathbb{R}^{n_y \times n_\xi}$ e $\mathbf{D}_d \in \mathbb{R}^{n_y \times n_u}$ são derivadas da discretização do modelo contínuo e estruturadas para extrair seletivamente componentes do vetor de estado $\mathbf{x}_i(k) \in \mathbb{R}^{n_\xi}$ e das entradas de controle $\mathbf{u}_i(k) \in \mathbb{R}^{n_u}$. As saídas podem ser organizadas em três grupos principais, cada um com dimensão $n_{y_p} = 3$:

- **posição** — extraída por meio da matriz $\mathbf{C}_p \in \mathbb{R}^{n_{y_p} \times n_\xi}$, que seleciona os termos do vetor de estado $\mathbf{x}_i(k)$ correspondentes à posição $\mathbf{r}_a^i(k)$. Essa variável representa a localização tridimensional do agente no referencial global $\mathcal{S}_g$, sendo essencial para o rastreamento de alvos e para a verificação de restrições de permanência e alcance.

- **velocidade** — obtida por meio da matriz $\mathbf{C}_v \in \mathbb{R}^{n_{y_p} \times n_\xi}$, que isola os componentes $\mathbf{v}_a^i(k)$ do vetor de estado. Essa variável é utilizada para garantir que o movimento do agente permaneça dentro dos limites dinâmicos estabelecidos, prevenindo comportamentos instáveis e respeitando as capacidades físicas da plataforma aérea.

- **aceleração** — estimada por meio de uma combinação linear entre o vetor de estado e a entrada de controle, de acordo com a equação:

$$\mathbf{a}_i(k) = \mathbf{C}_a \mathbf{x}_i(k) + \mathbf{D}_a \mathbf{u}_i(k), \tag{2.9}$$

  em que $\mathbf{C}_a \in \mathbb{R}^{n_{y_p} \times n_\xi}$ e $\mathbf{D}_a \in \mathbb{R}^{n_{y_p} \times n_u}$, apresentadas na equação (2.10).

$$\mathbf{C}_a = \begin{bmatrix} -4 & -4 & 0 & 0 & 0 & 0 \\ 0 & 0 & -4 & -4 & 0 & 0 \\ 0 & 0 & 0 & 0 & -4 & -4 \end{bmatrix}, \quad \mathbf{D}_a = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{bmatrix}. \tag{2.10}$$

  Diferentemente da posição e da velocidade, a aceleração $\mathbf{a}_i(k) \in \mathbb{R}^3$ não está diretamente presente no vetor de estado, mas é inferida a partir da dinâmica do modelo. A inclusão dessa variável no modelo permite impor limites ao esforço dos atuadores, controlar o consumo energético e suavizar o perfil das trajetórias.

A definição explícita das matrizes $\mathbf{C}_p$, $\mathbf{C}_v$, $\mathbf{C}_a$ e $\mathbf{D}_a$ permite extrair diretamente as variáveis de interesse, posição, velocidade e aceleração, a partir dos estados e entradas do modelo. Essa abordagem favorece a organização do modelo e simplifica a formulação de restrições no problema de otimização, mantendo a estrutura compatível com diferentes cenários e configurações de missão.

# 3 Fundamentos para a Solução do Problema

Este capítulo apresenta os fundamentos matemáticos que sustentam a abordagem proposta, bem como as formulações que viabilizam a resolução do problema definido no Capítulo 2. O conteúdo é organizado de forma modular, com base na estrutura de um problema de programação inteira mista quadrática (*mixed-integer quadratic programming* – MIQP), compatível com cenários dinâmicos envolvendo múltiplos agentes, alvos móveis e obstáculos.

Na Seção 3.1, são discutidos os princípios da otimização com restrições, abordando conceitos fundamentais e métodos de solução relevantes para a modelagem do problema. Em seguida, a Seção 3.2 apresenta os fundamentos do planejador ótimo, detalhando sua estrutura, mecanismo de funcionamento e sua aplicação ao planejamento de trajetórias, com foco na antecipação de dinâmicas e na imposição explícita de restrições. Por fim, a Seção 3.3 introduz o uso de variáveis binárias no contexto do planejador e a técnica do Big-M, permitindo a formulação de restrições condicionais e a modelagem de decisões discretas no cenário multiagente.

## 3.1 Problemas de Otimização com Restrições

A otimização com restrições é um ramo da otimização matemática que trata de problemas em que a variável de decisão $\mathbf{x} \in \mathbb{R}^n$ deve satisfazer um conjunto de condições, conhecidas como restrições, além de minimizar ou maximizar uma função objetivo $f(x)$ (FLETCHER, 2000; KIRK, 2004; BOYD; VANDENBERGHE, 2004; BAZARAA *et al.*, 2006). Este tipo de problema é amplamente encontrado em aplicações práticas, como controle de sistemas, planejamento de trajetórias e alocação de recursos, onde limitações físicas, de segurança ou operacionais precisam ser consideradas.

A formulação geral de um problema de otimização com restrições pode ser expressa

como:

$$\min_{x \in \mathbb{R}^n} f(x), \quad \text{sujeito a} \quad \begin{cases} g_i(x) \leq 0, & i = 1, \ldots, m, \\ h_j(x) = 0, & j = 1, \ldots, p. \end{cases} \tag{3.1}$$

Nesta formulação, $f(x) : \mathbb{R}^n \to \mathbb{R}$ é a função objetivo que deve ser minimizada, $g_i(x) : \mathbb{R}^n \to \mathbb{R}$ representa as restrições de desigualdade que delimitam o espaço viável e $h_j(x) : \mathbb{R}^n \to \mathbb{R}$ corresponde às restrições de igualdade que precisam ser satisfeitas (RUSZCZYNSKI, 2011; LUENBERGER; YE, 1984).

### 3.1.1 Problemas Convexos e Não Convexos

A classificação de um problema de otimização como convexo ou não convexo tem implicações diretas sobre a complexidade da solução e sobre a garantia de obtenção de ótimos globais. Um problema é dito convexo quando a função objetivo $f(x)$ é convexa e o conjunto viável definido pelas restrições $g_i(x) \leq 0$, $h_j(x) = 0$ e formam um domínio convexo. Nesses casos, qualquer mínimo local é também global, e algoritmos como o gradiente descendente ou métodos de pontos interiores tendem a convergir eficientemente (BOYD; VANDENBERGHE, 2004; NOCEDAL; WRIGHT, 1999; BEN-TAL; NEMIROVSKI, 2001; BIEGLER, 2010).

No contexto deste trabalho, um exemplo típico de problema convexo seria o planejamento de trajetória de um único agente, com o objetivo de minimizar o esforço de controle ou o tempo de percurso, sujeito a restrições lineares de posição, velocidade e aceleração. Quando todos os termos envolvidos são lineares ou quadráticos, o problema pode ser resolvido de forma eficiente via programação quadrática (*quadratic programming* – QP) convexa, com garantia de otimalidade global.

Em contraste, problemas não convexos surgem quando há variáveis discretas, descontinuidades ou restrições não lineares. Um exemplo relevante no planejador de trajetórias proposto é a alocação dinâmica de agentes a múltiplos alvos, considerando diferentes níveis de bateria. Essa decisão envolve combinatórias modeladas por variáveis binárias, caracterizando o problema como MIQP. Nesses casos, o espaço de busca torna-se não convexo, e a solução ótima depende do uso de técnicas como *branch-and-bound*, relaxações sucessivas ou heurísticas específicas.

Distinguir corretamente entre problemas convexos e não convexos é fundamental para a escolha do solucionador adequado, impactando diretamente no tempo de solução, robustez numérica e escalabilidade da arquitetura de controle.

### 3.1.2 Métodos de Solução para MILP/MIQP

A resolução de problemas de otimização do tipo MILP e MIQP exige métodos especializados, pois tais problemas envolvem variáveis contínuas e inteiras e apresentam estrutura combinatória (NEMHAUSER; WOLSEY, 1998; RICHARDS; HOW, 2005). Solucioná-los não é trivial e demanda técnicas avançadas para garantir viabilidade computacional e qualidade das soluções. A seguir, são descritos os principais métodos utilizados, de acordo com o estado da arte (CONFORTI *et al.*, 2014; BERTSIMAS; TSITSIKLIS, 1997; LIU *et al.*, 2024; QUIRYNEN *et al.*, 2025).

#### 3.1.2.1 Branch-and-Bound

O algoritmo *branch-and-bound* é uma das técnicas fundamentais para resolver MILP. Ele adota uma abordagem de busca em árvore, explorando possíveis soluções ao dividir o problema em subproblemas menores (ramificações) e eliminar ("podar") ramos que não podem resultar em soluções melhores que a já encontrada. O método se divide em três etapas principais:

- Branching (Divisão): O problema é dividido em subproblemas, geralmente com base nas variáveis inteiras.
- Bounding (Limitação): É calculado um limite superior ou inferior para o custo mínimo de cada subproblema.
- Pruning (Poda): Subproblemas que não possuem potencial para melhorar o valor da melhor solução viável encontrada até o momento (incumbente) são eliminados.

O *branch-and-bound* pode ser eficiente, mas sua complexidade cresce exponencialmente com o número de variáveis inteiras e a quantidade de restrições do problema.

#### 3.1.2.2 Cutting Planes

A técnica de *cutting planes* busca acelerar a solução de MILP e MIQP pela adição de restrições adicionais, chamadas cortes, ao problema original. Esses cortes, baseados na geometria do problema, eliminam regiões inviáveis do espaço de soluções sem excluir soluções ótimas. Alguns tipos comuns de cortes incluem:

- Cortes de Gomory: Baseados na solução relaxada do problema inteiro.
- Cortes de Chvátal-Gomory: Refinam a solução relaxada do MILP.

- Cortes de fluxo: Eliminam soluções inviáveis em problemas de rede.

Os cortes são gerados iterativamente, normalmente em conjunto com o *branch-and-bound*, reduzindo o número de nós explorados e acelerando o processo de resolução.

#### 3.1.2.3 Branch-and-Cut

O *branch-and-cut* combina as abordagens *branch-and-bound* e *cutting planes*. Essa técnica, bastante utilizada em MILP e MIQP, alia a busca em árvore à geração de cortes durante a solução. Cortes são aplicados em cada nível da árvore de busca, reduzindo significativamente o espaço de soluções a ser explorado. O *branch-and-cut* é especialmente eficiente para problemas de grande porte, como planejamento de trajetórias e alocação de recursos.

### 3.1.3 Software e Ferramentas de Resolução

Diversos softwares e bibliotecas especializadas resolvem MILP e MIQP. Os mais populares são:

- CPLEX (IBM): Solver amplamente utilizado para MILP, com suporte a diversas técnicas avançadas (IBM, 2023).
- Gurobi: Solver comercial de alto desempenho para MILP e MIQP, reconhecido pela performance e funcionalidades, com disponibilidade de licenças acadêmicas (Gurobi Optimization, LLC, 2024).
- SCIP: Solver open source que integra *branch-and-bound*, *cutting planes* e outros métodos (ACHTERBERG, 2009).

Esses solvers implementam as técnicas descritas e são referência tanto em pesquisa quanto em aplicações industriais (RICHARDS; TURNBULL, 2015).

## 3.2 Planejadores Ótimos

Os planejadores ótimos são técnicas amplamente utilizadas para resolver problemas de planejamento de trajetórias em sistemas dinâmicos. Essa abordagem busca determinar a sequência ótima de ações, ou trajetória, que minimiza uma função objetivo, sujeita a um conjunto de restrições, buscando soluções diretas para o problema de alocação de recursos e alvos com base em condições de contorno e na dinâmica do sistema (CAMACHO; BORDONS, 2007; KERRIGAN; MACIEJOWSKI, 2002; KOUVARITAKIS; CANNON, 2016).

### 3.2.1 Princípios Fundamentais dos Planejadores Ótimos

Os planejadores ótimos utilizam um modelo dinâmico do sistema para calcular a sequência de ações $\mathbf{u}(k), \mathbf{u}(k+1), \ldots, \mathbf{u}(k+n_{\max}-1)$ ao longo de um horizonte de predição finito $n_{\max}$, de forma a minimizar uma função de custo que pode envolver múltiplos critérios, como tempo de operação, consumo de energia e precisão no rastreamento de trajetórias (CARVALHO, 2015). A principal diferença entre os planejadores ótimos e o controle preditivo está na formulação do problema de otimização, que é resolvido uma única vez, ao invés de ser iterativamente recalculado em cada iteração (KOUVARITAKIS; CANNON, 2016).

A formulação de um planejador ótimo geralmente envolve a minimização de uma função de custo $J$ em relação a uma sequência de entradas $\mathbf{u}$, sujeita a restrições no sistema. O problema de otimização pode ser descrito genericamente como

$$\min_{\mathbf{u}} J(\mathbf{u}, \mathbf{x}(k)) = \sum_{i=1}^{n_{\max}} \ell(\hat{\mathbf{x}}(k+i), \mathbf{u}(k+i)), \tag{3.2}$$

onde $\hat{\mathbf{x}}(k+i)$ representa o estado do sistema no instante $k+i$, e $\mathbf{u}(k+i)$ são as entradas de controle aplicadas ao sistema. A função de custo $\ell(\hat{\mathbf{x}}(k+i), \mathbf{u}(k+i))$ combina o erro de rastreamento do estado em relação a um estado de referência $\mathbf{x}_{\text{ref}}$ e o esforço de controle, de modo a otimizar tanto o desempenho quanto a viabilidade do sistema.

### 3.2.2 Modelagem do Sistema

O comportamento do sistema é modelado através de equações de estado que descrevem como o sistema evolui com o tempo sob a influência das entradas de controle. Para sistemas lineares, a equação de estado assume a forma:

$$\mathbf{x}(k+1) = \mathbf{A}\mathbf{x}(k) + \mathbf{B}\mathbf{u}(k), \tag{3.3}$$

onde $\mathbf{A}$ é a matriz de transição de estados e $\mathbf{B}$ é a matriz de controle, que relaciona as entradas de controle aos estados do sistema.

Em sistemas não lineares, a dinâmica do sistema é descrita por:

$$\mathbf{x}(k+1) = f(\mathbf{x}(k), \mathbf{u}(k)), \tag{3.4}$$

onde $f(\mathbf{x}(k), \mathbf{u}(k))$ representa uma função não linear que descreve a evolução dos estados do sistema sob a aplicação das entradas de controle.

### 3.2.3 Restrições no Planejador Ótimo

Assim como no MPC, os planejadores ótimos podem incorporar restrições diretamente no problema de otimização, o que é essencial para garantir que o comportamento do sistema permaneça dentro dos limites operacionais e de segurança. (CAMACHO; BORDONS, 2007; KOUVARITAKIS; CANNON, 2016), apresenta detalhadamente como funciona a montagem dessas restrições. Essas restrições podem incluir limites de posição, velocidade, aceleração, e outras condições que são relevantes para o desempenho do sistema. As restrições podem ser modeladas como:

$$\mathbf{x}_{\min} \leq \mathbf{x}(k) \leq \mathbf{x}_{\max}, \tag{3.5}$$

onde $\mathbf{x}_{\min}$ e $\mathbf{x}_{\max}$ representam os limites inferiores e superiores para o estado do sistema. Similarmente, as restrições nas entradas de controle podem ser expressas como:

$$\mathbf{u}_{\min} \leq \mathbf{u}(k) \leq \mathbf{u}_{\max}, \tag{3.6}$$

onde $\mathbf{u}_{\min}$ e $\mathbf{u}_{\max}$ definem os limites de operação para as entradas de controle, como por exemplo a força de controle aplicada aos atuadores.

### 3.2.4 Resolução do Problema de Otimização

A resolução do problema de otimização formulado pelo planejador, descrito pelas equações (3.2) e (3.3), é realizada iterativamente a cada instante de controle. A abordagem de solução varia dependendo da linearidade do modelo e da natureza das restrições.

Para sistemas lineares, o problema assume frequentemente a forma de um QP, onde a função de custo é quadrática nas variáveis de controle e as restrições são lineares, detalhado em (BOYD; VANDENBERGHE, 2004; NOCEDAL; WRIGHT, 1999). Problemas QP são resolvidos de maneira eficiente por métodos numéricos como simplex ou interior-point, amplamente utilizados devido à sua robustez e garantia de convergência.

Em sistemas não lineares, como apresentado em (FLOUDAS, 1995) e aqueles descritos pela equação (3.4), o problema é tratado como uma NLP. Para resolver problemas NLP, são empregados métodos baseados em gradientes, como o método de Newton ou o gradiente reduzido, e, em casos mais complexos, métodos heurísticos, como algoritmos genéticos ou otimização por enxame de partículas, que são úteis para lidar com não linearidades severas ou funções de custo não diferenciáveis.

Além disso, em problemas que envolvem restrições ativáveis, como mudança de condições ou obstáculos dinâmicos, é comum introduzir variáveis binárias para modelar a ativação ou desativação de restrições, discutidos em (BIEGLER, 2010; KIRK, 2004). Nesse

caso, o problema é formulado como um MIP, resolvida por algoritmos como branch-and-bound ou técnicas de relaxação contínua. Essas variáveis permitem maior flexibilidade na modelagem, mas aumentam a complexidade computacional. No otimizador proposto, essa estrutura de resolução é adaptada para lidar com a dinâmica dos drones e a necessidade de replanejamento contínuo, o que torna a abordagem adequada para aplicações em cenários cooperativos e dinâmicos.

### 3.2.5 Planejador Ótimo com Horizonte Variável

O planejador de trajetórias proposto neste trabalho segue uma abordagem com horizonte de predição variável, permitindo que o número de variáveis de decisão seja ajustado ao longo da missão. Isso se alinha com a ideia de reduzir progressivamente o horizonte de predição à medida que a missão avança, o que diminui a complexidade computacional do problema. A cada iteração, após a aplicação do controle ótimo $\mathbf{u}^*(k)$, o horizonte é reduzido, mantendo o planejamento eficiente e garantindo que as mudanças no sistema sejam levadas em consideração. Essa abordagem também facilita a adaptação a novas condições do ambiente e do sistema (KERRIGAN; MACIEJOWSKI, 2002; KOUVARITAKIS; CANNON, 2016; AMMOUR *et al.*, 2022).

Essa estratégia é particularmente útil em cenários de missão com múltiplos agentes e obstáculos móveis, pois permite otimizar as alocações e as trajetórias de maneira eficiente, respeitando as restrições operacionais, sem sobrecarregar o sistema computacional.

#### 3.2.5.1 Formulação do Horizonte Variável com MIP

Uma alternativa à formulação de horizonte variável descrita anteriormente é a utilização de um horizonte dinâmico baseado em MIP. Nessa abordagem, o horizonte de predição é ajustado de forma explícita, de acordo com a necessidade de adaptação às condições do ambiente e do sistema. A principal vantagem dessa formulação está na possibilidade de integrar a escolha do horizonte de predição diretamente na otimização, sem a necessidade de um ajuste manual progressivo como na abordagem anterior.

Neste caso, a variável binária associada ao tempo de término $b_t(k)$ é utilizada para decidir dinamicamente qual será o instante final do horizonte $n^*$. A variável $b_t(k)$ pode ser ajustada em cada iteração, garantindo que o instante de término da missão seja sempre o mais adequado ao longo da execução. A restrição de que a soma das variáveis binárias seja igual a 1, dada por

$$\sum_{k=0}^{n_{\max}} b_t(k) = 1, \tag{3.7}$$

garante que apenas um único instante $k$ seja selecionado para representar o final do

horizonte de predição. Isso permite que a otimização se concentre na previsão de curto e longo prazo de forma adaptativa, levando em consideração as condições dinâmicas do ambiente e os requisitos da missão.

Além disso, a função de custo pode ser ajustada para incluir a penalização do tempo, de modo que o objetivo de otimização busque minimizar não apenas a execução da tarefa, mas também o tempo necessário para completá-la, resultando em um planejamento mais eficiente e adaptativo.

## 3.3 Variáveis Binárias e a Técnica Big-M no Planejador Ótimo

O planejador pode lidar com situações em que certas decisões precisam ser modeladas de forma discreta, como a ativação ou desativação de restrições, a escolha entre diferentes modos operacionais e a aplicação condicional de penalizações. Para isso, utiliza-se uma combinação de variáveis binárias e da técnica Big-M (DING *et al.*, 2013), permitindo a formulação do problema de otimização como um problema MIP (BORRELLI *et al.*, 2017; AMMOUR *et al.*, 2022). Essa abordagem torna o otimizador flexível para lidar com condições variáveis e mudanças dinâmicas nas restrições de planejamento.

As variáveis binárias $b \in \{0, 1\}$ são usadas para representar decisões discretas no problema de controle. Elas permitem ativar ou desativar restrições, selecionar modos operacionais e aplicar penalizações condicionais, conforme o estado do sistema. Ao serem incorporadas à formulação de otimização, essas variáveis controlam a ativação de condições específicas, sendo particularmente úteis quando certas restrições devem ser aplicadas apenas sob critérios definidos.

### 3.3.1 Big-M no Planejador Ótimo

O Big-M é uma técnica utilizada para modelar restrições condicionais em problemas de otimização (BELOTTI *et al.*, 2013). Ele assegura a viabilidade do problema ao permitir a relaxação de restrições quando critérios específicos não são atendidos. Isso é feito ao introduzir o termo $M(1 - b)$ nas inequações de restrição, onde $M > 0$ é uma constante suficientemente grande para garantir o relaxamento da restrição quando necessário. Considere, por exemplo, uma restrição de posicionamento que deve ser aplicada apenas quando uma condição específica for satisfeita

$$\mathbf{x} \leq \mathbf{x}_{\max} + \mathbf{1}M(1 - b). \tag{3.8}$$

Nesta formulação, $\mathbf{x}_{\max}$ representa o limite máximo permitido para a variável $\mathbf{x}$, enquanto $b$ é uma variável binária que indica se a restrição está ativa ($b = 1$) ou desativada ($b = 0$). Quando $b = 0$, o termo $M(1-b)$ relaxa a restrição, permitindo maior flexibilidade no problema de otimização. No entanto, a escolha de $M$ é fundamental: valores muito altos podem causar problemas de estabilidade numérica, enquanto valores muito baixos podem não garantir a devida relaxação da restrição (BEMPORAD; MORARI, 2007).

### 3.3.2 Formulação do Problema de Otimização com Variáveis Binárias

No contexto do controle preditivo, o uso de variáveis binárias permite modelar restrições dependentes de estados e entradas de forma flexível. Em sistemas de otimização com controle preditivo, as variáveis binárias são utilizadas para ativar ou desativar certas restrições durante o horizonte de predição, dependendo das condições do sistema. A função de custo típica do planejador ótimo pode ser ajustada para incluir penalizações proporcionais à ativação dessas variáveis binárias, com o objetivo de otimizar o desempenho do sistema e a eficiência computacional.

A formulação do problema de controle preditivo com variáveis binárias pode ser expressa como:

$$\min_{\mathbf{u},b} \sum_{i=1}^{n_{\max}} \left( \|\mathbf{x}(k+i) - \mathbf{x}_{\text{ref}}\|_Q^2 + \|\mathbf{u}(k+i)\|_R^2 + Pkb(k+i) \right), \tag{3.9}$$

onde $P$ é um peso que penaliza a ativação das variáveis binárias $b(k+i)$. O termo $b(k+i)$ indica a ativação ou desativação de uma restrição no instante $k+i$. Para garantir que o controlador selecione um único instante para a conclusão da missão ao longo do horizonte de predição, introduz-se a seguinte restrição sobre as variáveis binárias:

$$\sum_{i=1}^{n_{\max}} b(k+i) = 1. \tag{3.10}$$

Essa restrição garante que apenas uma variável binária seja ativada, indicando o ponto $k+i$ em que a missão será concluída, como um dos possíveis uso de variáveis binárias. O objetivo da formulação é minimizar o custo combinado, controlando o instante $k+i$ em que a restrição será ativada e a missão será concluída. Esse mecanismo possibilita que o controlador determine dinamicamente o ponto final da missão durante o processo de otimização, com o objetivo de minimizar o tempo de missão.

Além disso, as restrições associadas ao problema de otimização são formuladas como segue:

$$\mathbf{x}(k+i+1) = \mathbf{A}\mathbf{x}(k+i) + \mathbf{B}\mathbf{u}(k+i), \tag{3.11}$$

onde $\mathbf{x}(k+i)$ é o vetor de estado no instante $k+i$, $\mathbf{u}(k+i)$ é o vetor de entrada de controle, $\mathbf{A}$ e $\mathbf{B}$ são as matrizes do modelo dinâmico do sistema. As restrições de estado e controle são então formuladas como

$$\mathbf{x}_{\min} - \mathbf{1}M\,(1 - b(k+i)) \leq \mathbf{x}(k+i) \leq \mathbf{x}_{\max} + \mathbf{1}M\,(1 - b(k+i)), \tag{3.12}$$

$$\mathbf{u}_{\min} - \mathbf{1}M\,(1 - b(k+i)) \leq \mathbf{u}(k+i) \leq \mathbf{u}_{\max} + \mathbf{1}M\,(1 - b(k+i)), \tag{3.13}$$

Essa abordagem permite que o otimizador adapte a aplicação das restrições ao longo do tempo, ajustando o comportamento do sistema dinamicamente, levando em consideração as condições do cenário, como o desvio de obstáculos, ajuste de trajetórias e imposição de restrições adicionais em situações de emergência. A flexibilidade do controle preditivo com variáveis binárias proporciona uma solução eficiente para otimização, com garantias de segurança e viabilidade computacional, especialmente em missões complexas de sistemas multiagentes (BEMPORAD *et al.*, 2002).

# 4 Formulações para Resolução do Problema

Este capítulo apresenta a formulação matemática do problema de planejamento de trajetórias para drones em ambientes dinâmicos, visando minimizar o tempo de operação e o consumo de energia, enquanto se garantem segurança e eficiência por meio de restrições operacionais. Essas restrições abrangem limitações de terreno, obstáculos estáticos, prevenção de colisões, alcance correto dos alvos e controle do consumo de bateria, baseando-se em um modelo dinâmico linear discreto apresentado no Capítulo 2. O modelo utilizado no planejamento de trajetórias é o mesmo que é implementado na planta. A função objetivo integra critérios de tempo, esforço de controle e consumo energético, assegurando que os drones cumpram suas missões de forma otimizada.

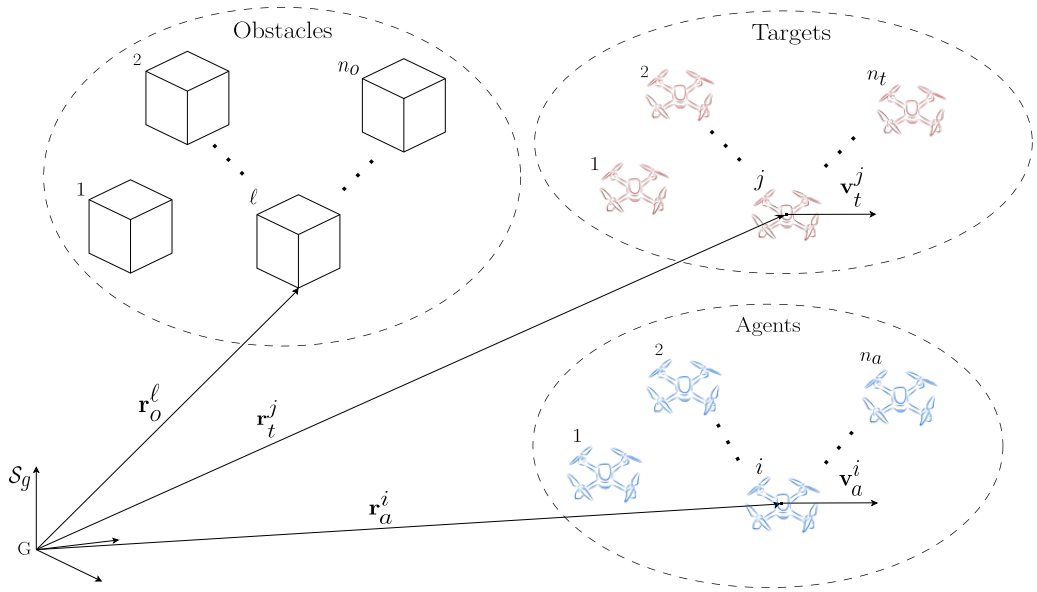



FIGURA 4.1 – Representação esquemática do cenário adotado.

A Figura 4.1 ilustra de forma esquemática o cenário considerado, bem como as principais notações e elementos que compõem o ambiente de operação, servindo de base para as formulações apresentadas a seguir.

## 4.1 Restrições Operacionais

Os agentes $i \in \{1, \ldots, n_a\}$ estão sujeitos a um conjunto de restrições operacionais que asseguram a segurança, estabilidade e viabilidade da missão. Essas restrições garantem que os agentes operem dentro dos limites físicos e operacionais, respeitando as capacidades da plataforma e os requisitos do ambiente.

Entre essas restrições, destaca-se a limitação de posição (restrição de terreno), que assegura que os agentes permaneçam dentro da área operacional permitida. A restrição é aplicada sobre a posição $\mathbf{r}_a^i(k)$, impondo limites definidos por $\mathbf{r}_{a,\min}$ e $\mathbf{r}_{a,\max}$ para cada dimensão espacial, formulada como

$$\mathbf{r}_{a,\min} \leq \mathbf{r}_a^i(k) \leq \mathbf{r}_{a,\max}, \quad \forall i,\ k = 0, \ldots, n^*. \tag{4.1}$$

O índice $n^*$ representa o instante ótimo no horizonte de predição em que o agente completa sua tarefa. Esse valor não é fixado a priori, mas determinado pela otimização, a partir da ativação de uma variável binária $b_t(k) \in \{0, 1\}$, usada para identificar o tempo de término da missão. Para garantir que um instante $k$ seja selecionado como o fim da missão, impõe-se

$$\sum_{k=0}^{n_{\max}} b_t(k) = 1. \tag{4.2}$$

A partir de (4.2), o instante $n^*$ é implicitamente definido como aquele para o qual $b_t(k) = 1$, como expresso por

$$n^* = \sum_{k=0}^{n_{\max}} k b_t(k). \tag{4.3}$$

Uma vez determinado $n^*$, os instantes posteriores a esse valor, ou seja, os valores de $k$ para $k > n^*$, são desconsiderados na otimização, pois o planejamento é concluído dentro do horizonte $n^*$. Ou seja, o sistema de otimização encontra o horizonte ótimo de execução da missão, e qualquer instante de tempo após $n^*$ é irrelevante para o planejamento, uma vez que o agente já completou sua tarefa. O uso da variável binária $b_t(k)$ permite ao sistema descartar, de forma eficiente, os instantes $k > n^*$, promovendo um planejamento de missão focado apenas no período relevante para a execução. Para permitir o relaxamento condicional das restrições de posição após esse ponto, aplica-se a técnica Big-M, junto a (4.1). Assim, a restrição de posição é reformulada como:

$$\mathbf{r}_{a,\min} - \mathbf{1}Mb_t(k) \leq \mathbf{r}_a^i(k) \leq \mathbf{r}_{a,\max} + \mathbf{1}Mb_t(k), \quad \forall i,\ k = 0, \ldots, n^*. \tag{4.4}$$

Quando $b_t(k) = 0$, a restrição é ativa; quando $b_t(k) = 1$, a restrição é relaxada, permitindo maior flexibilidade ao planejador para manter a viabilidade da solução.

Além das restrições de posição (4.4), é necessário impor limites às grandezas dinâmi-

cas dos agentes, como velocidade e aceleração, para garantir movimentos suaves, evitar saturações de atuadores e preservar a integridade da plataforma aérea. A velocidade $\mathbf{v}_a^i(k)$, componente do vetor de estado do agente $i$ no instante de amostragem $k$, é restringida por limites inferiores e superiores definidos por vetores $\mathbf{v}_{\min} \in \mathbb{R}^3$ e $\mathbf{v}_{\max} \in \mathbb{R}^3$, respectivamente. A restrição aplicada é descrita por

$$\mathbf{v}_{\min} - \mathbf{1}Mb_t(k) \leq \mathbf{v}_a^i(k) \leq \mathbf{v}_{\max} + \mathbf{1}Mb_t(k), \quad \forall i,\ k = 0, \ldots, n^*, \tag{4.5}$$

já a aceleração $\mathbf{a}_a^i(k)$ é derivada da dinâmica do modelo com os limites de aceleração definidos por $\mathbf{a}_{\min}, \mathbf{a}_{\max} \in \mathbb{R}^3$, e a restrição é expressa como

$$\mathbf{a}_{\min} - \mathbf{1}Mb_t(k) \leq \mathbf{a}_a^i(k) \leq \mathbf{a}_{\max} + \mathbf{1}Mb_t(k), \quad \forall i,\ k = 0, \ldots, n^*. \tag{4.6}$$

As restrições (4.4), (4.5) e (4.6) são fundamentais para assegurar a estabilidade do movimento e o cumprimento das capacidades físicas dos agentes, evitando comandos abruptos que comprometam a operação segura durante o planejamento e execução da trajetória. As entradas de controle $\mathbf{u}_i(k)$ também devem respeitar os limites estabelecidos para garantir que os drones operem de forma segura:

$$\mathbf{u}_{\min} - \mathbf{1}Mb_t(k) \leq \mathbf{u}_i(k) \leq \mathbf{u}_{\max} + \mathbf{1}Mb_t(k), \quad \forall i,\ k = 0, \ldots, n^*. \tag{4.7}$$

Para preservar a autonomia dos agentes, o consumo energético ao longo da trajetória é monitorado e limitado à capacidade máxima da bateria embarcada. Cada agente $i$ é equipado com uma bateria de capacidade finita $c_i$, e para garantir a viabilidade da missão, o consumo total de energia $e_i$ não deve exceder esse valor. O consumo energético é estimado considerando dois componentes principais: a aceleração e a duração da missão. A energia total consumida é computada por

$$e_i = \sum_{k=0}^{n^*} \left( \|\mathbf{a}_a^i(k)\|_1 + \gamma k \right), \quad \forall i, \tag{4.8}$$

onde $\mathbf{a}_a^i(k) \in \mathbb{R}^3$ é a aceleração do $i$-ésimo agente no instante $k$ e $\gamma k$ é uma penalização crescente com o tempo, que penaliza trajetórias mais longas, com $\gamma = 0,1$ . A energia acumulada em (4.8) deve obedecer a restrição operacional

$$e_i \leq c_i, \quad \forall i, \tag{4.9}$$

assegurando que o planejamento de trajetória permaneça dentro dos limites energéticos disponíveis para cada agente ao longo do horizonte de predição $n^*$.

Essas restrições integradas formam a base para o controle seguro dos agentes, garan-

tindo que eles permaneçam dentro dos limites operacionais, respeitem suas capacidades dinâmicas e otimizem o uso de recursos energéticos para alcançar seus alvos.

## 4.2 Formulação dos Obstáculos

Nesta subseção, apresenta-se a modelagem matemática utilizada para representar os obstáculos estáticos presentes no ambiente e sua incorporação no problema de otimização. A abordagem visa garantir que os agentes permaneçam fora das regiões proibidas durante toda a execução da missão, por meio da imposição de restrições espaciais explícitas ao longo do horizonte de predição.

Cada obstáculo fixo $\ell \in \{1, \ldots, n_o\}$ é representado como um poliedro convexo no espaço tridimensional, definido por um conjunto de planos (facetas) que delimitam seu contorno. Formalmente, o poliedro associado ao obstáculo $\ell$ é definido como

$$\mathcal{O}_\ell = \left\{ \mathbf{r}_o^\ell \in \mathbb{R}^3 : \mathbf{P}_o^\ell \mathbf{r}_o^\ell \leq \mathbf{d}_o^\ell \right\}, \tag{4.10}$$

onde a posição de referência do obstáculo $\ell$ é denotada por $\mathbf{r}_o^\ell \in \mathbb{R}^3$, $\mathbf{P}_o^\ell \in \mathbb{R}^{n_o^s \times 3}$ é a matriz que contém os vetores normais às $n_o^s$ facetas do obstáculo $\ell$, e $\mathbf{d}_o^\ell \in \mathbb{R}^{n_o^s}$ contém os deslocamentos associados a cada plano. A Figura 4.2 ilustra dois exemplos de obstáculos modelados dessa forma.

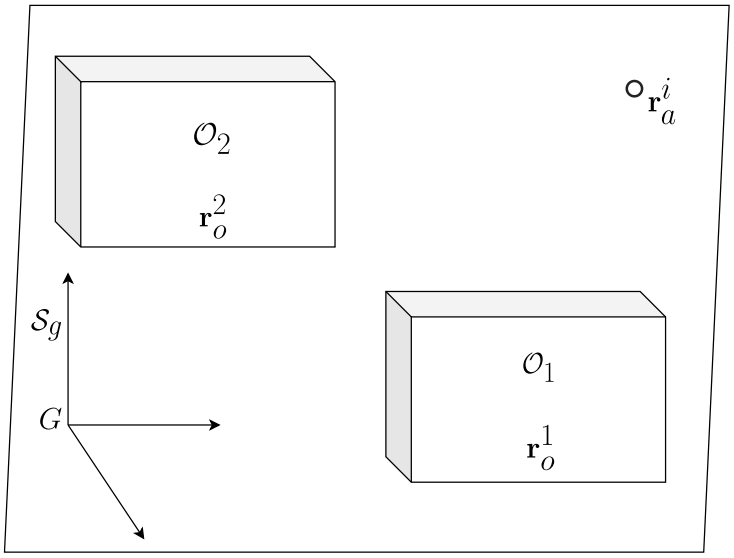



FIGURA 4.2 – Representação do ambiente com obstáculos e um agente. Os obstáculos $\mathcal{O}_1$ e $\mathcal{O}_2$, posicionados em $\mathbf{r}_o^1$ e $\mathbf{r}_o^2$, são modelados como poliedros convexos definidos por facetas planas. O drone $i$ está representado por sua posição $\mathbf{r}_a^i$ no referencial global $\mathcal{S}_g$.

### 4.2.1 Modelagem das Restrições de Evitamento

Para garantir que os agentes não penetrem nas regiões ocupadas pelos obstáculos, são impostas restrições de não penetração sobre a posição prevista de cada agente. O objetivo é assegurar que a posição futura do agente $i$, no instante $k+1$, esteja fora do poliedro convexo associado ao obstáculo $\ell$ (4.10), isto é

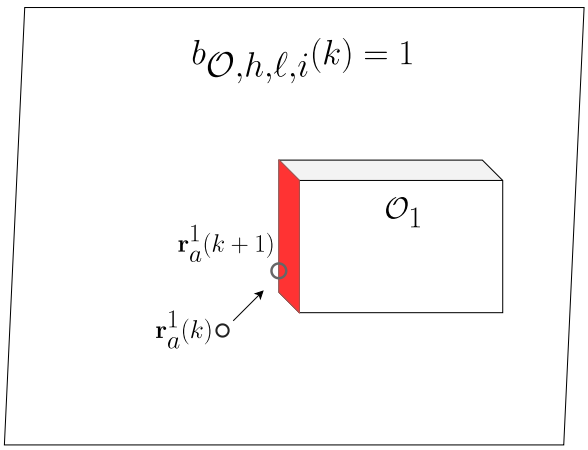
$$\mathbf{r}_a^i(k+1) \notin \mathcal{O}_\ell, \quad \forall i \in \{1,\ldots,n_a\}, \ell \in \{1,\ldots,n_o\}, k = 0,\ldots,n^*. \tag{4.11}$$

Para isso, cada obstáculo $\ell$ é representado por um conjunto de planos que definem seu contorno convexo. A modelagem dessas restrições se baseia na formulação de uma desigualdade para cada faceta $h \in \{1,\ldots,n_o^s\}$ do obstáculo, ativada ou desativada por meio de variáveis binárias $b_{\mathcal{O},h,\ell,i}(k) \in \{0,1\}$. A técnica do Big-M é empregada para viabilizar essa ativação seletiva ao longo do horizonte de predição. A inequação de restrição associada a cada plano é expressa por

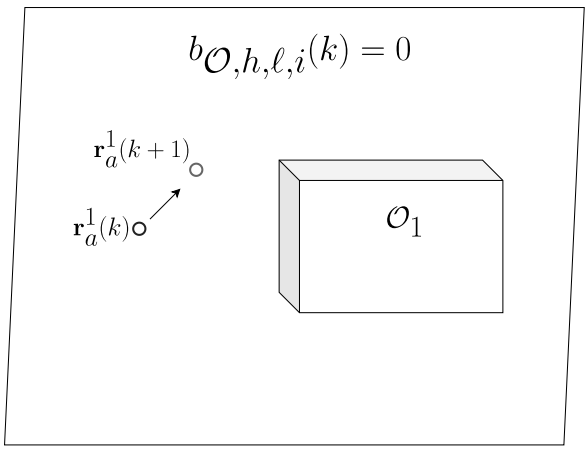
$$-{\mathbf{p}_{o,h}^\ell}^{\mathrm{T}} \mathbf{r}_a^i(k+1) \leq -d_{o,h}^\ell + \mathbf{1}M\left(1 - b_{\mathcal{O},h,\ell,i}(k)\right) + \varepsilon, \tag{4.12}$$

em que, $\mathbf{p}_{o,h}^\ell$ representa a $h$-ésima linha da matriz $\mathbf{P}_o^\ell$, correspondente ao vetor normal da faceta $h$ do obstáculo $\ell$, $d_{o,h}^\ell$ é o limite escalar associado a essa faceta, $\mathbf{r}_a^i(k+1) \in \mathbb{R}^3$ denota a posição prevista do agente $i$ no instante de tempo $k+1$ e $\varepsilon > 0$ é um valor pequeno adicionado para garantir uma margem de segurança.

Quando $b_{\mathcal{O},h,\ell,i}(k) = 1$, a restrição é ativa e força a posição do agente a satisfazer a inequação. Quando $b_{\mathcal{O},h,\ell,i}(k) = 0$, a restrição é desativada e relaxada por meio do termo Big-M.




$b_{\mathcal{O},h,\ell,i}(k) = 1$: Restrição ativa, o agente $D_1$ é forçado a manter-se fora do poliedro.




$b_{\mathcal{O},h,\ell,i}(k) = 0$: Restrição desativada, a inequação é relaxada.

FIGURA 4.3 – Exemplo de ativação e desativação das variáveis binárias associadas às facetas do obstáculo $\mathcal{O}_1$.

Para garantir que o agente $i$ esteja efetivamente fora do poliedro do obstáculo $\ell$ no instante $k+1$, impõe-se a seguinte condição de viabilidade:

$$\sum_{h=1}^{n_o^s} b_{\mathcal{O},h,\ell,i}(k) \geq 1, \quad \forall \ell, i, k = 0, \ldots, n^*, \tag{4.13}$$

garantindo que pelo menos uma das facetas esteja bloqueando a entrada do agente na região ocupada pelo obstáculo.

## 4.3 Formulação das Restrições de Anticolisão entre Agentes

Nesta subseção, apresenta-se a formulação das restrições de anticolisão entre agentes, com o objetivo de assegurar que, ao longo do horizonte de predição, não ocorram interseções entre os volumes ocupados por diferentes drones.

Cada agente $i$ é modelado como um politopo convexo tridimensional, definido por um conjunto de planos que representam as faces da sua geometria. O politopo do agente, denotado por $\mathcal{P}$, é definido como

$$\mathcal{P} = \left\{ \mathbf{r}_a^i \in \mathbb{R}^3 : \mathbf{G}_a^i \, \mathbf{r}_a^i \leq \mathbf{d}_a^i \right\}, \tag{4.14}$$

onde $\mathbf{G}_a^i \in \mathbb{R}^{n_f^a \times 3}$ é a matriz cujas linhas correspondem aos vetores normais das $n_f^a$ faces do politopo, e $\mathbf{d}_a^i \in \mathbb{R}^{n_f^a}$ contém os deslocamentos escalares associados a cada uma dessas faces. Essa formulação baseada em restrições plano-normais permite uma representação precisa da geometria do agente e viabiliza o uso de estratégias de otimização mista para garantir a separação entre volumes em movimento no espaço tridimensional.

A restrição de anticolisão entre dois agentes distintos $i$ e $i_o$, com $i \neq i_o$, é garantida por meio da formulação de separação entre os politopos $\mathcal{P}_i(k)$ e $\mathcal{P}_{i_o}(k)$. Neste modelo, cada agente é considerado um obstáculo dinâmico para os demais, e a separação entre seus volumes é assegurada por meio de planos associados às faces do politopo do agente $i_o$. A condição geral de não interseção entre os volumes ocupados pelos agentes pode ser expressa formalmente como

$$\mathcal{P}_i(k) \cap \mathcal{P}_{i_o}(k) = \emptyset, \quad \forall i, i_o, i \neq i_o, k = 0, \ldots, n^*. \tag{4.15}$$

Essa restrição garante que a interseção entre o volume ocupado pelo politopo do agente $i$ e o volume do politopo do agente $i_o$ seja vazia para cada instante de tempo $k$, ou seja, os dois agentes não podem ocupar a mesma região do espaço simultaneamente.

Para garantir essa condição de forma computacionalmente viável, adota-se uma formulação baseada na técnica de disjunção lógica. Para cada par de agentes e para cada instante $k$, associa-se uma variável binária $b_{f,i,i_o}(k) \in \{0,1\}$ a cada face $f \in \{1,\ldots,n_f^a\}$ do politopo $\mathcal{P}_{i_o}$, relativa à separação do agente $i$. Essa variável permite o uso da técnica Big-M, possibilitando o relaxamento da restrição de separação em uma face por vez. A restrição associada à separação é dada por

$$\mathbf{r}_a^i(k) \leq \mathbf{r}_a^{i_o}(k) - \mathbf{1}2d_{a,f}^{i_o} - (1 - b_{f,i,i_o}(k))M\mathbf{1} \tag{4.16}$$

onde $d_{a,f}^{i_o}$ representa o deslocamento escalar correspondente à face $f$ do politopo do agente $i_o$ definido previamente, e $M$ é um valor suficientemente grande para garantir o relaxamento das restrições de separação quando $b_{f,i,i_o}(k) = 1$. Essa formulação permite que a separação entre os agentes seja relaxada de acordo com a ativação da variável binária, permitindo a flexibilidade necessária para a movimentação dinâmica dos agentes no espaço de operações.

Para garantir que a separação entre os agentes seja de fato mantida, impõe-se que pelo menos uma das desigualdades definidas na Equação (4.16) permaneça ativa:

$$\sum_{f=1}^{n_f^a} b_{f,i,i_o}(k) \geq 1, \quad \forall i, i_o, i \neq i_o, k = 0,\ldots,n^*, \tag{4.17}$$

assegurando que o agente $i$ permaneça fora do volume do agente $i_o$ em todos os instantes de tempo do horizonte de planejamento.

A Equação (4.16) garante que o agente $i$, posicionado em $\mathbf{r}_a^i(k)$, permaneça separado do agente $i_o$, posicionado em $\mathbf{r}_a^{i_o}(k)$, por ao menos uma das faces de $\mathcal{P}_{i_o}$. A Equação (4.17) assegura que pelo menos uma dessas restrições esteja ativa, impedindo a sobreposição dos volumes, de acordo com a condição geral de não interseção definida na Equação (4.15).

A Figura 4.4 ilustra o conceito de separação entre os volumes representados pelos politopos associados aos agentes. Esta formulação torna o modelo mais coerente com representações físicas tridimensionais e é eficaz em cenários de alta densidade, com múltiplos drones operando de forma coordenada.

Essa restrição é aplicada a todos os pares de agentes distintos e em todos os instantes do horizonte de planejamento. Ao utilizar representações geométricas mais flexíveis e compatíveis com a geometria real dos drones, o modelo mantém a viabilidade computacional dentro da estrutura de problemas de otimização mista, assegurando a segurança operacional mesmo em missões de alta complexidade espacial.

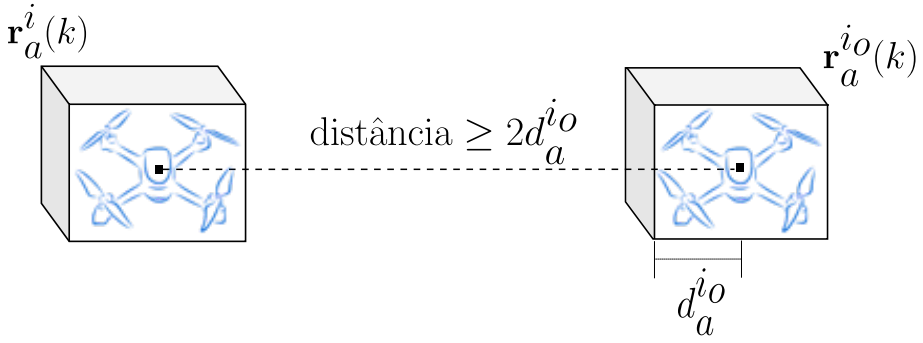



FIGURA 4.4 – Ilustração da restrição de anticolisão entre os drones $i$ e $i_o$, utilizando representação por politopos. As regiões cinza representam o volume ocupado por cada agente, e os planos de separação garantem que não haja interseção.

## 4.4 Modelagem e Restrições de Alvos

Nesta subseção, apresentamos a modelagem matemática dos alvos e as restrições associadas à interação dos agentes com esses destinos. Os alvos podem ser estáticos ou dinâmicos, com trajetórias definidas por uma combinação de posições iniciais, direções de movimento e magnitudes de velocidade. O movimento dos agentes em relação aos alvos é regulado por restrições de posicionamento, adjacência e velocidade, garantindo um encontro eficiente e seguro.

Cada alvo $j \in \{1, \ldots, n_t\}$ é caracterizado por uma posição inicial $\mathbf{r}_t^j(0) \in \mathbb{R}^3$, um vetor unitário que define a direção normalizada do movimento $\mathbf{d}_{vt}^j \in \mathbb{R}^3$ e magnitude de velocidade $v_t^j \in \mathbb{R}^3$. A evolução da posição do alvo ao longo do horizonte de predição é descrita por

$$\mathbf{r}_t^j(k+1) = \mathbf{r}_t^j(k) + v_t^j \mathbf{d}_{vt}^j t_s, \tag{4.18}$$

onde $t_s$ é o tempo de amostragem.

Além da modelagem matemática da trajetória dos alvos, considera-se, neste trabalho, dois cenários distintos de inicialização para os $n_t$ alvos no espaço de operação. Em ambos os cenários, os alvos são posicionados aleatoriamente dentro da *área protegida*, delimitada conforme ilustrado na Figura 4.5, assegurando que estejam fora do *centro de atuação*, uma região central crítica que os agentes devem proteger.

No primeiro cenário, atribuem-se aos alvos posições iniciais e direções de movimento aleatórias. A direção do movimento é escolhida aleatoriamente no início da simulação e permanece fixa durante a execução da missão. Assim, as trajetórias dos alvos se desenvolvem livremente dentro da área protegida, respeitando as restrições de limites de posição impostas para o otimizador. A escolha aleatória da direção garante uma variação nos padrões de movimento dos alvos, simulando diferentes cenários dinâmicos para os agentes.

No segundo cenário, além de serem posicionados aleatoriamente fora do centro de atuação, os alvos são programados para se mover diretamente em direção ao centro da operação, definido pela coordenada $\mathbf{r}_c = (0, 0, 1)$. Esse ponto representa a zona prioritária de defesa, sendo o objetivo dos alvos alcançá-lo, enquanto os agentes devem interceptá-los e impedir sua entrada. Esse método segue o cenário apresentado no projeto que vem sendo estudado no Instituto Tecnológico de Aeronáutica (ITA), denominado "Cooperative threat engagement with heterogeneous drone swarms - (CTEDS)", que apresenta um cenário de defesa aérea, onde os alvos partem em direção a uma determinada área protegida, com a intenção de atacá-la e a missão dos agentes é impedir o ataque.

Esta diferenciação entre os cenários permite avaliar o desempenho do planejamento de trajetória em situações de deslocamentos aleatórios e também em contextos de ataques coordenados.

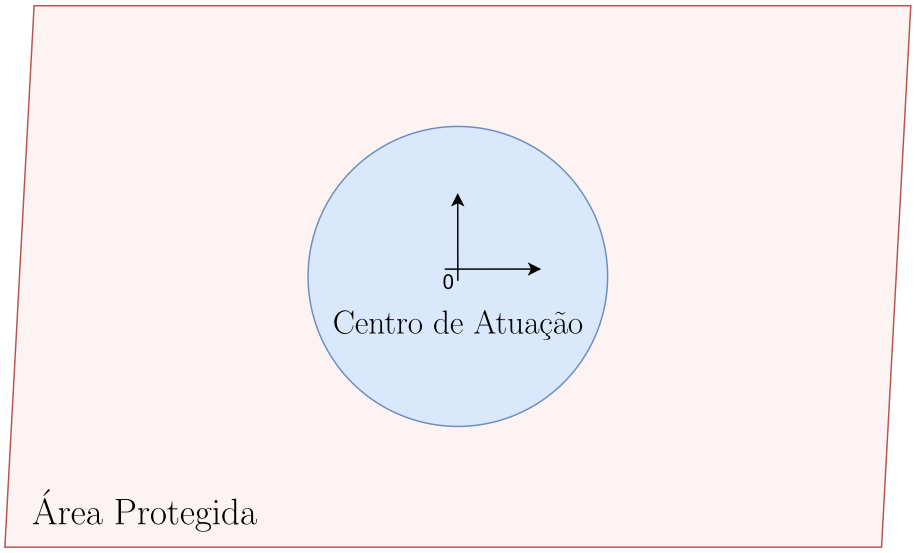



FIGURA 4.5 – Representação da área protegida com a zona crítica denominada *centro de atuação*. Os alvos são inicializados aleatoriamente fora do centro, mas dentro da área protegida.

### 4.4.1 Politopo de Adjacência e Restrições de Posição

Para formalizar a proximidade entre os agentes e os alvos, utilizamos o conceito de politopo de adjacência $\mathcal{T}(k)$. Este politopo delimita a região espacial em que um agente é considerado próximo ou dentro da zona de captura de um alvo, como ilustrado na Figura 4.6. A formulação matemática do politopo é dada por:

$$\mathcal{T}_j(k) = \left\{ \mathbf{r}_t^j(k) \in \mathbb{R}^3 : \mathbf{P}_t^j \mathbf{r}_t^j \leq \mathbf{d}_t^j \right\}, \tag{4.19}$$

onde $\mathbf{P}_t^j \in \mathbb{R}^{n_t^s \times 3}$ é uma matriz constante contendo as normais dos planos delimitadores das $n_t^s$ facetas do alvo, e $\mathbf{d}_t^j \in \mathbb{R}^{n_t^s}$ especifica as distâncias máximas permitidas ao longo

dessas normais.

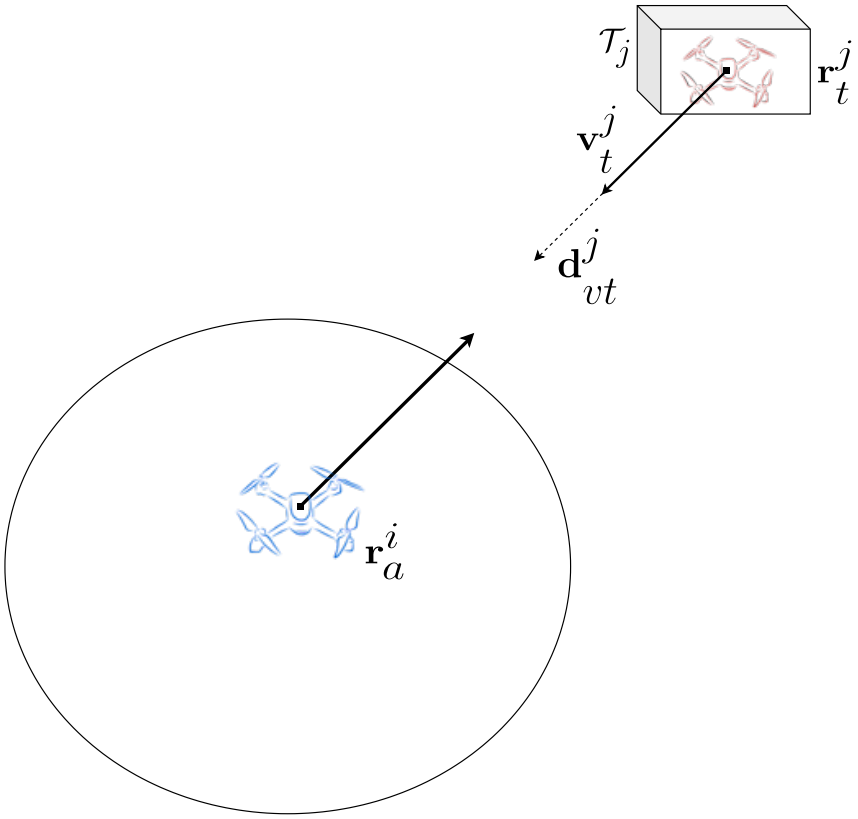



FIGURA 4.6 – Ilustração da interação entre o agente $i$ e o alvo dinâmico $j$ na posição $\mathbf{r}_t^j$. O alvo se move seguindo a direção $\mathbf{d}_{vt}^j$ com velocidade $\mathbf{v}_t^j$. O politopo de adjacência $\mathcal{T}_j$ delimita a zona em que o agente é considerado próximo ao alvo.

A posição prevista do agente $i$, no instante final $n^*$, denotada por $\mathbf{r}_a^i(n^*)$, deve estar dentro do politopo (4.19) para garantir que o agente esteja suficientemente próximo do alvo. Isso é expresso pela inequação

$$\mathbf{r}_a^i(n^*) \in \mathcal{T}_j(n^*). \tag{4.20}$$

### 4.4.2 Restrições de Posição e Zona de Captura

As zonas de captura dos alvos são delimitadas por vetores de posição mínimos $\mathbf{r}_{t,\min}^j(k) \in \mathbb{R}^3$ e máximos $\mathbf{r}_{t,\max}^j(k) \in \mathbb{R}^3$, definindo os limites espaciais dentro dos quais um agente $i$ é considerado como tendo alcançado o alvo $j$. Esses limites são calculados a partir da posição central do alvo $\mathbf{r}_t^j(k) \in \mathbb{R}^3$, calculado em (4.18), e do parâmetro $s_t^j \in \mathbb{R}$, que representa o comprimento da aresta do poliedro de captura

$$\mathbf{r}_{t,\min}^j(k) = \mathbf{r}_t^j(k) - \mathbf{1}\frac{s_t^j}{2}, \quad \mathbf{r}_{t,\max}^j(k) = \mathbf{r}_t^j(k) + \mathbf{1}\frac{s_t^j}{2}. \tag{4.21}$$

Para garantir que o agente $i$ esteja posicionado corretamente ao final da trajetória, dentro da zona de captura do alvo $j$, impõe-se que sua posição final no instante $n^*$ esteja contida nos limites espaciais da caixa de captura definida por $\mathbf{r}^j_{t,\min}(k)$ e $\mathbf{r}^j_{t,\max}(k)$. A restrição básica é dada por

$$\mathbf{r}^j_{t,\min}(k) \leq \mathbf{r}^i_a(n^*) \leq \mathbf{r}^j_{t,\max}(k), \tag{4.22}$$

essa inequação assegura que, no instante final do planejamento, o agente esteja fisicamente dentro do volume designado como região de captura do alvo.

Para permitir maior flexibilidade na formulação e possibilitar que essa condição seja ativada apenas quando necessária e relaxada quando o agente atingir o alvo, a restrição (4.22) pode ser reescrita utilizando uma variável binária $b_{\mathcal{T}_j,i}(k) \in \{0,1\}$ e o Big-M. A formulação condicional é

$$\mathbf{r}^j_{t,\min}(k) - (1 - b_{\mathcal{T}_j,i}(k))M\mathbf{1} \leq \mathbf{r}^i_a(n^*) \leq \mathbf{r}^j_{t,\max}(k) + (1 - b_{\mathcal{T}_j,i}(k))M\mathbf{1}, \tag{4.23}$$

onde $M > 0$ é uma constante suficientemente grande que relaxa a restrição quando $b_{\mathcal{T}_j,i}(k) = 0$. Quando $b_{\mathcal{T}_j,i}(k) = 1$, a restrição é aplicada integralmente, exigindo o posicionamento preciso do agente dentro da zona de captura. Para garantir que o agente atinja a zona de captura pelo menos uma vez ao longo do horizonte de predição, a partir de (4.23), impomos a condição

$$\sum_{k=1}^{n^*} b_{\mathcal{T}_j,i}(k) \geq 1, \quad \forall \mathcal{T}_j \in \{1, \ldots, n_t\}, \tag{4.24}$$

assegurando que o agente seja direcionado ao alvo em pelo menos um dos instantes previstos. Essa restrição garante que, ao final do horizonte de predição, a posição do agente esteja dentro dos limites da zona de captura, desde que pelo menos uma variável binária $b_{\mathcal{T}_j,i}$ tenha sido ativada ao longo do horizonte. A soma das variáveis binárias da equação (4.24) assegura que a restrição seja efetivamente aplicada se o agente estiver designado ao alvo.

Para garantir uma interceptação alinhada e suave, especialmente em cenários que exigem perseguição ou acompanhamento contínuo após o encontro, é imposta uma restrição vetorial de velocidade terminal. Essa restrição assegura que o vetor de velocidade do agente $\mathbf{v}^i_a$ esteja suficientemente próximo ao vetor de velocidade do alvo $\mathbf{v}^j_t$ no instante final da trajetória. Inicialmente, essa condição de alinhamento é expressa pela norma da diferença entre os vetores

$$\|\mathbf{v}^i_a(n^*) - \mathbf{v}^j_t\|_\infty \leq \nu, \tag{4.25}$$

onde $\nu \in \mathbb{R}^+$ é a tolerância escalar permitida, e $\mathbf{v}^i_a(n^*) \in \mathbb{R}^3$, $\mathbf{v}^j_t \in \mathbb{R}^3$ são, respectivamente, os vetores de velocidade do agente $i$ e do alvo $j$.

Para viabilizar a implementação da restrição no problema de otimização, a condição da Equação (4.25) é reformulada em termos de desigualdades componentes, considerando a tolerância por eixo

$$\mathbf{v}_t^j - (1 - b_{\mathcal{T}_j,i}(k))M\mathbf{1} - \nu \leq \mathbf{v}_a^i(n^*) \leq \mathbf{v}_t^j + (1 - b_{\mathcal{T}_j,i}(k))M\mathbf{1} + \nu. \tag{4.26}$$

### 4.4.3 Tomada de Decisão e Alocação de Alvos

Em cenários com múltiplos agentes e alvos, a designação eficiente de tarefas é essencial para garantir o sucesso da missão. Neste trabalho, a alocação de alvos aos agentes é incorporada diretamente no planejamento de trajetória resolvido pelo otimizador, dispensando regras externas ou decisões estáticas. A principal vantagem dessa integração é permitir que as decisões de alocação sejam ajustadas dinamicamente com base no estado atual dos agentes, levando em consideração aspectos como o tempo necessário para cumprir a tarefa e o consumo energético estimado.

A abordagem proposta utiliza diretamente os indicadores de desempenho relevantes, que já estão presentes na função objetivo do problema de controle. Dois critérios são otimizados de forma conjunta: o tempo de missão, representado pela quantidade de passos até o agente alcançar sua zona de captura, e o consumo energético total, conforme definido na Equação (4.8). Essa formulação promove decisões que equilibram eficiência temporal e autonomia, priorizando alocações em que os agentes consigam cumprir sua missão rapidamente e com menor esforço energético.

A associação entre agentes e alvos é representada por variáveis binárias $\delta_{i,j} \in \{0, 1\}$, em que $\delta_{i,j} = 1$ indica que o agente $i$ foi alocado ao alvo $j$. Cada alvo possui uma demanda $a_j \in \mathbb{N}$, que determina o número mínimo de agentes necessários para sua interceptação ou monitoramento. A restrição que assegura essa cobertura é expressa como

$$\sum_{i=1}^{n_a} \delta_{i,j} = a_j, \quad \forall j \in \{1, 2, \ldots, n_t\}. \tag{4.27}$$

Ao acoplar a tomada de decisão ao ciclo de controle do otimizador, o otimizador passa a reavaliar continuamente as alocações de acordo com as condições operacionais dos agentes, como mudanças na energia disponível, surgimento de novos alvos ou alteração na dinâmica do ambiente. Essa abordagem unificada evita alocações inviáveis, melhora a eficiência da missão e favorece o uso racional dos recursos da frota.

Com base nas variáveis de alocação $\delta_{i,j}$ definidas na Equação (4.27), a restrição de captura do alvo é condicionada exclusivamente aos agentes efetivamente designados. Para isso, as restrições de interceptação são adaptadas de forma condicional utilizando a técnica Big-M. A restrição de posição do agente em relação ao alvo, no instante ótimo $n^*$, é ativada

se o agente $i$ estiver alocado ao alvo $j$, conforme segue:

$$\mathbf{r}^j_{t,\min}(k)-(1-b_{\mathcal{T}_j,i}(k))M\mathbf{1}-(1-\delta_{i,j})M\mathbf{1} \leq \mathbf{r}^i_a(n^*) \leq \mathbf{r}^j_{t,\max}(k)+(1-b_{\mathcal{T}_j,i}(k))M\mathbf{1}+(1-\delta_{i,j})M\mathbf{1}. \tag{4.28}$$

De forma análoga, a restrição de alinhamento vetorial entre a velocidade do agente e a do alvo também é ativada apenas para os pares efetivamente alocados:

$$\mathbf{v}^j_t-(1-b_{\mathcal{T}_j,i}(k))M\mathbf{1}-(1-\delta_{i,j})M\mathbf{1}-\nu \leq \mathbf{v}^i_a(n^*) \leq \mathbf{v}^j_t+(1-b_{\mathcal{T}_j,i}(k))M\mathbf{1}+(1-\delta_{i,j})M\mathbf{1}+\nu. \tag{4.29}$$

Por fim, a ativação da captura ao longo do horizonte é forçada apenas para agentes que receberam uma tarefa, conforme

$$\sum_{k=1}^{n_{\max}} b_{\mathcal{T}_j,i}(k) \geq \delta_{i,j}. \tag{4.30}$$

Essa formulação garante que os agentes executem a captura apenas quando forem formalmente designados a um alvo, integrando de forma coerente a tomada de decisão com as etapas de execução no mesmo problema de otimização.

## 4.5 Problema de Otimização Integrado

O principal objetivo do planejamento de trajetória neste trabalho é determinar, para todos os agentes $i \in \{1, \ldots, n_a\}$, a melhor sequência de entradas de controle $\mathbf{u}_i(k)$ ao longo do horizonte de predição, guiando-o de forma eficiente até a zona de captura de um alvo. A formulação do problema incorpora, de maneira unificada, a alocação de agentes aos alvos, o planejamento de trajetória, a evitação de obstáculos e a consideração de restrições físicas e energéticas.

A função objetivo busca minimizar uma combinação ponderada de critérios de desempenho relevantes para a missão, incluindo: (i) o tempo total até a captura do alvo; e (ii) o consumo total de bateria durante a missão. A seguir, apresenta-se a formulação completa do problema de otimização:

$$\min_{\{\mathbf{x}_i(k),\mathbf{a}_a^i(k),b_t(k)\}_{i=1}^{n_a}} \quad \sum_{i=1}^{n_a}\sum_{k=0}^{n_{max}} (\lambda_1 k b_t(k) + \lambda_2 e_i) \tag{4.31a}$$

sujeito a:

$$\sum_{k=0}^{n_{\max}} b_t(k) = 1, \tag{4.31b}$$

$$n^* = \sum_{k=0}^{n_{\max}} k b_t(k), \tag{4.31c}$$

$$\mathbf{x}_i(k+1) = \mathbf{A}_d \mathbf{x}_i(k) + \mathbf{B}_d \mathbf{u}_i(k), \quad \forall i, k = 0, \ldots, n^*, \tag{4.31d}$$

$$\mathbf{x}_{\min} - \mathbf{1}Mb_t(k) \leq \mathbf{x}_i(k) \leq \mathbf{x}_{\max} + \mathbf{1}Mb_t(k), \quad \forall i, k = 0, \ldots, n^*, \tag{4.31e}$$

$$\mathbf{u}_{\min} - \mathbf{1}Mb_t(k) \leq \mathbf{u}_i(k) \leq \mathbf{u}_{\max} + \mathbf{1}Mb_t(k), \quad \forall i, k = 0, \ldots, n^*, \tag{4.31f}$$

$$\mathbf{a}_{\min} - \mathbf{1}Mb_t(k) \leq \mathbf{a}_a^i(k) \leq \mathbf{a}_{\max} + \mathbf{1}Mb_t(k), \quad \forall i,\ k = 0, \ldots, n^*, \tag{4.31g}$$

$$\mathbf{r}_a^i(k+1) \notin \mathcal{O}_\ell, \quad \forall i, \ell, k = 0, \ldots, n^*, \tag{4.31h}$$

$$\mathcal{P}_i(k) \cap \mathcal{P}_{i_o}(k) = \emptyset, \quad \forall i, i_o, i \neq i_o, k = 0, \ldots, n^*, \tag{4.31i}$$

$$\mathbf{r}_a^i(n^*) \in \mathcal{T}_j(n^*), \quad \forall i, j, \tag{4.31j}$$

$$\|\mathbf{v}_a^i(n^*) - \mathbf{v}_t^j\|_\infty \leq \nu, \quad \forall i, j, \tag{4.31k}$$

$$e_i \leq c_i, \quad \forall i, \tag{4.31l}$$

$$\sum_{i=1}^{n_a} \delta_{i,j} = a_j, \quad \forall j. \tag{4.31m}$$

Os parâmetros $\lambda_1$ e $\lambda_2$ são coeficientes de ponderação que permitem ajustar a influência relativa de cada termo na função objetivo, em que os valores utilizados nos dois parâmetros foi 1. O valor de $\lambda_1$ regula a penalização associada ao esforço de controle e deslocamento, incentivando trajetórias energeticamente eficientes. O termo $\lambda_2$ penaliza o tempo de duração total da missão, assegurando assim um mínimo tempo. Já o termo $\lambda_3$ penaliza o consumo de bateria dos agentes, assegurando assim missões com menor gasto de bateria.

Essa formulação permite que o planejador otimize o comportamento de cada agente respeitando as limitações dinâmicas, espaciais e energéticas, promovendo interceptações eficientes e seguras.

# 5 Configuração da Simulação

Neste capítulo, são apresentados os aspectos computacionais relacionados à implementação do planejador de trajetória em um ambiente prático e dinâmico. São discutidas as escolhas de parâmetros, dos algoritmos e ferramentas utilizadas para a solução da otimização.

## 5.1 Seleção e Análise dos Parâmetros do Planejador de Trajetória

A configuração apropriada dos parâmetros do planejador de trajetória é fundamental para garantir a estabilidade, viabilidade computacional e desempenho dos agentes em ambientes tridimensionais com restrições complexas. Esta seção apresenta os principais parâmetros utilizados no otimizador proposto, discutindo suas motivações, efeitos sobre o planejamento e critérios de escolha.

### 5.1.1 Tempo de Amostragem

O tempo de amostragem $t_s$ define a frequência com que o otimizador atualiza suas decisões. Um valor menor de $t_s$ resulta em maior densidade de pontos ao longo da trajetória, permitindo melhor aderência às restrições e maior suavidade no controle. No entanto, valores muito baixos aumentam significativamente o número de etapas de predição e, consequentemente, o custo computacional.

Neste trabalho, foi adotado $t_s = 0{,}2$ segundo. Esse valor foi escolhido com base em testes preliminares, nos quais se observou que menores valores aumentavam o tempo de solução sem ganhos relevantes de desempenho.

### 5.1.2 Parâmetros do Cenário

A Tabela 5.1 resume os principais parâmetros utilizados nos testes realizados, incluindo limites físicos, restrições de atuação e características dos agentes e obstáculos. Todos os parâmetros foram escolhidos com base em limitações reais do ambiente de testes e capacidades dos drones empregados.

TABELA 5.1 – Parâmetros utilizados no planejador de trajetória.

| **Símbolo** | **Descrição** | **Valor(es)** |
|---|---|---|
| $t_s$ | Tempo de amostragem | 0,2 s |
| $\mathbf{r}_{a,\min}, \mathbf{r}_{a,\max}$ | Limites de posição | $x, y \in [-6,\ 6]$ m; $z \in [0{,}5,\ 1{,}8]$ m |
| $\mathbf{v}_{\min}, \mathbf{v}_{\max}$ | Limites de velocidade | $[-0{,}5,\ 0{,}5]$ m/s e $[-0{,}2,\ 0{,}2]$ m/s |
| $\mathbf{a}_{\min}, \mathbf{a}_{\max}$ | Limites de aceleração | $[-0{,}8,\ 1]$ m/s$^2$ |
| $\delta$ | Tolerância de velocidade terminal | 0,1 m/s |
| $\epsilon$ | Distância mínima entre agentes e obstáculos | 0,2 m |
| $n_a$ | Número de agentes | 1, 2, 3 |
| $n_t$ | Número de alvos | 1, 2, 3 |
| $\mathbf{x}_i(0)$ | Estados iniciais dos agentes | Posições variadas; velocidades nulas |
| $a_j$ | Número de agentes por alvo | 1, 2 |

### 5.1.3 Modelagem dos Obstáculos

Cada obstáculo é modelado como um poliedro convexo definido por um conjunto de planos, conforme apresentado na Seção 4.2. A Tabela 5.2 resume os limites utilizados para os três obstáculos considerados nos testes, expressos pelas equações de seus planos, conforme definido na Equação (4.10).

TABELA 5.2 – Definição dos obstáculos utilizados nas simulações.

| **Obstáculo** | **Planos definidores (P, d)** |
|---|---|
| 1 | $x \in [-1{,}5,\ 1],\ y \in [-2,\ 2],\ z \in [-2,\ 2]$ |
| 2 | $x \in [-3{,}5,\ 4],\ y \in [-1,\ 6],\ z \in [-3,\ 6]$ |
| 3 | $x \in [-2,\ 2{,}5],\ y \in [-1{,}5,\ 4],\ z \in [-1,\ 3]$ |

A escolha dos parâmetros garante que o planejador de trajetória possa operar de forma segura e eficiente, mesmo em cenários com múltiplas restrições simultâneas. No Capítulo 6, os efeitos diretos da variação de alguns desses parâmetros são avaliados, demonstrando sua influência sobre o desempenho global do planejador.

## 5.2 Infraestrutura Algorítmica e Suporte Computacional

A implementação do planejador exige a resolução eficiente de um problema de otimização a cada iteração. Para isso, foi utilizado o pacote `YALMIP`, em conjunto com o MATLAB® (MATHWORKS, 2024), estruturado em programação orientada a objetos (*object-oriented programming* — OOP), o que permite a formulação modular de funções custo, restrições e variáveis de decisão, com integração a diversos *solvers* numéricos compatíveis com problemas convexos e mistos. Todas as execuções ocorreram em um notebook equipado com o sistema operacional Windows® 11 Home Single Language, processador Intel® Core™ i7 e 16 GB de memória RAM.

No contexto deste trabalho, o `YALMIP` foi empregado para construir a estrutura de otimização de forma parametrizada e modular, viabilizando a escalabilidade do otimizador para diferentes números de agentes e cenários operacionais. A função objetivo inclui termos associados à esforço de controle, tempo de missão e consumo energético. As restrições são formuladas em formato matricial, com o uso de inequações entre estados sucessivos para representar a dinâmica dos agentes.

A resolução do problema é feita por meio de um bloco *solver*, no qual o `YALMIP` compila previamente a estrutura do programa de otimização. Durante a execução, esse *solver* recebe os estados iniciais dos agentes e retorna a sequência ótima de posições, comandos de controle e variáveis auxiliares. Essa abordagem favorece reavaliações eficientes, respeitando as características específicas de cada agente e missão.

Entre as variáveis manipuladas no processo de otimização, destacam-se:

- Variáveis de estado, associadas às posições e velocidades previstas ao longo do horizonte de predição;

- Variáveis de controle, representando as entradas de referência a serem aplicadas a cada etapa;

- Variáveis binárias, responsáveis por ativar logicamente eventos como a chegada ao alvo, a ativação de obstáculos ou o acionamento de zonas de segurança.

Devido à presença simultânea de variáveis contínuas (como estados e entradas de

controle) e variáveis discretas (como decisões representadas por variáveis binárias), o problema de planejamento é classificado como uma instância de MIQP. Essa formulação combina uma função custo quadrática com restrições lineares sujeitas a variáveis de decisão mistas.

Para a resolução do problema, foi utilizado o ambiente de modelagem `YALMIP`, em conjunto com o *solver* `Gurobi`, amplamente reconhecido por sua eficiência na resolução de problemas de otimização mista. A escolha pelo `Gurobi` foi motivada pelo seu desempenho superior, especialmente em problemas com elevado número de variáveis binárias e restrições condicionais, como é o caso da formulação adotada neste trabalho (LUPPOLD *et al.*, 2018; AVELLA *et al.*, 2023).

# 6 Avaliação Baseada em Simulação

Este capítulo apresenta uma análise do planejador de trajetória proposto com base em testes realizados em ambiente simulado. O principal objetivo é validar a funcionalidade da arquitetura de planejamento e controle, em diferentes configurações, destacando sua capacidade de adaptação a cenários variados e restrições operacionais. Todos os experimentos utilizam o mesmo modelo do planejador e seguem os princípios fundamentais da otimização com restrições e da tomada de decisão.

As simulações foram organizadas em categorias distintas, permitindo isolar e avaliar aspectos específicos da otimização. A primeira série de testes explora a variação na quantidade de agentes e de alvos, com o objetivo de analisar o comportamento do otimizador em missões com diferentes níveis de complexidade e demanda de coordenação. Em seguida, são apresentados cenários com diferentes limites de velocidade, para avaliar o impacto dessas restrições na execução das trajetórias planejadas.

Outros testes consideram a presença de obstáculos, fixos e móveis. Nesses casos, avalia-se a capacidade do planejador de prever e evitar colisões, respeitando as restrições de segurança estabelecidas. Também foram realizados experimentos com variação do nível de bateria, simulando diferentes combinações de quantidade de agentes e disponibilidade energética. Além disso, este capítulo apresenta a avaliação da restrição de velocidade terminal, que tem como objetivo garantir que os agentes, ao alcançarem seus alvos, o façam com alinhamento vetorial de velocidades.

Devido ao período de amostragem pequeno, utilizado para o planejamento, para facilitar a visualização dos marcadores nos gráficos de posição, foi adotado um espaçamento de $0,5$ segundo entre cada marcador. Essa abordagem permitiu uma apresentação mais clara dos resultados, sem comprometer a acuracidade do modelo, e facilitou a interpretação das dinâmicas de movimentação dos agentes e alvos durante os experimentos.

Por fim, apresenta-se um cenário representativo voltado ao contexto do projeto CTEDS, no qual o planejador de trajetórias é avaliado em um cenário de defesa aérea, em que múltiplos alvos simulam ataques a uma área protegida. Esse experimento foi concebido para representar um ambiente operacional mais realista e desafiador, no qual os agentes devem atuar de forma coordenada para interceptar os alvos, respeitando simultaneamente

restrições físicas, energéticas e de segurança. A inclusão deste cenário visa demonstrar a aplicabilidade da metodologia proposta em contextos críticos, nos quais a tomada de decisão rápida e eficiente é essencial para o sucesso da missão.

## 6.1 Análise de Escalabilidade com Múltiplos Agentes e Alvos

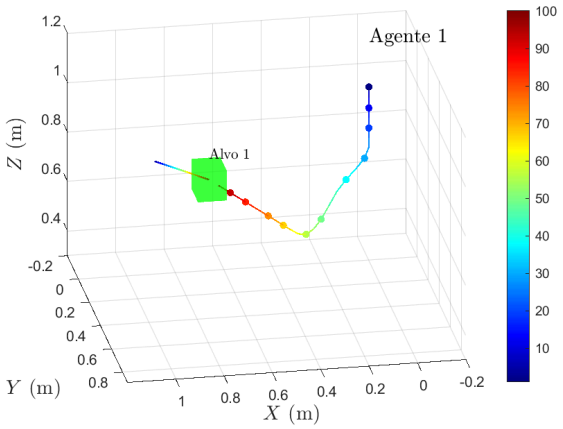
Esta seção avalia o comportamento do planejador de trajetória em cenários com diferentes quantidades de agentes e alvos, com o objetivo de verificar sua capacidade de manter a coordenação e viabilidade das trajetórias à medida que a escala da operação aumenta. Os experimentos foram conduzidos em ambientes simples, com variações controladas no número de drones e alvos. O foco está em observar como o otimizador responde ao aumento do número de agentes, mantendo a execução coordenada das trajetórias simuladas.

O primeiro experimento tem como objetivo validar o funcionamento do planejador de trajetória em sua configuração mais simples: um único agente alocado a um único alvo, em um ambiente livre de obstáculos e sem restrições adicionais de alocação. O agente é inicializado na posição $(0,\ 0,\ 1)$ m, com velocidade inicial nula nos três eixos.

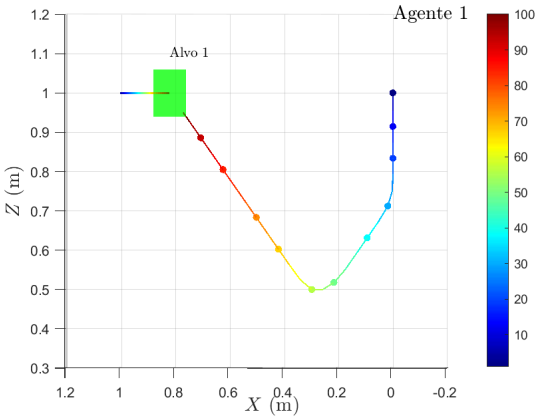
As restrições para o modelo dinâmico incluem limites de posição $x, y, z \in [-1{,}8,\ 1{,}8]$ m, velocidade $[-0{,}2,\ 0{,}2]$ m/s, e aceleração $[-0{,}8,\ 0{,}8]$ m/s$^2$. O horizonte de predição ótimo foi de 27 passos, com tempo de amostragem $t_s = 0{,}2$ s e $n_{\max} = 50$, em que foi selecionado de forma a garantir que o valor de $n^*$ estivesse contido dentro desse valor, de forma a assegurar um horizonte ótimo. O alvo desloca-se com velocidade constante de 0,2 m/s em direção aleatória.

A Figura 6.1 apresenta a trajetória ótima gerada pelo otimizador ao longo do tempo, com a coloração indicando a progressão temporal da missão em percentual do horizonte de predição. O tempo de solução da otimização para este caso foi de $t_c = 0{,}0206$ s.

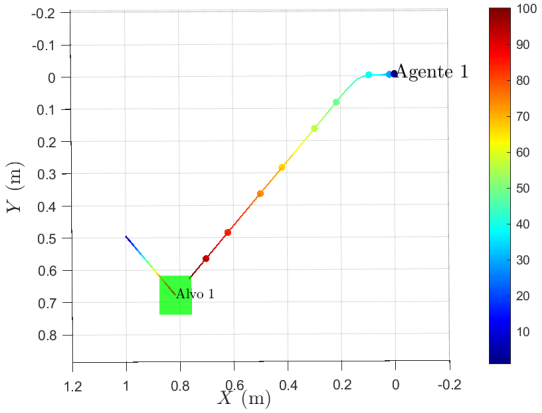
Observa-se que o agente segue uma trajetória contínua e suave até atingir o alvo, respeitando todas as restrições físicas e dinâmicas. Como não há múltiplos agentes nem obstáculos, não há exigência de estratégias de evasão ou coordenação. Esse experimento serve como ponto de partida para validar o comportamento básico do algoritmo de planejamento de trajetória antes da introdução de cenários mais complexos.




(1) Visão Diagonal 3D.




(2) Visão Lateral.




(3) Visão Superior.

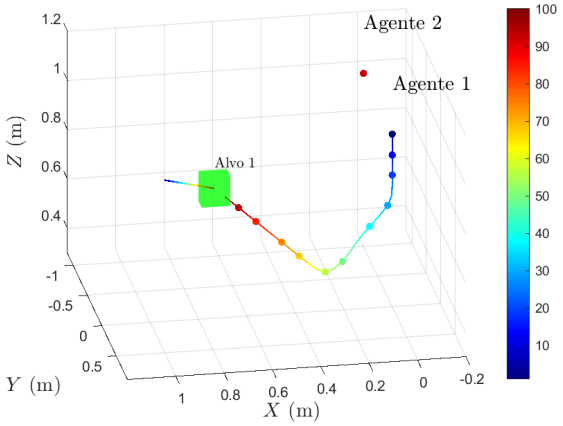
FIGURA 6.1 – Visualização das posições do alvo e do agente para o cenário com um agente e um alvo. As três subfiguras mostram diferentes perspectivas do movimento do agente em direção ao alvo: (1) visão diagonal 3D, (2) visão lateral no plano $XZ$ e (3) visão superior no plano $XY$. A coloração ao longo das trajetórias representa a progressão temporal da missão em percentual do horizonte de predição (0 a 100%). O agente é inicializado na posição $(0,\ 0,\ 1)$ com velocidade inicial nula nos três eixos. Legenda: ○ Posição e ■ Alvo.

No segundo teste, o planejador foi configurado com dois agentes operando no mesmo ambiente. O objetivo é avaliar o comportamento da simulação com MAS, ainda sem obstáculos.

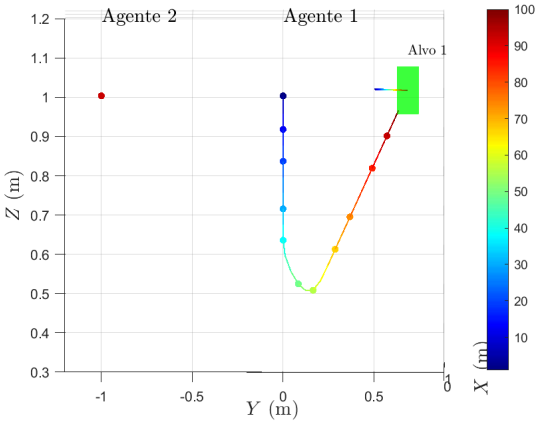
Ambos os agentes foram inicializados em posições distintas, com altura de 1 metro e velocidades nulas. O Agente 1 foi posicionado em $(0,\ 0,\ 1)$ m, enquanto o Agente 2 foi iniciado em $(0,\ -1,\ 1)$ m. Um alvo móvel foi adicionado ao ambiente, e o planejamento de trajetória foi realizado de modo que apenas o Agente 1 se deslocasse até ele, enquanto o Agente 2 permaneceu estacionado durante toda a simulação. Essa alocação está de

acordo com a restrição definida na Equação (4.27), que especifica a quantidade de agentes atribuídos a cada alvo.

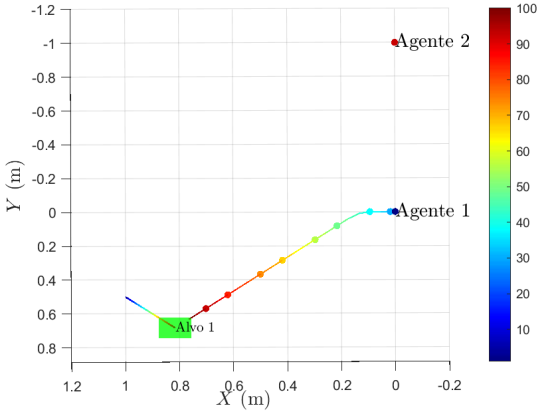
As restrições dinâmicas e operacionais utilizadas nesse teste foram mantidas idênticas às do cenário anterior, garantindo consistência na análise comparativa do otimizador. O horizonte de predição utilizado pelo otimizador foi de $n^* = 27$ passos, e o tempo de solução da otimização para esse caso foi de $t_c = 0{,}022$ s, apresentando apenas uma pequena variação em relação ao teste com um único agente e novamente com $n_{\max} = 50$.




(1) Visão Diagonal 3D.




(2) Visão Lateral.




(3) Visão Superior.

FIGURA 6.2 – Visualização das posições simuladas do alvo e dos agentes para o cenário com dois agentes e um único alvo. O Agente 1 parte da posição $(0,\ 0,\ 1)$ m, enquanto o Agente 2 inicia em $(0,\ -1,\ 1)$ m, ambos com velocidades iniciais nulas. Apenas o Agente 1 executa a movimentação até o alvo, enquanto o Agente 2 permanece estacionado durante toda a simulação, respeitando a restrição (4.27). A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

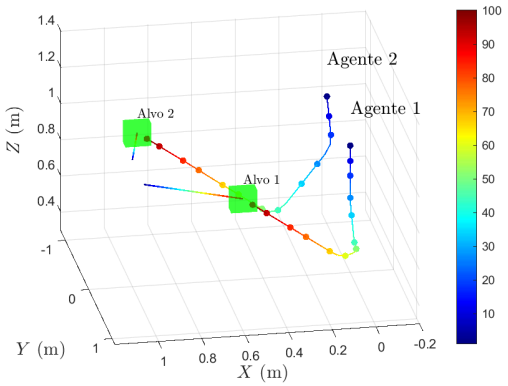
A Figura 6.2 apresenta as trajetórias simuladas sob três perspectivas: visão diagonal

3D, lateral no plano $XZ$ e superior no plano $XY$. O agente designado para alcançar o alvo realiza o deslocamento completo até a posição final, enquanto o outro permanece parado, conforme previsto na configuração do teste.

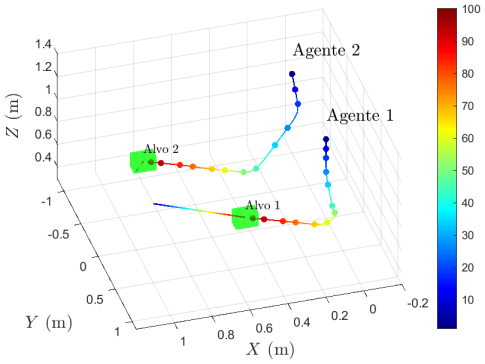
O terceiro cenário teve por objetivo avaliar a escalabilidade do planejador de trajetória em missões com múltiplos agentes e alvos. Dois agentes são encarregados de interceptar dois alvos distintos, operando de forma coordenada e simultânea. O ambiente é livre de obstáculos ou restrições adicionais, permitindo a análise isolada da complexidade associada ao aumento do número de entidades no otimizador.

Os agentes são inicializados em posições distintas, com altura constante de 1 metro e velocidades nulas, como na avaliação anterior. Os alvos são distribuídos no espaço, e a associação de cada agente a um alvo é determinada automaticamente pelo otimizador, respeitando a restrição de alocação definida na Equação (4.27). A trajetória de cada agente é planejada em conjunto dentro de um único problema de otimização, garantindo a coordenação das ações e o cumprimento simultâneo das restrições da missão. O tempo de solução para este cenário foi de $t_c = 0{,}1451$ s.

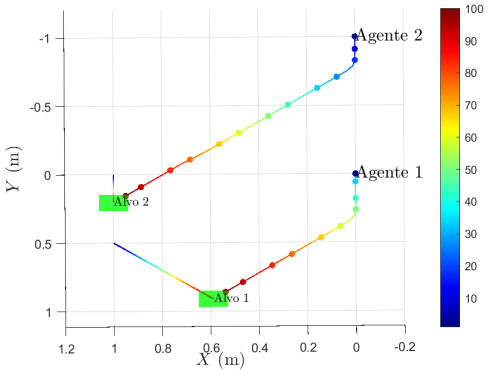
A Figura 6.3 apresenta a evolução das posições simuladas dos agentes ao longo do tempo, com três visualizações: uma vista diagonal 3D, uma vista diagonal superior e uma projeção no plano $XY$. As cores indicam a progressão temporal da missão. Cada agente segue uma trajetória distinta em direção ao seu respectivo alvo, de forma fluida e sem interferência mútua.




(1) Visão Diagonal 3D.



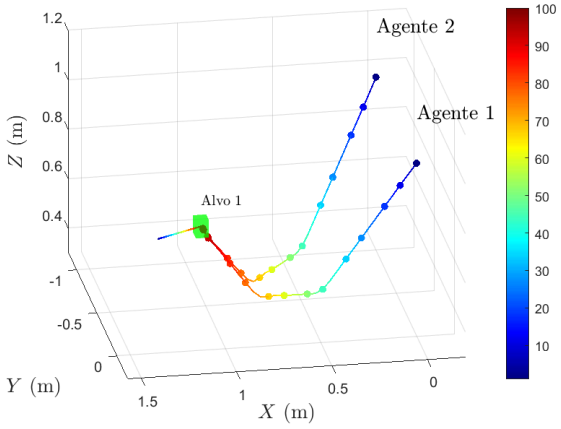

(2) Visão Diagonal Superior.



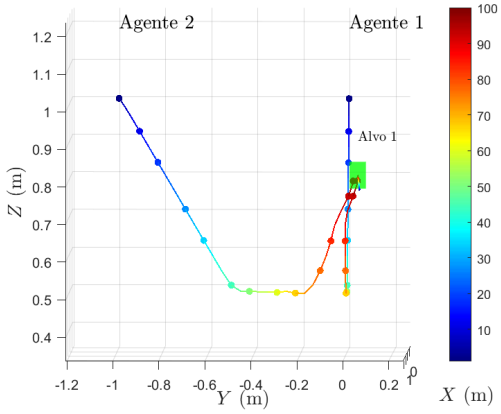

(3) Visão Superior.

FIGURA 6.3 – Visualização das posições simuladas dos alvos e dos agentes para o cenário com dois agentes e dois alvos. Os agentes são inicializados com alturas iguais de um metro e velocidades iniciais nulas, sendo alocados automaticamente a alvos distintos pelo otimizador. Cada agente realiza o deslocamento até seu respectivo alvo, sem sobreposição entre as trajetórias. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

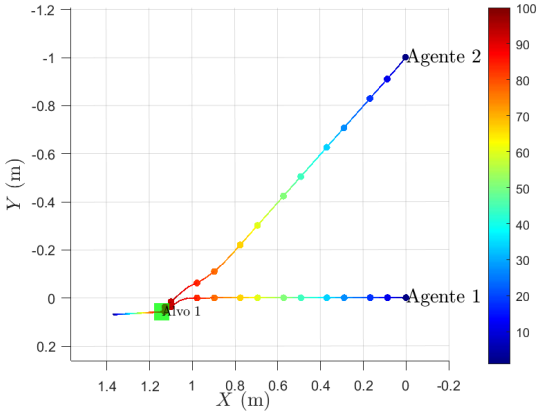
No quarto cenário, o objetivo foi avaliar a capacidade do planejador em lidar com múltiplos agentes atribuídos a um mesmo alvo, modificando a restrição de alocação da Equação (4.27) para permitir a designação de mais de um agente por alvo.




(1) Visão Diagonal 3D.




(2) Visão Lateral.




(3) Visão Superior.

FIGURA 6.4 – Visualização das posições simuladas do alvo e dos agentes para o cenário com dois agentes e um alvo. O Agente 1 parte da posição $(0,\ 0,\ 1)$ m, enquanto o Agente 2 inicia em $(0,\ -1,\ 1)$ m, ambos com velocidades iniciais nulas. Ambos os agentes executam a movimentação até o mesmo alvo, respeitando a restrição (4.27), a qual teve o número de agentes alocados $a_j = 2$. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

Foram utilizados dois agentes posicionados em $(0,\ 0,\ 1)$ m e $(0,\ -1,\ 1)$ m, respectivamente, ambos com velocidades iniciais nulas. Um único alvo móvel foi inserido no ambiente, e, diferentemente do segundo teste, desta vez ambos os agentes foram autorizados a persegui-lo simultaneamente, cooperando para cumprir a missão comum. Essa abordagem permite verificar se o otimizador é capaz de gerar trajetórias compatíveis e seguras em um cenário de cooperação direta para um mesmo objetivo.

As restrições operacionais e dinâmicas dos agentes permaneceram inalteradas em relação aos testes anteriores, garantindo comparabilidade dos resultados. O horizonte ótimo

de predição determinado pelo otimizador foi $n^* = 29$, e o tempo necessário para resolver o problema foi de $t_c = 0{,}8199$ s, um valor superior ao dos testes anteriores devido à inclusão da lógica de coordenação entre múltiplos agentes atuando sobre um mesmo destino.

A Figura 6.4 apresenta as trajetórias dos agentes, demonstrando que ambos se deslocaram em direção ao mesmo alvo, com rotas coordenadas. A evolução temporal é indicada pela coloração dos caminhos.

No último teste da avaliação com variação no número de agentes, o planejador de trajetórias foi simulado com três agentes operando simultaneamente, cada um direcionado a um alvo distinto. Esse cenário representa a configuração mais complexa desta etapa, aumentando o nível de paralelismo e exigindo maior coordenação na execução das trajetórias.

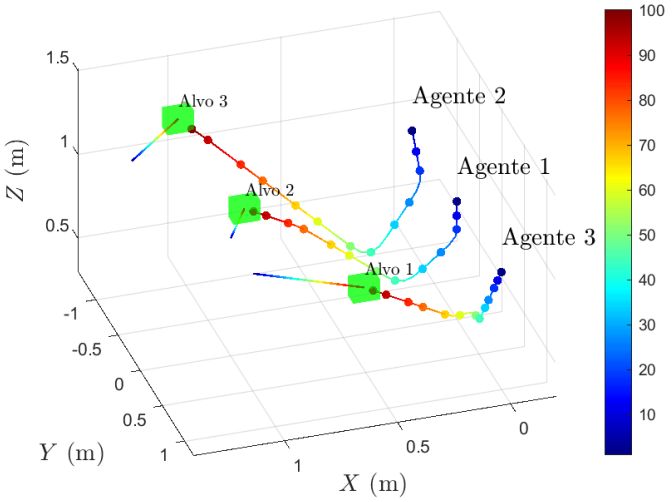



FIGURA 6.5 – Visualização das posições simuladas dos agentes e dos alvos no cenário com três agentes e três alvos. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

Os três agentes são inicializados em posições distintas, com velocidades nulas, e posicionados em diferentes regiões do espaço de operação. Os alvos são distribuídos aleatoriamente com diferentes trajetórias, permitindo a análise da resposta do otimizador em termos de sincronização e fluidez de movimento em múltiplas direções. O tempo de otimização para esse cenário foi de $1,7$ s.

A Figura 6.5 apresenta a visualização geral da simulação, em que cada agente segue uma trajetória distinta até seu respectivo alvo. O comportamento coordenado, sem conflitos de rota, evidencia a capacidade do otimizador de coordenar múltiplas missões simultaneamente de forma eficiente.

Os resultados desta seção demonstram que o planejador é capaz de escalar com a in-

clusão de múltiplos agentes operando cooperativamente no mesmo ambiente. A execução coordenada das trajetórias foi mantida mesmo com o aumento gradual do número de agentes. Embora o cálculo do otimizador seja realizado de forma centralizada, a modelagem foi estruturada de forma modular, permitindo a incorporação de novos agentes com mínimas alterações na arquitetura geral. Assim, o otimizador proposto pode ser estendido para um número arbitrário de $n_a$ agentes, desde que respeitados os limites computacionais da simulação e as restrições físicas do espaço de operação. A Tabela 6.1 apresenta os tempos de solução para diferentes configurações de agentes e alvos.

TABELA 6.1 – Tempo de solução para diferentes quantidades de agentes e alvos.

| $n_a$ | $n_t$ | $a_j$ | $n^*$ | $t_c$ (s) |
|---|---|---|---|---|
| 1 | 1 | 1 | 27 | 0,0206 |
| 2 | 1 | 1 | 27 | 0,0219 |
| 2 | 1 | 2 | 29 | 0,8199 |
| 2 | 2 | 1 | 30 | 0,1451 |
| 3 | 3 | 1 | 30 | 1,7065 |

Observa-se que o tempo de solução $t_c$ aumenta com a complexidade do cenário, seja pelo número de agentes, de alvos ou pela exigência de múltiplos agentes por alvo. Embora o caso com três agentes e três alvos apresente o maior tempo de solução (1,7065 s), o cenário com dois agentes alocados a um único alvo ($a_j = 2$) também demonstra impacto relevante no custo computacional, elevando o tempo para 0,8199 s. Esse comportamento reflete o aumento no número de variáveis binárias e restrições de acoplamento, que tornam o problema de otimização mais denso e exigente para o solucionador.

## 6.2 Impacto da Restrição de Velocidade nas Métricas de Desempenho

Para avaliar o impacto da restrição de velocidade no comportamento do agente, foi realizada uma simulação com apenas um agente, de forma a isolar os efeitos dessa limitação sem a interferência de múltiplos agentes. O agente foi inicializado na posição $(0,\ 0,\ 1)$ metros, com velocidades nulas nos três eixos.

O limite de velocidade foi aplicado individualmente a cada componente do vetor, isto é, $v_e \in [-0{,}5,\ 0{,}5]$ m/s para $e = x,\ y,\ z$. As demais restrições foram: aceleração limitada a $[-0{,}8,\ 1{,}0]$ m/s$^2$ em cada eixo e posição dentro do intervalo $[-1{,}8,\ 1{,}8]$ metros em $x$ e $y$, com altura mínima de 0,5 metros em $z$.

A Figura 6.6 apresenta a posição simulada do agente, com a progressão temporal representada pela coloração dos pontos. Observa-se que o deslocamento ocorre de forma suave até o alvo, respeitando os limites definidos para cada eixo. A limitação de velocidade influenciou diretamente o tempo de deslocamento, como veremos posteriormente.

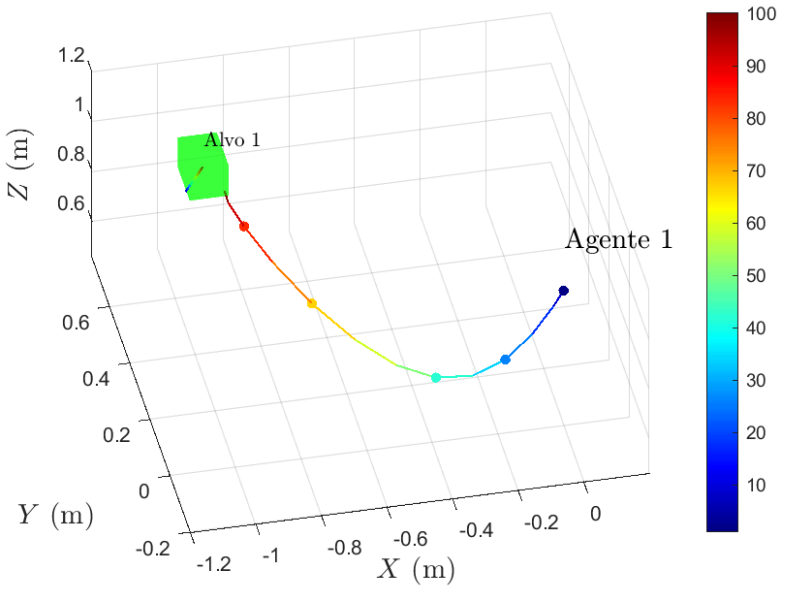



FIGURA 6.6 – Posições simuladas para o cenário com um agente, um alvo e restrição de velocidade de $[-0{,}5,\ 0{,}5]$ m/s em cada eixo para o agente. O agente inicia em $(0,\ 0,\ 1)$ m com velocidades nulas e percorre a trajetória respeitando as restrições impostas de posição, velocidade e aceleração. A coloração ao longo da trajetória indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

A Figura 6.7 apresenta os gráficos de velocidade, aceleração e ação de controle (posição de referência) para os três eixos. As linhas tracejadas indicam os limites definidos para cada variável. Observa-se que todas as componentes de velocidade permanecem dentro do intervalo $[-0{,}5,\ 0{,}5]$ m/s ao longo de toda a trajetória. O mesmo ocorre com as demais variáveis, confirmando o correto funcionamento do otimizador e o atendimento às restrições operacionais impostas.

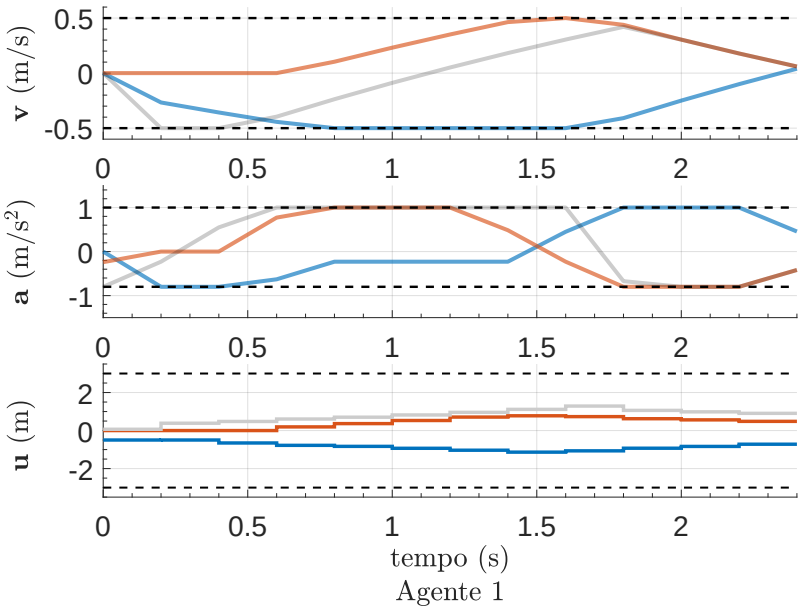



FIGURA 6.7 – Velocidades, acelerações e ações de controle do agente durante a simulação com restrição de velocidade de $[-0{,}5,\ 0{,}5]$ m/s por eixo. Os gráficos mostram a resposta nos eixos $x$, $y$ e $z$, com os limites impostos destacados por linhas tracejadas. Todas as variáveis respeitaram os limites definidos. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições.

No segundo experimento, a velocidade do agente foi limitada a um valor menor, restringindo cada componente do vetor velocidade ao intervalo $[-0{,}2,\ 0{,}2]$ m/s. O objetivo é observar os efeitos dessa limitação mais severa sobre o tempo de execução da trajetória e o desempenho do planejador, além de representar melhor as características de determinados atuadores. Assim como no caso anterior, o agente foi inicializado na posição $(0,\ 0,\ 1)$ m, com velocidades nulas.

A Figura 6.8 apresenta a visualização da posição simulada ao longo do tempo. Em comparação com o teste anterior, com limite de $[-0{,}5,\ 0{,}5]$ m/s, observa-se uma curva maior, coerente com a menor velocidade permitida para os atuadores. Ainda assim, a trajetória permaneceu contínua, estável e suave, evidenciando a adaptação do otimizador à nova restrição.

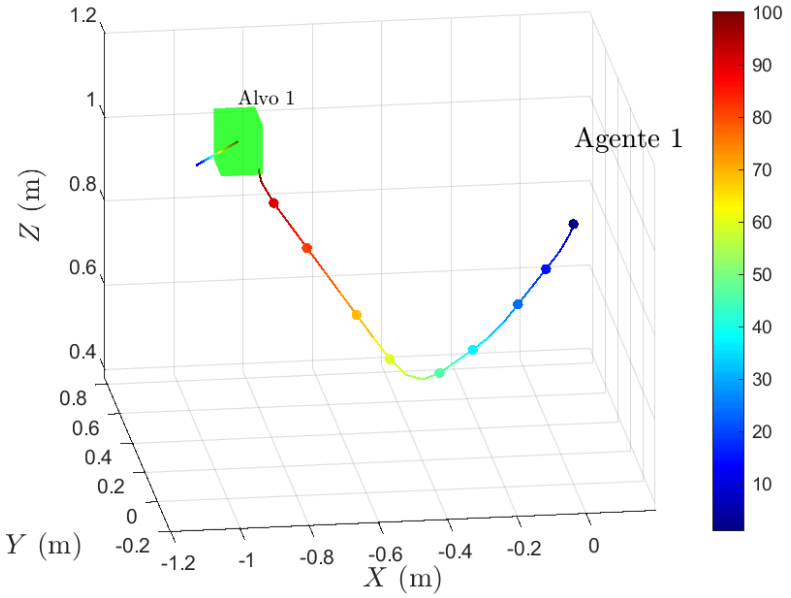



FIGURA 6.8 – Posições simulada para o cenário com um agente, um alvo e restrição de velocidade de $[-0{,}2,\ 0{,}2]$ m/s por eixo. O agente inicia em $(0,\ 0,\ 1)$ m com velocidades nulas e alcança o alvo respeitando os limites impostos. A coloração ao longo da trajetória indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

A Figura 6.9 mostra os gráficos de velocidade, aceleração e ação de controle nos três eixos. Mesmo com a restrição mais rigorosa, todas as variáveis permaneceram dentro dos limites definidos, com o agente executando a tarefa sem ultrapassar os valores máximos permitidos para velocidade, aceleração ou controle.

A Tabela 6.2 evidencia o impacto direto da limitação de velocidade nas métricas de desempenho do planejador de trajetórias. Ao comparar os dois cenários simulados, observa-se que a redução do intervalo de velocidade permitida, de $[-0{,}5,\ 0{,}5]$ m/s para $[-0{,}2,\ 0{,}2]$ m/s por eixo, aumentou significativamente o tempo necessário para a conclusão da missão, passando de 3,4 s para 4,4 s. Essa diferença é coerente com a limitação imposta à velocidade de cruzeiro do agente, que reduz sua capacidade de resposta dinâmica. Além disso, nota-se um leve aumento no tempo de solução da otimização, o que sugere que restrições mais rígidas podem demandar maior esforço computacional para encontrar soluções viáveis. Esses resultados reforçam a importância do ajuste adequado das restrições de velocidade, considerando o equilíbrio entre desempenho, segurança e viabilidade computacional.

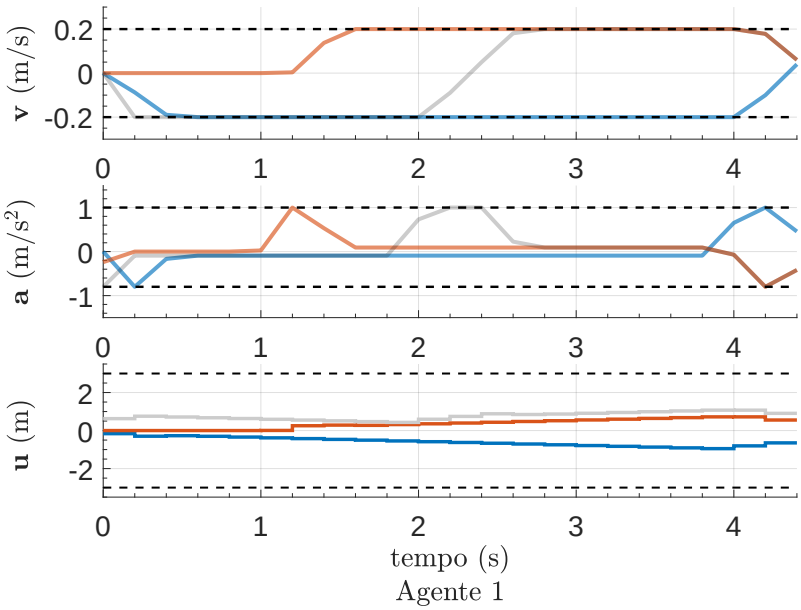



FIGURA 6.9 – Velocidades, acelerações e ações de controle durante a simulação com restrição de velocidade $[-0{,}2,\ 0{,}2]$ m/s por eixo. As curvas correspondem aos eixos $x$, $y$ e $z$, com os limites operacionais destacados por linhas tracejadas. O otimizador permaneceu dentro das restrições em todos os instantes. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições.

TABELA 6.2 – Impacto da restrição de velocidade nas métricas de desempenho (um agente e um alvo).

| $\mathbf{v}_{\max}$ (m/s) | $n^*$ | Tempo de Missão (s) | $t_c$(s) |
|---|---|---|---|
| 0,5 | 17 | 3,4 | 0,0079 |
| 0,2 | 22 | 4,4 | 0,0184 |

O resultado reforça a capacidade do otimizador de adaptar planejamento e controle às restrições impostas, mantendo conformidade com as condições operacionais. Também evidencia a flexibilidade do modelo proposto, que permite ajustar parâmetros como velocidade, aceleração e limites espaciais conforme as exigências da aplicação ou as características dos atuadores utilizados.

## 6.3 Avaliação em Cenário com Obstáculos

Esta seção apresenta a avaliação do planejador em cenários com obstáculos no ambiente, com o objetivo de verificar sua capacidade de planejamento seguro e operação em espaços restritos. São consideradas duas categorias principais: obstáculos fixos e móveis.

Os obstáculos fixos são elementos estáticos representados por volumes geométricos do

tipo poliedro, posicionados de forma arbitrária no espaço tridimensional. Esses elementos permanecem imóveis ao longo do tempo e representam barreiras físicas que o agente deve evitar durante a execução da trajetória.

Os obstáculos móveis, por sua vez, são representados pelos próprios agentes operando simultaneamente. Nesse caso, o otimizador considera a posição de cada agente em tempo real para garantir que todos mantenham uma distância segura entre si, respeitando a restrição de não colisão.

Os testes a seguir buscam validar se o otimizador é capaz de gerar trajetórias viáveis, evitando colisões, respeitando as restrições operacionais e garantindo o sucesso da missão em cenários com maior complexidade estrutural.

### 6.3.1 Obstáculos Fixos

O primeiro experimento com obstáculos fixos foi configurado com dois agentes e dois alvos, incluindo elementos estáticos no ambiente para tornar o cenário mais desafiador do ponto de vista de navegação e planejamento de trajetórias. O uso de dois agentes permite avaliar o comportamento do otimizador operando simultaneamente em um espaço tridimensional restrito, com múltiplas rotas viáveis.

Para esse teste, foi adotada uma nova configuração de estados iniciais: o Agente 1 parte da posição $(4,\ 2,\ 1)$ m, enquanto o Agente 2 inicia em $(4,\ 1,\ 1)$ m. Ambos são inicializados com velocidades nulas. A escolha dessas posições visa ampliar a área de atuação e inserir os obstáculos diretamente na zona de trajeto dos agentes.

Devido a essa ampliação, as restrições de posição foram ajustadas para o intervalo $[-2,\ 6]$ m em todos os eixos, permitindo liberdade de navegação suficiente para contornar os obstáculos ao longo do caminho até os alvos.

A Figura 6.10 apresenta o resultado da simulação, destacando as posições planejadas, os dois obstáculos fixos (representados por blocos cinza) e os alvos atribuídos a cada agente. Observa-se que ambos alcançaram seus respectivos objetivos sem colisões, demonstrando a eficácia do planejamento mesmo em ambientes com barreiras estáticas.

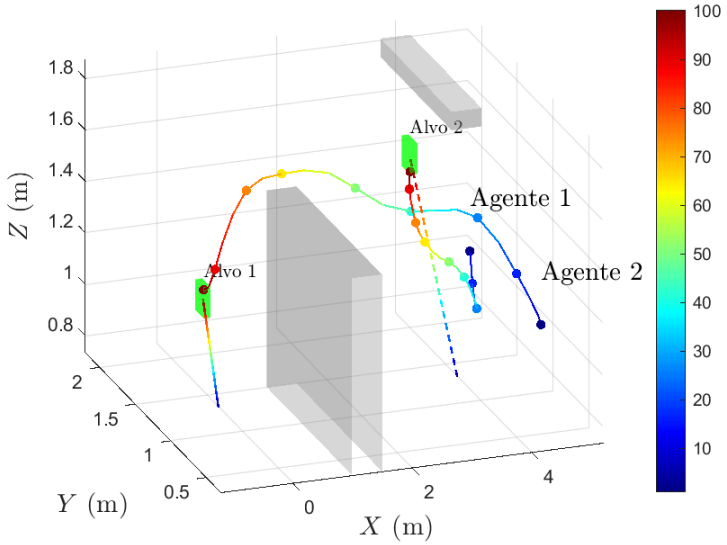
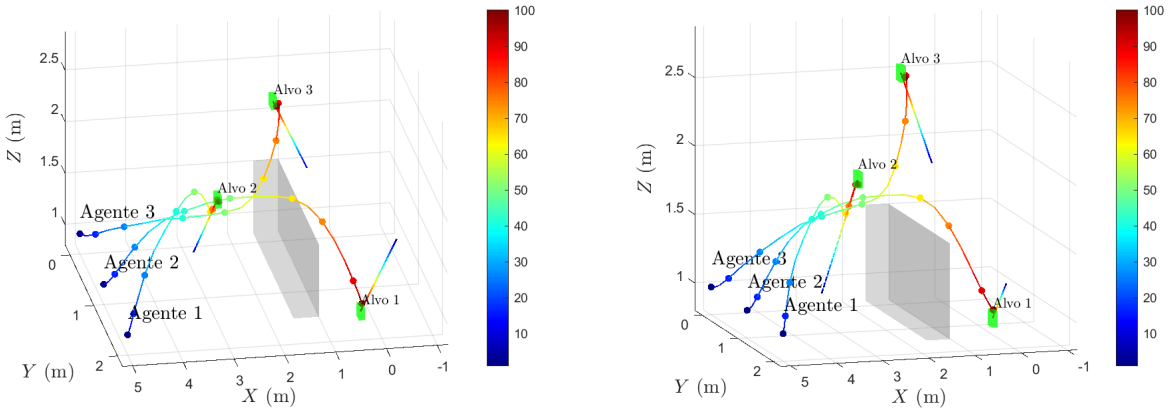



FIGURA 6.10 – Visualização do cenário com dois agentes e dois obstáculos fixos. Os agentes são inicializados nas posições $(4,\ 2,\ 1)$ m e $(4,\ 1,\ 1)$ m, com velocidades nulas, e cada um é designado a um alvo distinto. As trajetórias são calculadas de modo a evitar colisões com os obstáculos, representados por volumes em cinza. A coloração ao longo das trajetórias indica a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo.

Na segunda simulação com obstáculos fixos, foi utilizada uma configuração com três agentes e apenas um obstáculo estático. O objetivo é avaliar o comportamento do planejador de trajetórias em cenários com maior densidade de agentes, onde a necessidade de coordenação e planejamento se torna mais crítica, mesmo com um número reduzido de barreiras físicas.

Para permitir maior liberdade de manobra e gerar rotas mais amplas e diversificadas, as posições iniciais dos agentes foram novamente ajustadas. O Agente 1 parte da posição $(5,\ 2,\ 1)$ m, o Agente 2 de $(5,\ 1,\ 1)$ m e o Agente 3 de $(5,\ 0,\ 1)$ m, todos com velocidades nulas. Embora cada agente inicie em uma posição distinta no eixo $y$, todos compartilham a mesma coordenada em $x$ e $z$. Essa configuração avalia como os agentes se dispersam para alcançar seus respectivos alvos, contornando o obstáculo fixo posicionado entre suas rotas.

A Figura 6.11 apresenta o resultado da simulação em duas perspectivas distintas. Observa-se que os agentes seguem caminhos otimizados, mantendo distância segura do obstáculo e atingindo seus objetivos de forma eficiente. A visualização em diferentes ângulos facilita a análise da distribuição espacial das rotas e da interação entre os elementos do ambiente.




(1). (2).

FIGURA 6.11 – Cenário com três agentes e um obstáculo fixo. Os agentes partem de posições alinhadas no plano $XZ$, com velocidades nulas, e são direcionados a três alvos distintos. As trajetórias são planejadas de forma a evitar colisões com o obstáculo. A coloração ao longo das trajetórias representa a evolução temporal da simulação, expressa em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo.

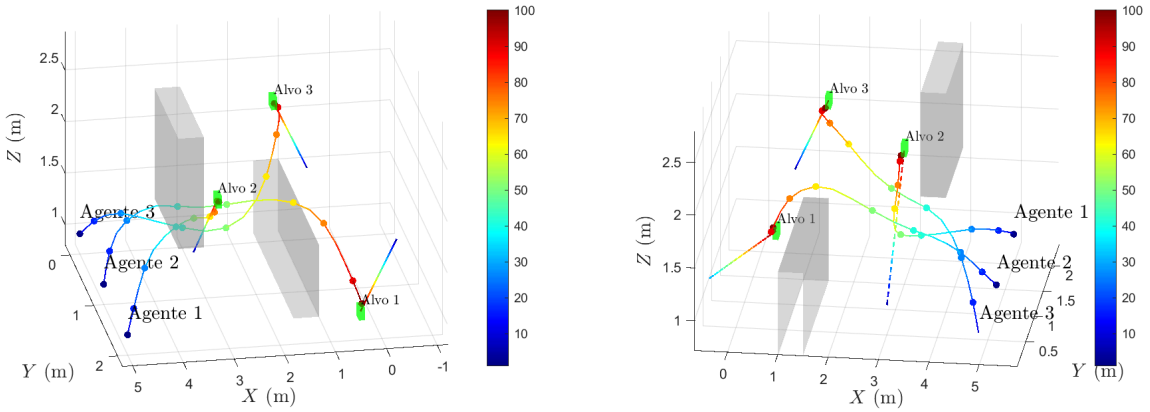
Dando continuidade aos testes com obstáculos fixos, este cenário utiliza a mesma configuração de agentes do experimento anterior, mantendo as posições iniciais em (5, 2, 1) m, (5, 1, 1) m e (5, 0, 1) m, todas com velocidades nulas. A única modificação em relação ao caso anterior é o aumento na quantidade de obstáculos, passando de um para dois, o que introduz maior complexidade estrutural ao ambiente.

A adição de um segundo obstáculo exige que o otimizador calcule rotas mais elaboradas, com maior coordenação entre os agentes e maior precisão no controle para garantir o sucesso da missão. A Figura 6.12 apresenta o resultado da simulação sob duas perspectivas distintas, permitindo visualizar com clareza a distribuição dos obstáculos e o percurso de cada agente até seu respectivo alvo.

No último experimento com obstáculos fixos, a configuração mantém os mesmos três agentes e seus respectivos estados iniciais, mas aumenta ainda mais a complexidade do ambiente ao inserir três obstáculos estáticos no espaço de navegação. Essa modificação tem como objetivo avaliar a escalabilidade do otimizador diante de múltiplas interferências distribuídas no cenário.

Com a adição do terceiro obstáculo, o espaço disponível para navegação torna-se mais restrito, exigindo maior precisão nas trajetórias e maior capacidade de adaptação do otimizador. A coordenação entre os agentes e a escolha de rotas seguras tornam-se ainda mais críticas, especialmente em regiões onde os caminhos se aproximam.

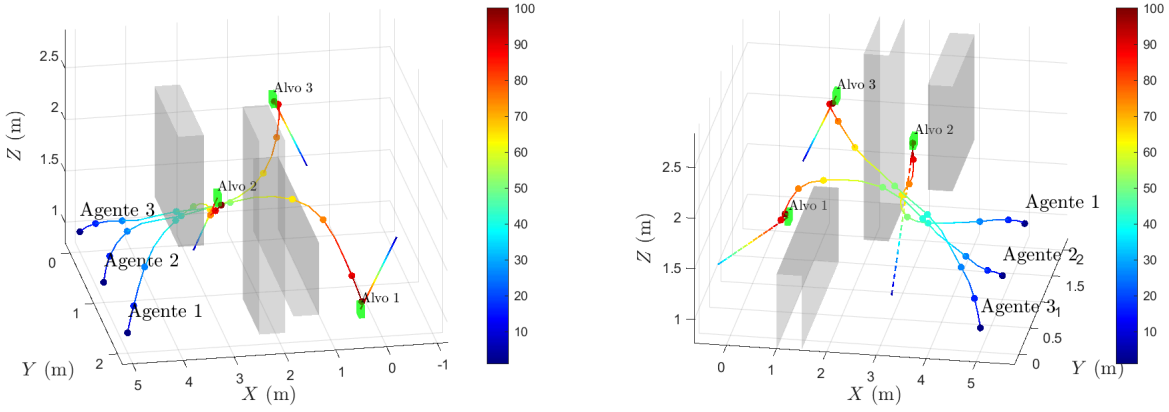
A Figura 6.13 apresenta a simulação sob duas perspectivas distintas. Observa-se que,




(1). (2).

FIGURA 6.12 – Cenário com três agentes e dois obstáculos fixos. Os agentes partem de posições alinhadas no plano $XZ$ e se deslocam até seus respectivos alvos, evitando dois obstáculos. As trajetórias são otimizadas para evitar colisões, e as diferentes perspectivas destacam a interação espacial entre agentes e obstáculos. A coloração ao longo das trajetórias representa a evolução temporal da simulação, expressa em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo.

mesmo com a sobreposição visual entre rotas e obstáculos, todos os agentes alcançaram seus respectivos alvos sem violar as restrições de não colisão, demonstrando a robustez do modelo em ambientes com alta densidade de obstáculos.




(1). (2).

FIGURA 6.13 – Cenário com três agentes e três obstáculos fixos. As trajetórias são planejadas de forma a garantir a interceptação dos alvos enquanto evitam colisões com os obstáculos distribuídos no ambiente. A coloração ao longo das trajetórias representa a evolução temporal da simulação, expressa em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição, ■ Alvo e ■ Obstáculo.

A partir dos testes realizados com diferentes configurações de obstáculos fixos, foi possível observar que o otimizador é capaz de planejar trajetórias viáveis mesmo em cenários

com obstáculos posicionados em regiões críticas do espaço de navegação. Com o aumento da densidade de obstáculos, a liberdade de movimentação dos agentes foi naturalmente reduzida, levando-os a seguir rotas mais próximas entre si. Esse comportamento, embora esperado, introduz um risco adicional de colisão entre agentes, mesmo em ambientes compostos apenas por elementos estáticos. Esses dados servem como motivação para a próxima etapa de avaliação, que aborda diretamente a presença de obstáculos móveis representados pelos próprios agentes em operação cooperativa.

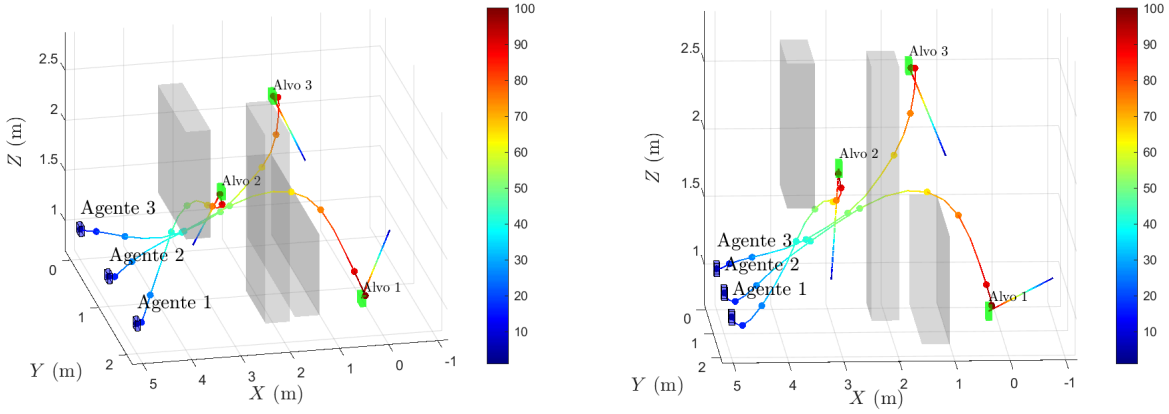
### 6.3.2 Restrição de Prevenção de Colisões entre Agentes

Nesta seção, avalia-se o desempenho do planejador de trajetórias diante da necessidade de evitar colisões entre múltiplos agentes que operam simultaneamente no mesmo espaço tridimensional. Como cada agente é representado por um politopo convexo e atua como obstáculo dinâmico para os demais, é essencial garantir que suas trajetórias não resultem em interseção entre volumes ao longo do horizonte de predição.

A formulação da restrição de anticolisão foi apresentada no Capítulo 3, utilizando uma abordagem baseada na separação por planos entre os politopos dos agentes. A condição de não interseção é imposta por meio de inequações lineares parametrizadas por vetores normais às faces do politopo e uma variável binária associada a cada uma delas, conforme Equações (4.16) e (4.17). O parâmetro $d_a^{i_o}$ representa o deslocamento escalar associado a cada face do politopo do agente $i_o$, e o termo $2d_a^{i_o}$ define a separação mínima entre os volumes dos agentes.

Para avaliar o efeito dessa restrição, foi realizado um experimento com três agentes e três obstáculos fixos. Os agentes partem de posições distintas e são direcionados a alvos diferentes, de modo a gerar cruzamento potencial de trajetórias. A separação mínima imposta entre os volumes foi fixada em $2d_a^{i_o} = 0{,}1\,\mathrm{m}$, o que equivale a cada face do politopo ter um deslocamento escalar $d_a^{i_o} = 0{,}05\,\mathrm{m}$.

A Figura 6.14 ilustra o comportamento dos agentes durante a missão. Observa-se que os trajetos planejados respeitam as restrições de não interseção entre os volumes, mesmo em regiões onde as trajetórias convergem ou se aproximam dos obstáculos. A coloração das trajetórias representa a evolução temporal da missão, expressa em percentual do horizonte de predição.




(1). (2).

FIGURA 6.14 – Simulação com três agentes em ambiente tridimensional, sob restrição de anticolisão com separação mínima de $2d_a^{io} = 0{,}1\,\text{m}$. A trajetória de cada agente respeita a separação entre os volumes poliedrais, mesmo em regiões críticas. Legenda: ■ Agente, ○ Posição, ■ Alvo, ■ Obstáculo.

Para confirmar que a separação entre volumes foi mantida, monitorou-se a distância entre os centros de massa dos agentes ao longo do tempo. Embora essa métrica não represente diretamente a violação de volume (por ser apenas um indicador escalar), ela serve como referência complementar. A Figura 6.15 apresenta a distância euclidiana entre os pares de agentes, evidenciando que, mesmo nas aproximações, o planejador ajusta as trajetórias para evitar colisões, validando o funcionamento da formulação baseada em politopos e disjunção lógica.

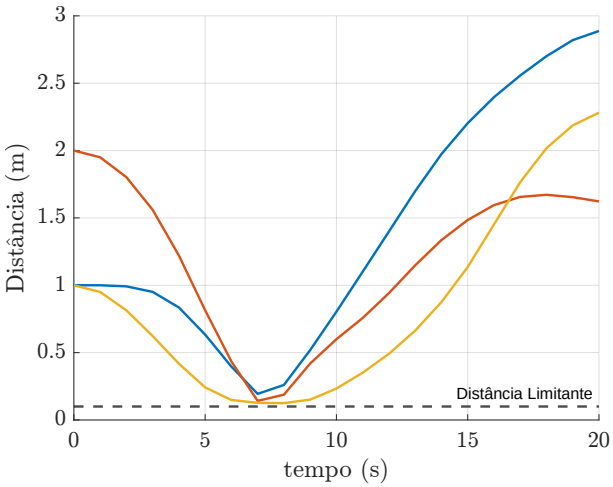
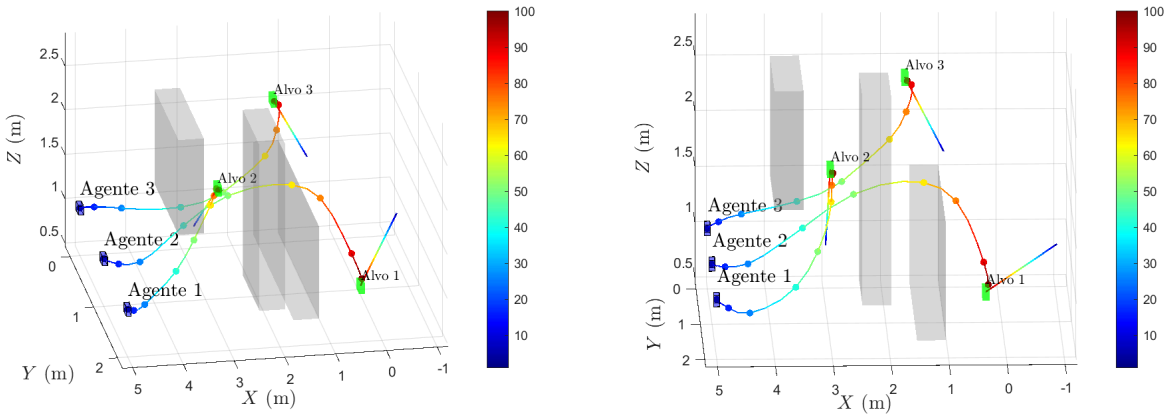



FIGURA 6.15 – Distância entre os centros de massa dos agentes durante a missão. Embora a restrição de anticolisão seja formulada sobre os contornos dos politopos, o monitoramento da distância entre posições ajuda a verificar o afastamento geral entre os agentes. Nenhuma trajetória levou a sobreposição, conforme validado pela formulação. Legenda: — Agente 1 – Agente 2, — Agente 1 – Agente 3, — Agente 2 – Agente 3.

No segundo experimento com obstáculos móveis, a separação mínima entre os volumes dos agentes foi ampliada para $2d_a^{i_o} = 0{,}3\,\text{m}$, elevando o nível de exigência da restrição de anticolisão. Todos os demais parâmetros do cenário foram mantidos constantes em relação ao teste anterior, incluindo as posições iniciais dos agentes, os alvos atribuídos e a presença de três obstáculos fixos no ambiente.

A imposição de uma separação maior entre os politopos reduz a liberdade de navegação em regiões congestionadas e exige que o otimizador gere trajetórias mais conservadoras. Essa mudança permite investigar o impacto direto da expansão dos volumes de exclusão sobre a coordenação dos agentes, o tempo de trajetória e o aproveitamento do espaço compartilhado.

A Figura 6.16 apresenta as simulações em duas perspectivas. Observa-se que os trajetos planejados são mais espaçados, e as curvas realizadas pelos agentes tendem a ser mais suaves e amplas. Em regiões onde a densidade de obstáculos limita o espaço navegável, os agentes ajustam suas rotas de forma coordenada, mantendo a separação exigida ao longo de toda a execução.




(1). (2).

FIGURA 6.16 – Simulação com três agentes e três obstáculos fixos, sob restrição de separação entre volumes de $2d_a^{i_o} = 0{,}3\,\text{m}$. As trajetórias planejadas respeitam a restrição poliedral de anticolisão, mesmo em regiões críticas. A coloração representa o avanço no tempo dentro do horizonte de predição. Legenda: ■ Agente, ○ Posição, ■ Alvo, ■ Obstáculo.

A Figura 6.17 apresenta a distância entre os centros dos agentes ao longo do tempo. As curvas indicam que os agentes mantêm distâncias superiores ao limite de 0,3 m, validando o efeito prático da restrição de não interseção imposta no modelo.

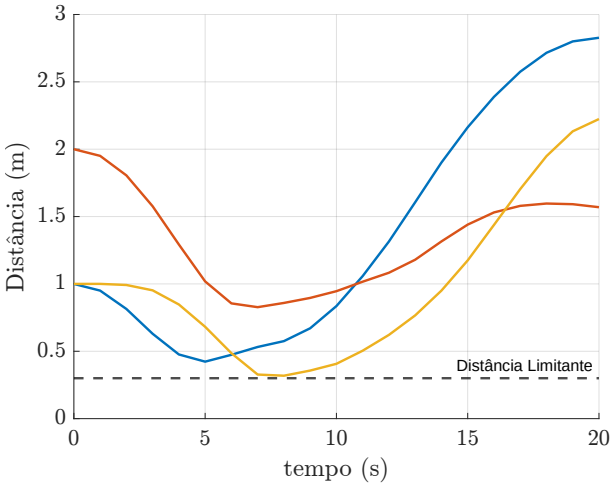
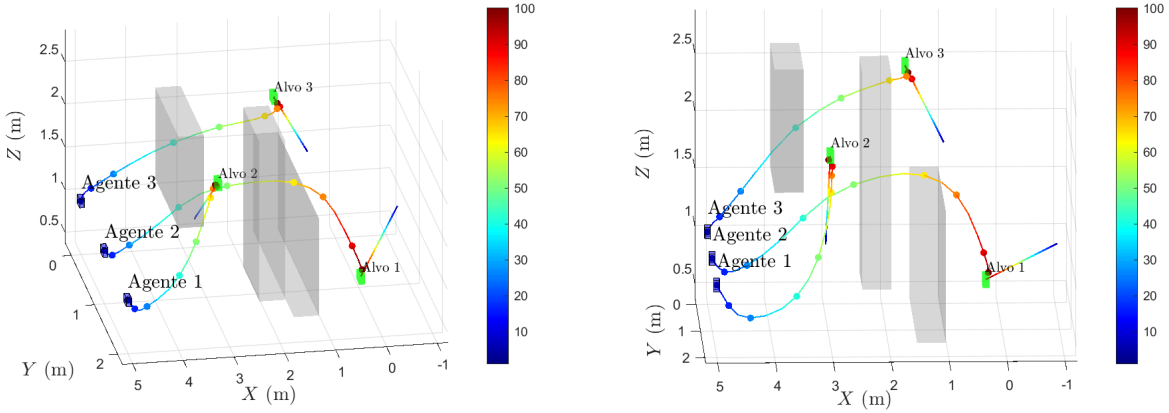



FIGURA 6.17 – Distância entre os centros de massa dos agentes durante a simulação com separação poliedral mínima de $2d_a^{io} = 0{,}3$ m. A linha tracejada representa esse limite. Nenhuma violação foi observada. Legenda: — Agente 1 – Agente 2, — Agente 1 – Agente 3, — Agente 2 – Agente 3.

No terceiro e último experimento, a separação mínima entre os volumes dos agentes foi elevada para $2d_a^{io} = 0{,}5\,\text{m}$, impondo uma restrição espacial ainda mais rigorosa ao otimizador. Essa configuração representa um cenário mais conservador de segurança, desafiando o planejador a manter uma distância ampliada entre os agentes em todas as etapas da missão.

Todos os demais parâmetros foram mantidos idênticos aos testes anteriores, incluindo as posições iniciais dos três agentes, os alvos atribuídos e a presença de três obstáculos fixos. O objetivo é observar como o sistema se adapta a uma restrição de não interseção mais severa, mantendo a viabilidade da missão.

A Figura 6.18 apresenta as trajetórias planejadas, com maior separação exigida, nota-se que os caminhos gerados são ainda mais espaçados, evitando regiões compartilhadas e garantindo ampla margem entre os volumes representados pelos politopos. As rotas mantêm fluidez e respeitam as restrições impostas pela geometria do ambiente e pelas zonas de exclusão entre os agentes.




(1). (2).

FIGURA 6.18 – Simulação com três agentes e três obstáculos fixos, sob restrição poliedral de $2d_a^{io} = 0{,}5\,\text{m}$. A separação mais exigente entre os volumes dos agentes resultou em trajetórias mais distribuídas e rotas conservadoras. A coloração representa a evolução temporal ao longo do horizonte de predição. Legenda: ■ Agente, ○ Posição, ■ Alvo, ■ Obstáculo.

A Figura 6.19 apresenta a distância entre os centros dos agentes durante a simulação. As curvas mostram que os agentes se mantiveram com folga acima do limite de 0,5 m ao longo de toda a missão.

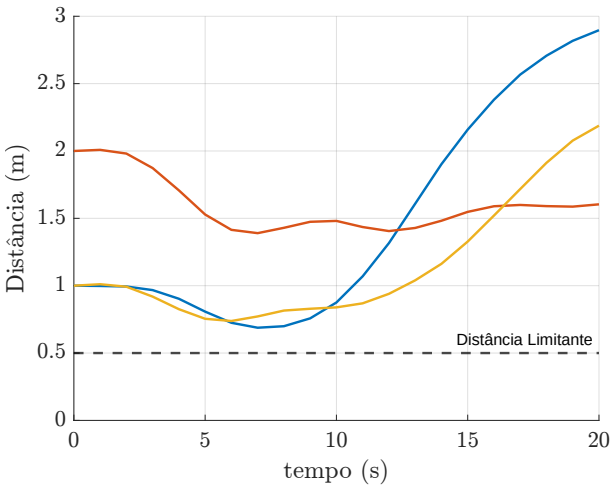



FIGURA 6.19 – Distância entre os centros dos agentes com separação mínima poliedral de $2d_a^{io} = 0{,}5\,\text{m}$. As trajetórias foram planejadas de forma a respeitar a restrição de não interseção. Legenda: — Agente 1 – Agente 2, — Agente 1 – Agente 3, — Agente 2 – Agente 3.

Esse terceiro teste demonstra que, mesmo com uma zona de exclusão expandida entre os agentes, o planejador é capaz de cumprir os objetivos da missão com rotas viáveis e seguras. A restrição poliedral imposta nos modelos de otimização mostrou-se eficaz na prevenção de colisões, mesmo sob configurações espaciais mais desafiadoras.

## 6.4 Modelagem do Consumo Energético

Nesta análise, avalia-se o comportamento do modelo de bateria integrado ao planejamento de trajetória. O modelo considera dois fatores principais como determinantes do consumo energético: o esforço da aceleração e o tempo de operação. Ambos os elementos são computados dinamicamente a cada iteração do otimizador, refletindo com maior fidelidade o impacto físico das ações de controle e da permanência em voo sobre a carga disponível, a qual tem valor mínimo de bateria atribuído como 1% no modelo do agente.

Para o primeiro cenário, foi considerado um único agente (Figura 6.20), inicialmente com $c_1 = 100\%$. A simulação incorpora as restrições dinâmicas dos agentes, enquanto o modelo de bateria é atualizado em tempo real durante a execução da trajetória.

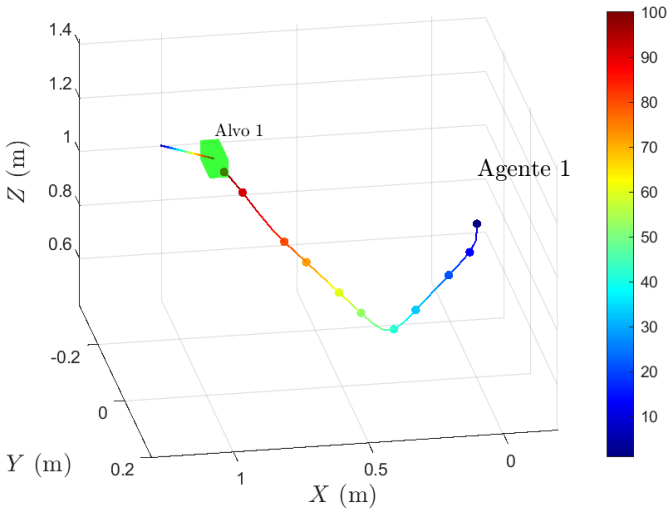



FIGURA 6.20 – Visualização das posições simuladas do agente e do alvo. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

A Figura 6.21 apresenta a evolução do consumo da bateria ao longo da missão. Observa-se uma redução progressiva do nível de energia, coerente com a aplicação contínua de esforços de controle para deslocamento até o alvo. Esse resultado apresenta a correta integração funcional entre o modelo energético e a lógica de planejamento, validando sua aplicabilidade em contextos futuros de restrição energética e decisões de alocação baseadas em autonomia residual.

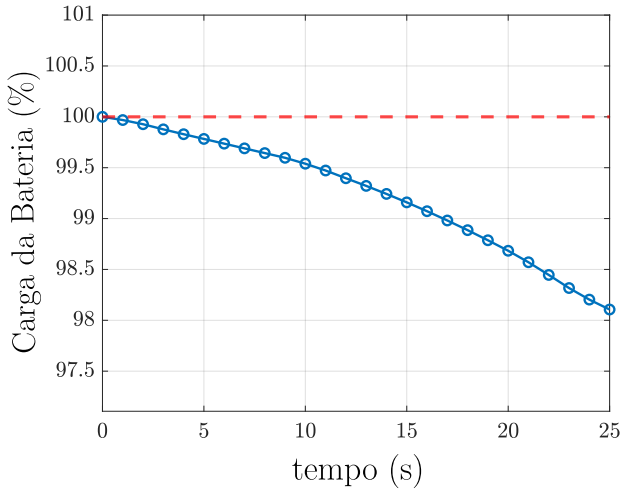



FIGURA 6.21 – Evolução da carga remanescente da bateria ao longo da trajetória com um agente. O modelo considera o esforço de controle e o tempo de operação. Legenda: ○ Carga remanescente ao longo do tempo e --- Bateria inicial do agente.

No segundo cenário, avalia-se o comportamento do modelo de bateria em uma missão envolvendo dois agentes, cada um designado a atingir um alvo distinto, como visto na Figura 6.22. O Agente 1 é inicializado com $c_1 = 100\%$, enquanto o Agente 2 parte com $c_2 = 80\%$. Essa configuração permite investigar a influência das condições iniciais de energia no perfil de consumo ao longo da missão.

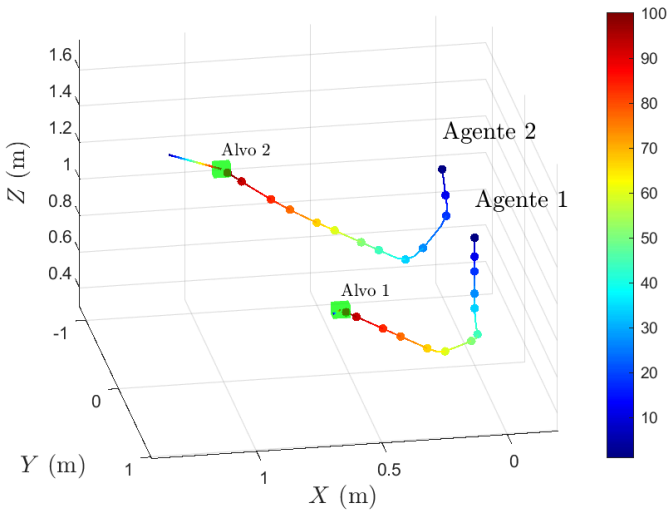



FIGURA 6.22 – Visualização das posições simuladas dos dois agentes e dos dois alvos. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

A Figura 6.23 apresenta a evolução do consumo energético de cada agente ao longo do tempo. Nota-se que o Agente 2, mesmo com menor carga inicial, é capaz de concluir sua missão com sucesso.

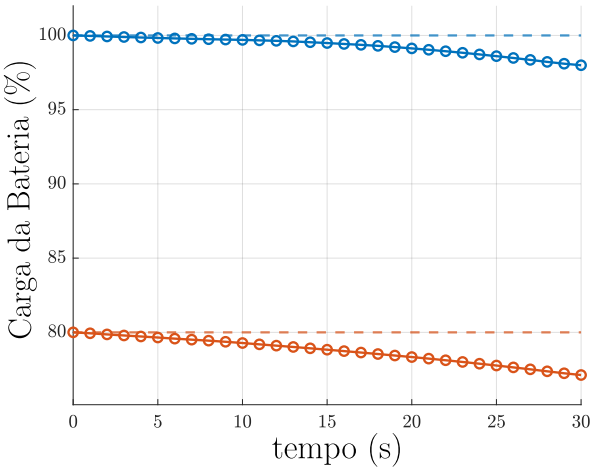



FIGURA 6.23 – Carga remanescente dos dois agentes durante a execução da missão. O Agente 1 inicia com $c_1 = 100\%$ e o Agente 2 com $c_2 = 80\%$ de carga disponível. Legenda: ○ Carga remanescente do agente 1, --- Bateria inicial do agente 1, ○ Carga remanescente do agente 2 e --- Bateria inicial do agente 2.

No último cenário com três agentes, avaliou-se o desempenho do planejador sob diferentes condições iniciais de energia. O Agente 1 iniciou a missão com $c_1 = 100\%$ da carga, o Agente 2 com $c_2 = 80\%$ e o Agente 3 com $c_3 = 85\%$. A Figura 6.24 apresenta a visualização gráfica desse cenário.

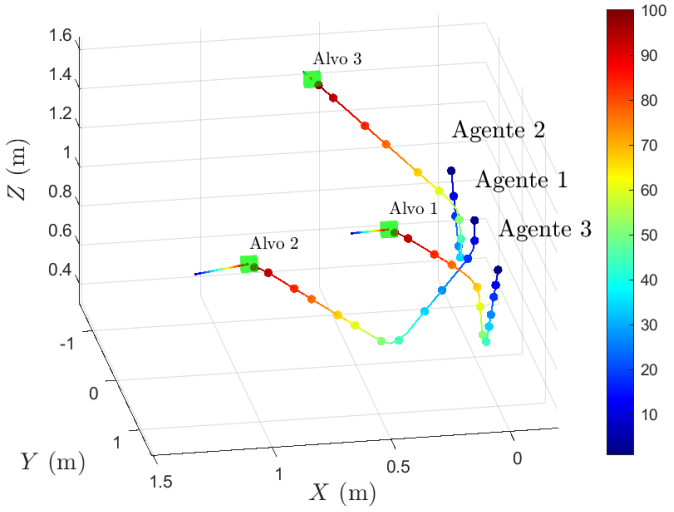



FIGURA 6.24 – Visualização das posições simuladas dos três agentes e dos três alvos. A coloração ao longo das trajetórias indica a progressão temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição e ■ Alvo.

A Figura 6.25 apresenta a carga remanescente de cada agente ao longo da missão.

Observa-se que o consumo energético é compatível com as trajetórias executadas, respeitando as restrições de energia estabelecidas para cada agente.

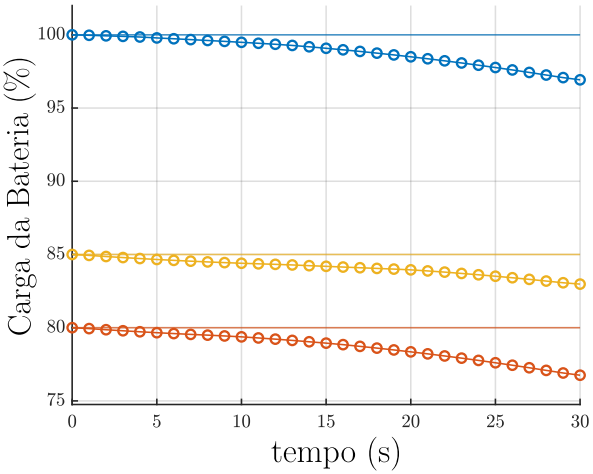



FIGURA 6.25 – Carga remanescente dos três agentes com diferentes condições iniciais. O otimizador adapta o planejamento de cada trajetória conforme a disponibilidade energética individual. Legenda: ○ Carga remanescente do agente 1,--- Bateria inicial do agente 1, ○ Carga remanescente do agente 2, --- Bateria inicial do agente 2, ○ Carga remanescente do agente 3 e --- Bateria inicial do agente 3.

A integração do modelo energético dos agentes ao processo de planejamento permite incorporar ao planejador a informação sobre o nível de carga dos agentes de forma explícita. Isso possibilita que o otimizador leve em conta a autonomia restante de cada agente na definição das trajetórias, priorizando opções que respeitem os limites energéticos estabelecidos. Dessa forma, o modelo contribui para aumentar a previsibilidade do comportamento do sistema, especialmente em missões cooperativas, onde decisões mais equilibradas e sustentáveis dependem da gestão eficiente dos recursos energéticos. Com essa base, a próxima etapa do planejamento passou a considerar não apenas a viabilidade energética, mas também a necessidade de alinhamento dinâmico com o alvo. Para isso, foi incorporada uma restrição de velocidade terminal, garantindo que o agente não apenas alcance o alvo, mas o faça com compatibilidade vetorial, permitindo manobras subsequentes como acompanhamento, bloqueio ou interceptação contínua.

## 6.5 Avaliação da Restrição de Velocidade Terminal na Interceptação de Alvos

Em cenários nos quais o objetivo do agente não é neutralizar o alvo, mas sim perseguí-lo ou acompanhá-lo após a interceptação, é fundamental que sua velocidade terminal esteja alinhada ou próxima à do alvo no momento do encontro. Essa restrição visa garantir continuidade no movimento, evitando desacelerações abruptas ou comportamentos incompatíveis com estratégias de rastreamento dinâmico.

Para avaliar o impacto dessa condição, foram realizados testes simulados com a imposição da restrição de velocidade terminal. A análise foca na transição entre a interceptação e o acompanhamento contínuo do alvo, observando a suavidade e a viabilidade das trajetórias planejadas sob diferentes configurações de controle. A seguir, são apresentados os resultados que demonstram como a inclusão dessa restrição contribui para um comportamento operacionalmente coerente em missões de vigilância ou defesa com múltiplos agentes.

A Figura 6.26 ilustra um cenário em que o agente deve interceptar um alvo em movimento ao longo de uma trajetória diagonal. Nesse contexto, além de alcançar a posição do alvo, o agente deve alinhar sua velocidade final à do alvo, garantindo continuidade para ações subsequentes, como acompanhamento ou coleta de informações.

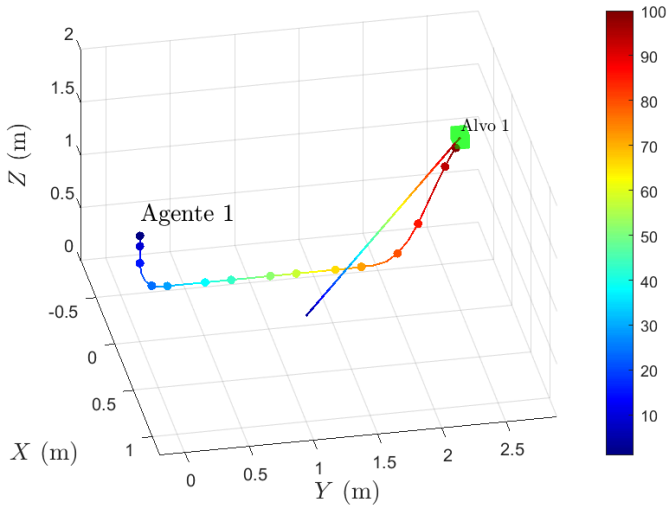



FIGURA 6.26 – Posições simuladas do agente e do alvo no cenário em que o alvo segue uma trajetória diagonal à frente do agente. O agente deve interceptá-lo com alinhamento vetorial de velocidade. A coloração ao longo das trajetórias representa a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição simulada, ■ Alvo.

Para isso, foi incorporada ao problema de otimização a restrição de velocidade ter-

minal (4.26), que força a diferença entre os vetores de velocidade do agente e do alvo a ser mínima no instante final do planejamento. A Figura 6.27 apresenta a evolução da norma $\|\mathbf{v}_a^i - \mathbf{v}_t^j\|_\infty$, evidenciando que, embora ocorram variações ao longo da trajetória, o controle é capaz de reduzir significativamente essa diferença nos instantes finais. Isso confirma a eficácia da abordagem em promover uma interceptação suave e condizente com a continuidade da missão.

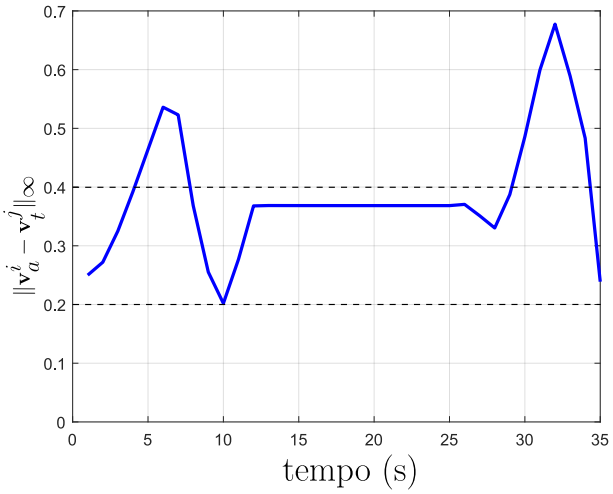



FIGURA 6.27 – Evolução da norma da diferença entre a velocidade do agente $\mathbf{v}_a^i$ e a do alvo $\mathbf{v}_t^j$ ao longo do horizonte de planejamento. O controle busca minimizar essa diferença no instante final, promovendo interceptação com velocidade terminal compatível.

No segundo cenário, o alvo realiza uma trajetória oblíqua em direção à região central protegida, cruzando-a pela parte superior no eixo $z$. Nesse caso, o agente deve executar uma manobra de retorno para se posicionar adequadamente, de modo a realizar a interceptação com alinhamento vetorial de velocidades.

A Figura 6.29 mostra a evolução da diferença de velocidade ao longo do tempo. Observa-se que o otimizador ajusta a trajetória do agente para minimizar essa diferença no instante final, promovendo uma interceptação suave e compatível com a velocidade do alvo.

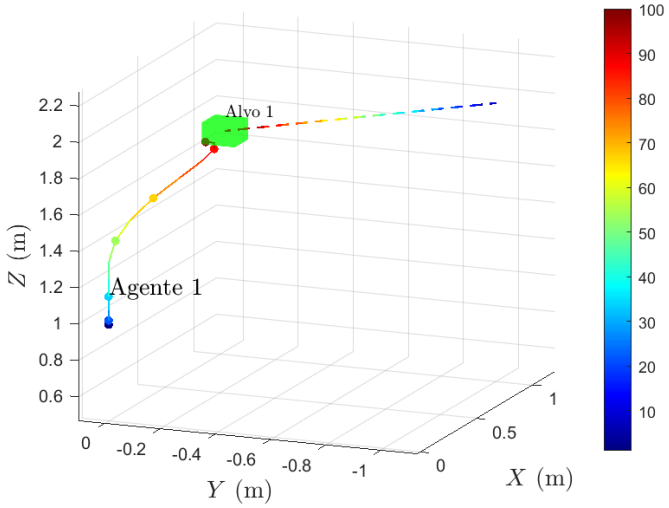



FIGURA 6.28 – Posições simuladas do agente e do alvo em um cenário em que o alvo cruza a região central da zona protegida por cima, no eixo $z$. O agente reposiciona-se para interceptá-lo com alinhamento de velocidades. A coloração ao longo das trajetórias representa a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição simulada, ■ Alvo.

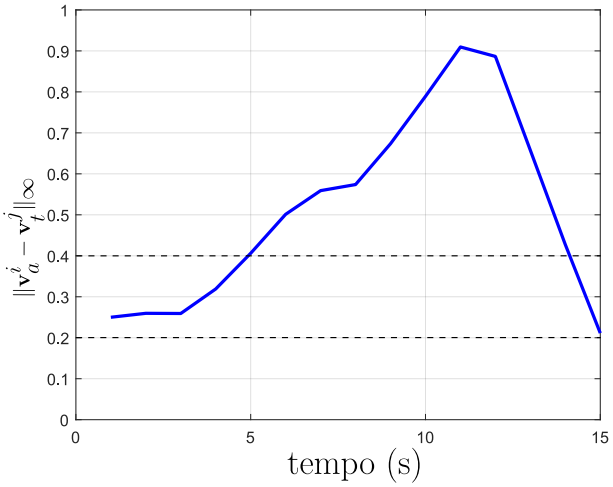



FIGURA 6.29 – Evolução da norma da diferença entre a velocidade do agente $\mathbf{v}_a^i$ e a do alvo $\mathbf{v}_t^j$ no cenário em que o alvo cruza a região protegida superiormente. O controle reduz essa diferença ao final da trajetória.

No terceiro cenário, considera-se que o alvo já se encontra próximo da zona protegida, cruzando o ponto central por cima. O agente, localizado abaixo, reconhece que uma interceptação direta exigiria elevado esforço energético e opta por uma estratégia de aproximação posterior ao cruzamento. O otimizador calcula uma trajetória que resulta na interceptação após a passagem do alvo, com realinhamento gradual do vetor de velocidade.

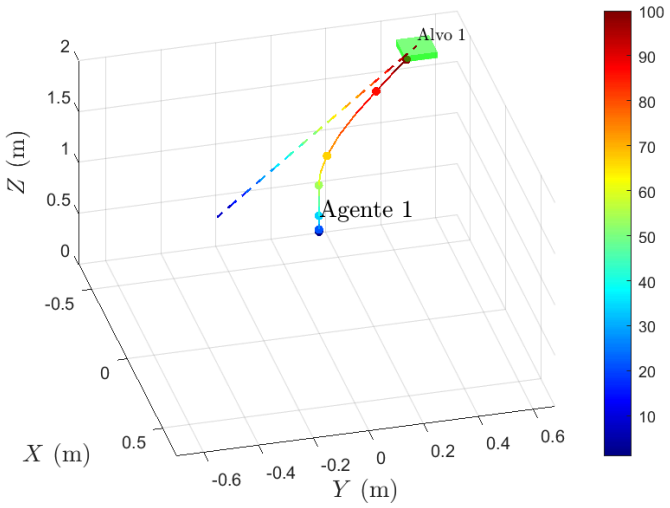



FIGURA 6.30 – Posições simuladas do agente e do alvo em um cenário onde o alvo atravessa a região protegida por cima. O agente, posicionado abaixo, intercepta o alvo após o cruzamento, ajustando sua velocidade à do alvo. A coloração ao longo das trajetórias representa a evolução temporal em percentual do horizonte de predição (0 a 100%). Legenda: ○ Posição simulada, ■ Alvo.

A Figura 6.31 apresenta a redução progressiva da diferença de velocidade, indicando que o otimizador é capaz de ajustar sua estratégia para manter eficiência energética sem comprometer a interceptação.

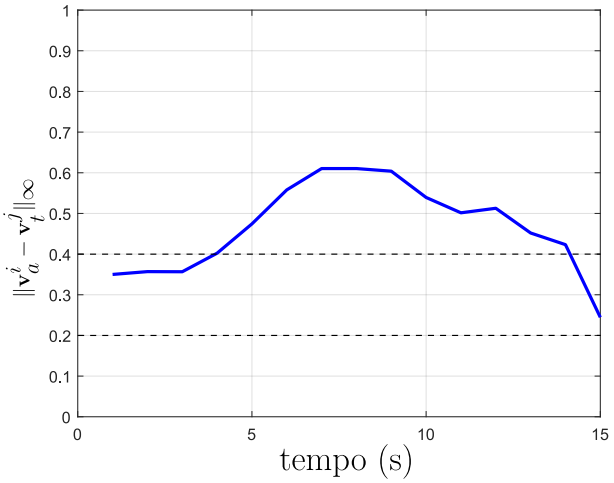



FIGURA 6.31 – Evolução da norma da diferença entre a velocidade do agente $\mathbf{v}_a^i$ e a do alvo $\mathbf{v}_t^j$ no cenário com interceptação após o cruzamento. O controle ajusta a velocidade terminal do agente para garantir alinhamento.

Os resultados evidenciam a eficácia da abordagem proposta para o planejamento de interceptações com alinhamento vetorial de velocidades, mesmo em cenários dinâmicos e restritos. A capacidade dos agentes de adaptar suas trajetórias com base em restrições físicas e energéticas garante interceptações eficientes e continuidade operacional. Ao

integrar essa lógica ao otimizador, o planejador de trajetórias passa a tomar decisões mais inteligentes, fundamentadas não apenas na viabilidade da trajetória, mas também na sustentabilidade da missão ao longo do tempo.

## 6.6 Avaliação em um Cenário de Defesa

Nesta seção, avalia-se o desempenho do planejador de trajetórias em um cenário inspirado no projeto CTEDS, voltado para aplicações de defesa aérea em cenário de ataque. Nesse contexto, destaca-se a lógica de tomada de decisão como uma das principais contribuições deste trabalho. A alocação dinâmica de agentes aos alvos é realizada com base em critérios múltiplos, considerando tanto o nível de carga de bateria de cada agente, quando o tempo de missão, de forma a garantir eficiência e viabilidade energética. O cenário é avaliado graficamente a seguir, com dois casos distintos que ilustram como variações no estado energético impactam diretamente as decisões de alocação.

Para esse cenário os limites de posição foram definidos como $[-1{,}8,\ 1{,}8]$ m nos eixos $x$ e $y$, e $[0{,}5,\ 1{,}8]$ m no eixo $z$. As restrições de velocidade foram mantidas em $[-0{,}2,\ 0{,}2]$ m/s, e as de aceleração em $[-0{,}8,\ 0{,}8]$ m/s$^2$ em cada eixo.

Os três agentes foram posicionados inicialmente nas coordenadas $(0,\ y,\ 1)$ m, com $y = 0,\ -1,\ 1$, todos com velocidades iniciais nulas. Essa configuração permite avaliar a alocação e execução de trajetória dentro de um espaço restrito, respeitando os limites operacionais e energéticos de cada agente.

### 6.6.1 Caso 1 – Passo Inicial

Neste primeiro caso, a missão é realizada com três agentes e três alvos posicionados aleatoriamente no ambiente. Para este cenário, os agentes foram inicializados com níveis de bateria: o Agente 1 com $c_1 = 100\%$, o Agente 2 com $c_2 = 80\%$ e o Agente 3 com $c_3 = 100\%$ da carga. Com o conjunto de alvos definidos como $\{\text{Alvo } 1, \text{Alvo } 2, \text{Alvo } 3\}$, e os agentes como $\{\text{Agente } 1, \text{Agente } 2, \text{Agente } 3\}$, a alocação final obtida foi: o Agente 1 foi designado ao Alvo 1, o Agente 2 ao Alvo 3, e o Agente 3 ao Alvo 2.

A Figura 6.32 apresenta a trajetória resultante da alocação realizada pelo otimizador e a Figura 6.35 a bateria dos respectivos agentes. A decisão de qual agente deve interceptar qual alvo foi tomada com base em dois critérios principais: o tempo total da missão, e a disponibilidade energética de cada agente. Como resultado, o planejador de trajetória priorizou a atribuição de alvos de forma a minimizar o custo da missão.

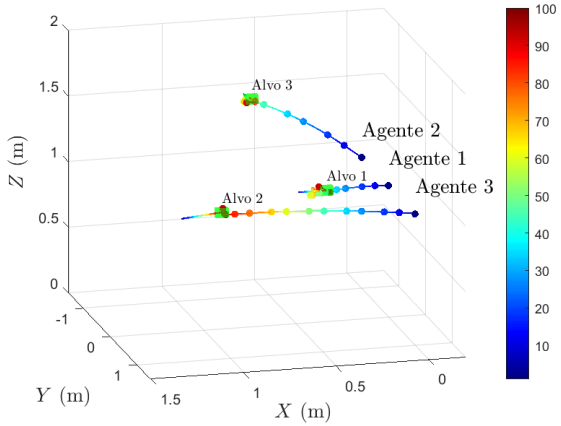
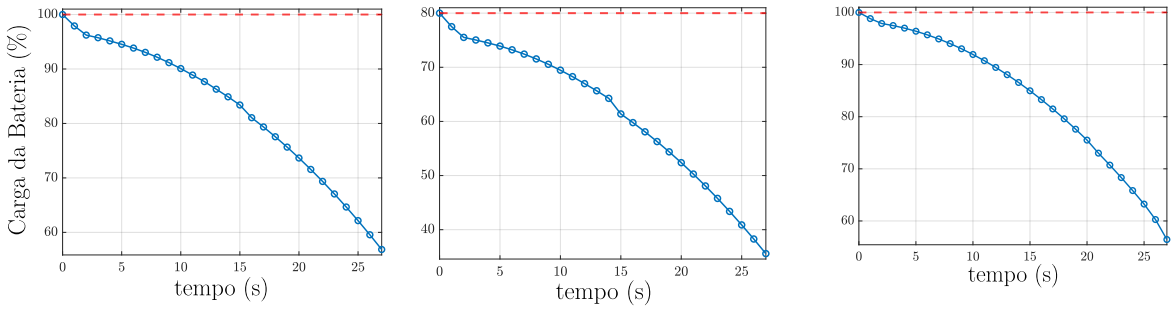



FIGURA 6.32 – Cenário considerando alocação baseada em tempo de missão e nível de bateria. Missão com três agentes e três alvos. Legenda: ○ Posição e ■ Alvo.




(1) Agente 1 (2) Agente 2 (3) Agente 3

FIGURA 6.33 – Evolução da carga remanescente da bateria ao longo da trajetória para cada agente. Legenda: ○ Carga remanescente ao longo do tempo e --- Bateria inicial do agente.

### 6.6.2 Caso 2 – Efeito da Modificação do Nível de Bateria no Processo de Alocação

Neste segundo cenário, manteve-se a mesma configuração espacial de agentes e alvos do Caso 1. A única modificação introduzida foi no nível de carga do Agente 3, que foi ajustado de $c_3 = 100\%$ para $c_3 = 45\%$, reduzindo a disponibilidade energética.

Essa alteração foi suficiente para induzir uma nova alocação de tarefas, resultado direto do mecanismo de decisão que leva em conta tanto o tempo quanto a energia remanescente de cada agente. A estratégia de otimização reavaliou o espaço de possibilidades e determinou uma nova atribuição de alvos mais eficiente à luz do estado energético atualizado. Com isso, o Agente 1 foi alocado ao Alvo 2, o Agente 2 ao Alvo 3, e o Agente 3 ao Alvo 1.

A Figura 6.34 apresenta as trajetórias executadas por cada agente e a Figura 6.35 a

bateria dos respectivos agentes. Em comparação com o cenário anterior, observa-se que o Agente 3 foi reatribuído ao Alvo 1, evidenciando a adaptabilidade do planejador de trajetórias na decisão diante de alterações internas no estado dos agentes. Este comportamento ilustra a capacidade do planejador proposto em incorporar informações e definir decisões, promovendo realocação eficiente com base em critérios operacionais dinâmicos.

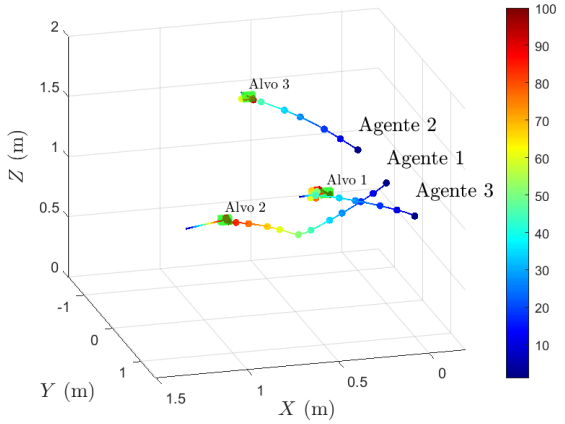
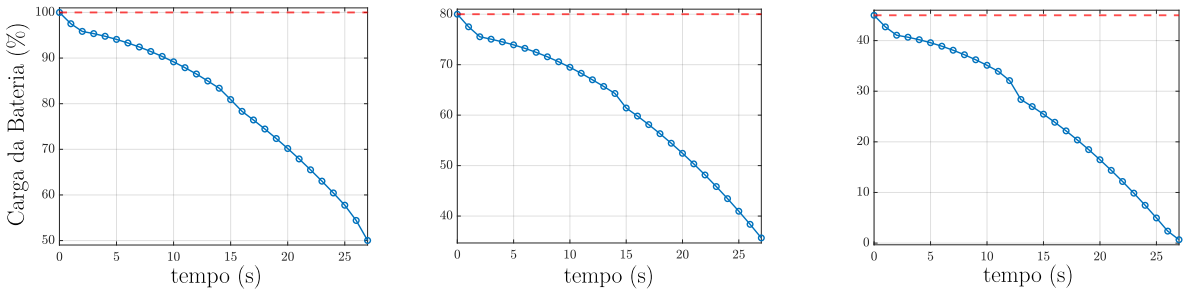



FIGURA 6.34 – Cenário do caso 2 considerando alocação baseada em tempo de missão e nível de bateria, com ajuste da carga inicial $c_3 = 45\%$. Missão com três agentes e três alvos. Legenda: ○ Posição e ■ Alvo.




(1) Agente 1 (2) Agente 2 (3) Agente 3

FIGURA 6.35 – Evolução da carga remanescente da bateria ao longo da trajetória para cada agente do caso 2. Legenda: ○ Carga remanescente ao longo do tempo e --- Bateria inicial do agente.

A sequência de testes sob diferentes condições permitiu avaliar a capacidade do planejador de trajetórias em coordenar, de forma eficiente, a alocação e execução de trajetórias multiagente. A integração da lógica de decisão ao otimizador mostrou-se essencial para adaptar o comportamento dos agentes a variáveis operacionais como tempo de missão e níveis de energia. Os resultados reforçam a viabilidade da abordagem para aplicações reais, e o Capítulo 7 apresenta sua demonstração prática com drones físicos.

# 7 Demonstração Experimental

Este capítulo apresenta a validação experimental do planejador de trajetórias proposto em um ambiente físico controlado. O capítulo está estruturado em duas partes complementares: na primeira, descreve-se a arquitetura experimental, incluindo a arena de realidade mista, bem como a infraestrutura de hardware e software empregada; na segunda, são discutidos os resultados obtidos nos testes de voo com agentes reais, com ênfase na precisão do rastreamento das trajetórias, na aderência às restrições operacionais e no desempenho global do otimizador.

## 7.1 Descrição do Aparato Experimental

A demonstração do planejador proposto foi conduzida em uma arena de voo controlada, projetada para experimentos com drones em ambientes *indoor*. Tal arena é descrita em (CRUZ *et al.*, 2024), onde se propõe uma infraestrutura de realidade mista voltada à avaliação de métodos de orientação e controle de voo. Essa infraestrutura experimental é composta por drones Crazyflie (BITCRAZE, 2013), sistema de captura de movimento OptiTrack (OPTITRACK, 1996), e uma integração de software desenvolvida em MATLAB® (MATHWORKS, 2024), Python e Unity® 3D (Unity Technologies, 2023), conforme apresentado no diagrama da Figura 7.1, permitindo avaliar métodos de controle com drones reais, simulados ou uma combinação de ambos.

A arena experimental opera em dois modos distintos: (i) modo de simulação, no qual tanto os drones quanto os obstáculos são modelados numericamente; e (ii) modo de realidade mista, em que drones reais interagem com obstáculos simulados ou outros drones simulados em um ambiente virtual, possibilitando atuação cooperativa e escalabilidade no número de agentes no cenário. Em ambos os casos, a visualização tridimensional é realizada por meio de um ambiente desenvolvido em Unity 3D (Figura 7.2), que exibe em tempo real a posição dos drones e dos obstáculos virtuais, com comunicação via protocolo UDP.

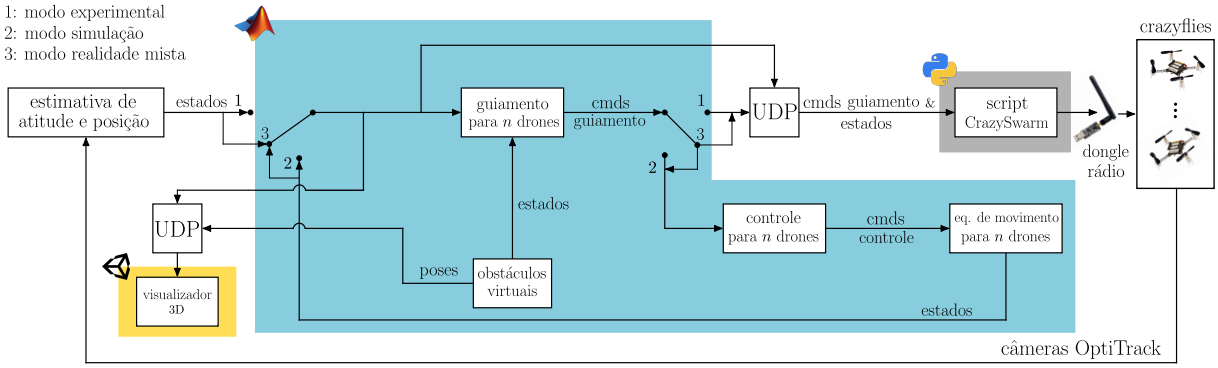



FIGURA 7.1 – Diagrama da estrutura de software da arena experimental em realidade mista. A arquitetura modular permite alternar entre os modos de simulação pura e realidade mista com facilidade (CRUZ *et al.*, 2024).

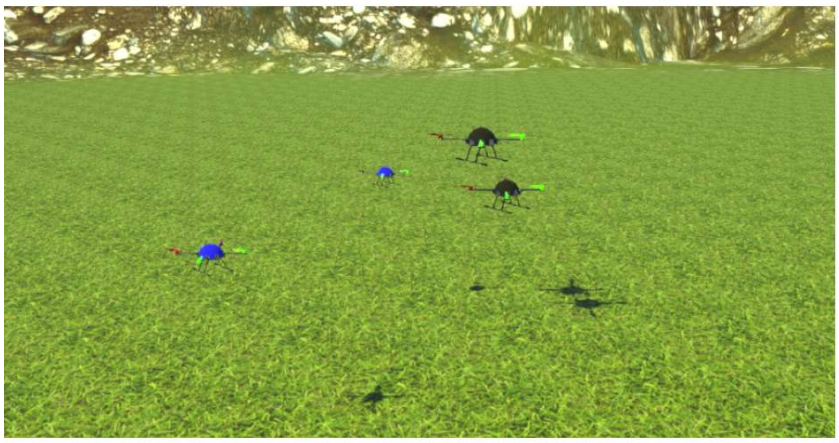


FIGURA 7.2 – Visualização da arena no ambiente Unity 3D. Drones pretos representam os agentes guiados, enquanto os drones azuis representam obstáculos virtuais (CRUZ *et al.*, 2024).

No modo experimental, o controle externo dos drones é realizado a partir de um script MATLAB®, que recebe as posições dos drones por meio do OptiTrack, responsável por fornecer essas informações em alta frequência e precisão (OPTITRACK, 1996). As informações são então processadas e enviadas a um script em Python que utiliza a biblioteca Crazyswarm para comunicação via rádio com os drones reais (PREISS *et al.*, 2017). Essa arquitetura de hardware é ilustrada na Figura 7.3.

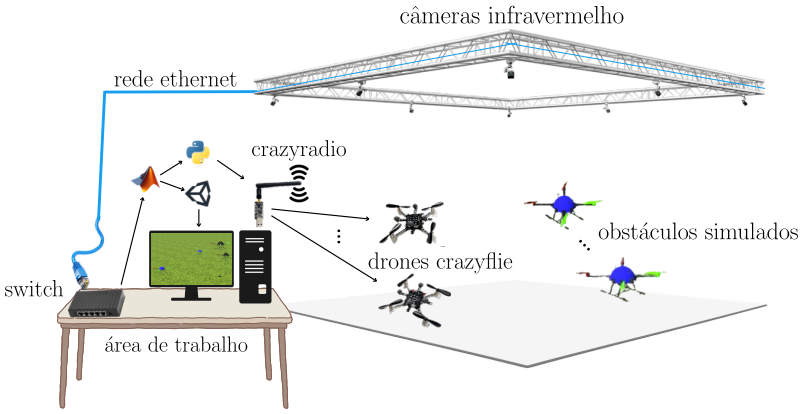



FIGURA 7.3 – Ilustração da configuração física da arena experimental (CRUZ *et al.*, 2024).

Para que o sistema de captura de movimento identifique corretamente a posição e a orientação de cada drone, é necessário configurar um corpo rígido no software de rastreamento *Motive*. Isso é feito com a fixação de marcadores reflexivos sobre a estrutura do drone Crazyflie, de modo que o conjunto seja reconhecido como uma única entidade pelo OptiTrack. A Figura 7.4 ilustra essa configuração.

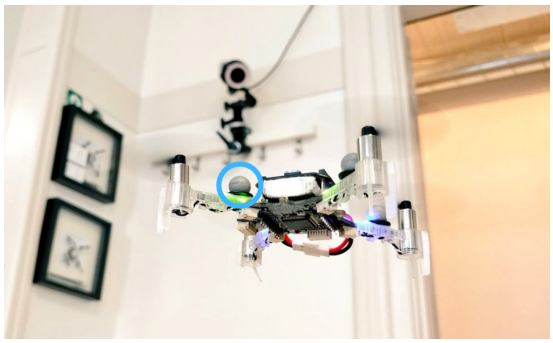


FIGURA 7.4 – Drone Crazyflie com marcadores reflexivos utilizados para rastreamento de corpo rígido via OptiTrack (BITCRAZE, 2013).

A arena permite a realização de testes em cenários com múltiplos obstáculos, sem comprometer a integridade física dos drones, uma vez que os obstáculos podem ser mantidos no domínio virtual. Essa configuração híbrida é particularmente adequada para avaliar algoritmos de planejamento de trajetória e controle em ambientes restritos e dinâmicos, como aqueles característicos de cenários de defesa.

Além da formulação do problema de planejamento de trajetórias, é essencial considerar o comportamento da malha de controle interna do guiamento dos drones, que impõe uma dinâmica de segunda ordem. O controlador de malha interna é responsável por garantir a estabilidade e a resposta do sistema a perturbações durante a execução da missão, regulando a posição do drone de acordo com os comandos de referência do planejador de

trajetórias, atuado de forma offline anteriormente ao experimento real. Essa dinâmica de segunda ordem é fundamental para assegurar que o drone siga as trajetórias previstas de maneira eficiente, ajustando-se rapidamente às variações no ambiente e nas condições de operação.

A integração com o método de Runge-Kutta de 4ª ordem é utilizada para realizar a simulação da dinâmica do drone no aparato experimental. Neste contexto, o input de controle $u^*$, gerado pelo planejador de trajetórias offline, é alimentado no modelo dinâmico do drone, garantindo a execução dos comandos de controle em tempo real. Para garantir precisão e estabilidade na simulação, é utilizado um filtro passa-baixa para suavizar as entradas e minimizar o ruído dos sinais de controle.

A condição inicial para a simulação é estabelecida pelas posições dos agentes no início da missão. A posição e a velocidade dos drones são determinadas pelo planejador de trajetórias, e essas variáveis são usadas como entrada para o modelo de Runge-Kutta de 4ª ordem, que realiza a integração numérica da equação de movimento do drone. Com isso, a dinâmica de segunda ordem é seguida de forma consistente, permitindo que o drone siga a trajetória planejada de maneira suave e precisa.

## 7.2 Resultados e Discussão

Esta seção apresenta os resultados experimentais obtidos com a execução do planejador de trajetórias proposto em diferentes configurações, escalando progressivamente a complexidade do cenário. As demonstrações incluem desde missões com um único agente até a execução cooperativa com múltiplos drones, integrando, inclusive, agentes simulados e reais em um ambiente de realidade mista. O objetivo é verificar o desempenho do planejador de trajetórias em condições próximas à aplicação real. Um vídeo dos experimentos em ambiente real está disponível em: `https://youtu.be/AemDSvZj_Ws`, oferecendo uma ilustração visual do comportamento do planejador de trajetórias durante a execução.

### 7.2.1 Demonstração com Um Drone Real

Como primeira etapa da avaliação experimental do planejador proposto, foi realizada uma demonstração com apenas um drone Crazyflie em operação, com o objetivo de verificar a capacidade da arena experimental em realizar o rastreamento preciso das posições de referência geradas offline. Essas posições foram obtidas a partir da solução do problema de otimização formalizado na Equação (4.31), parametrizado com os estados iniciais do agente e do alvo. O resultado forneceu uma sequência discreta de posições, geradas com frequência de amostragem de 5 Hz ($t_s = 0{,}2$ s).

Os parâmetros utilizados na formulação do problema de controle incluem limites operacionais de posição, velocidade e aceleração, definidos com base nas características físicas do drone e da arena experimental. Devido ao espaço físico disponível na arena de testes, foi necessário reduzir os limites de posição. Assim, a posição foi limitada ao intervalo de $[-1{,}8,\ 1{,}8]$ m no plano horizontal, com altura mínima de 0,5 m. A velocidade foi restringida ao intervalo $[-0{,}2,\ 0{,}2]$ m/s, enquanto a aceleração foi limitada entre $[-0{,}8,\ 1{,}0]$ m/s$^2$. O drone foi inicializado na posição $(0,\ 0,\ 1)$, com velocidades nulas.

Para garantir compatibilidade com a frequência de comunicação do drone Crazyflie, que opera a 100 Hz, foi necessário realizar a interpolação das posições geradas pela otimização, originalmente amostradas a 5 Hz ($t_s = 0{,}2$ s). O objetivo do processo foi aumentar a densidade de pontos das referências, preservando a suavidade e continuidade do movimento.

Utilizou-se o mesmo modelo dinâmico de segunda ordem criticamente amortecido para realizar a interpolação entre os pontos otimizados, gerando posições intermediárias com frequência de 100 Hz ($t_d = 0{,}01$ s). O número de pontos interpolados entre cada par de amostras consecutivas foi obtido pela razão $t_s/t_d = 20$, garantindo que a nova sequência tivesse a resolução necessária para o controle em tempo real.

Esse procedimento assegurou que as referências fossem compatíveis com a frequência exigida pela plataforma. A Figura 7.5 apresenta a comparação entre a trajetória planejada e a trajetória real executada, permitindo observar a capacidade de rastreamento do OptiTrack.

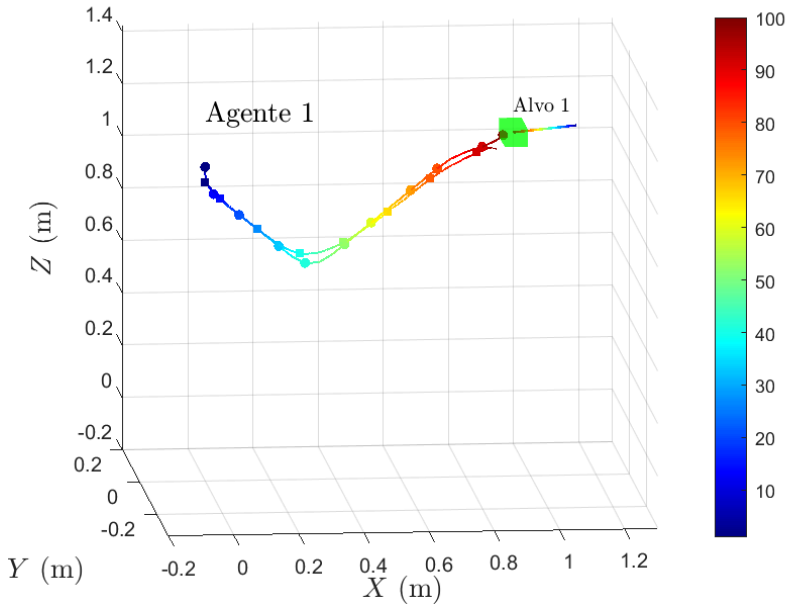



FIGURA 7.5 – Posições reais e otimizadas do agente na arena de voo para o experimento com um único drone. A trajetória real executada é comparada com a sequência de posições do agente gerada pela otimização. A coloração das trajetórias indica a evolução temporal da missão, de 0% a 100%. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo.

A Figura 7.6 apresenta os perfis de velocidade, aceleração e ação de controle (referência de posição) ao longo do tempo, em cada eixo do sistema de coordenadas. Os valores foram obtidos da solução do problema de otimização, considerando as restrições operacionais definidas previamente. Como pode ser observado, todas as grandezas permaneceram dentro dos limites impostos pelas restrições. A Figura 7.7 apresenta a evolução da carga remanescente da bateria ao longo do tempo durante a execução da missão.

Após a execução do experimento com o drone real, os dados de posição foram obtidos por meio do sistema de captura de movimento OptiTrack. A partir dessas medições, foi possível estimar as velocidades em cada eixo por diferenciação numérica dos sinais de posição. Com isso, foi realizada uma análise comparativa entre os comandos de posição e velocidade enviados ao agente e os dados efetivamente registrados durante o voo.

A Figura 7.8 apresenta, no lado esquerdo, as posições do agente capturadas em tempo real, e, no lado direito, os perfis de velocidade derivados das posições medidas. As curvas tracejadas representam os comandos de referência enviados ao drone, enquanto as curvas sólidas indicam os valores obtidos por meio do rastreamento.

A faixa sombreada em vermelho indica o intervalo correspondente à execução das posições de referência geradas pelo otimizador. O trecho anterior à faixa refere-se ao deslocamento inicial necessário para posicionar o drone na condição inicial para a manobra, enquanto o trecho posterior representa o retorno controlado do agente após atingir o ponto final da trajetória planejada.

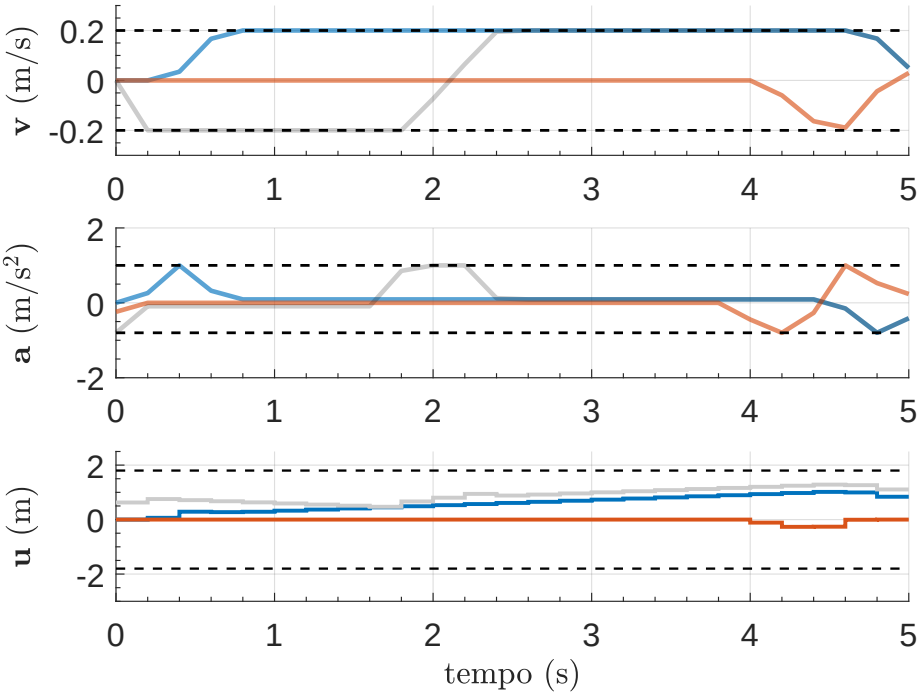
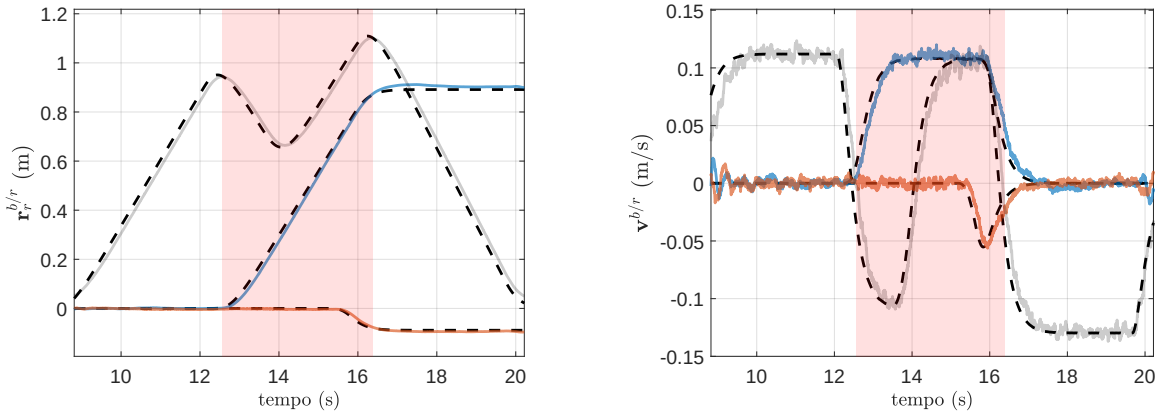



FIGURA 7.6 – Velocidades, acelerações e ações de controle do agente, obtidos durante a simulação do planejamento de trajetória offline. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições. Todos os valores permaneceram dentro dos limites definidos pelas restrições.




(1) Posição do agente.
(sistema de captura de movimento)

(2) Velocidade do agente.
(derivada da posição)

FIGURA 7.8 – Posições e velocidades do agente registradas pelo sistema de captura de movimento. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Comandos de posição gerados a partir dos estados de posição obtidos na solução do problema de otimização (Eq. (4.31)) e transmitidos aos drones por meio da arena experimental. A região sombreada em vermelho destaca o intervalo em que as posições otimizadas foram efetivamente aplicadas; os demais segmentos correspondem às fases de decolagem e pouso fora do planejamento.

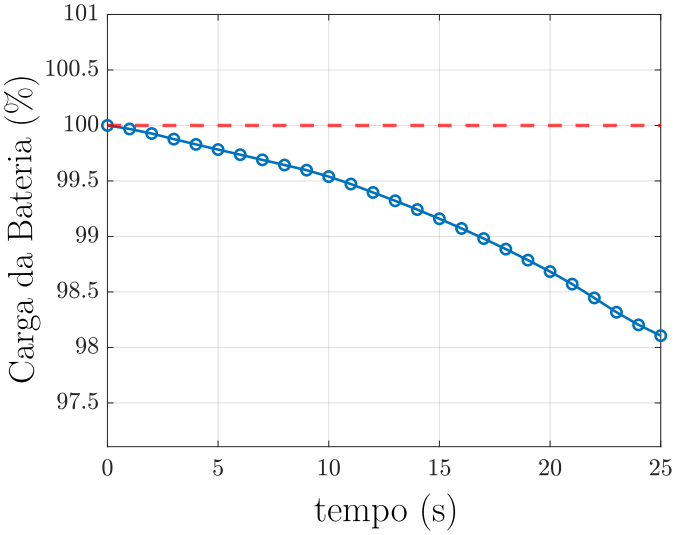



FIGURA 7.7 – Carga remanescente da bateria do agente com o modelo de bateria no planejamento de trajetória. Legenda: ○ Carga remanescente da bateria ao longo do tempo e --- Bateria inicial do agente. É possível observar a redução contínua da carga com base nas ações realizadas.

Observa-se que, durante o intervalo de rastreamento principal, o agente seguiu com boa precisão os comandos de posição e velocidade, apresentando resposta coerente com os sinais enviados pela arena experimental. As pequenas discrepâncias observadas podem ser atribuídas a atrasos na comunicação, distúrbios externos ou ruídos de medição.

### 7.2.2 Demonstração com Dois Drones Reais

Nesta etapa, foi realizada uma demonstração com dois drones Crazyflie operando simultaneamente em um cenário compartilhado. O objetivo foi avaliar a capacidade de realizar o rastreamento cooperativo de trajetórias de forma segura, respeitando as restrições dinâmicas impostas e sem colisões. Os parâmetros de controle utilizados foram os mesmos da demonstração anterior com um agente. A única diferença foi a adição de um segundo drone, com estado inicial definido como posição $(0,\ -1,\ 1)$ m e velocidades nulas.

As posições de referência foram geradas para cada agente, respeitando suas respectivas condições iniciais em um cenário cooperativo. A Figura 7.9 apresenta a comparação entre as posições simuladas e as posições reais registradas para ambos os agentes durante o experimento.

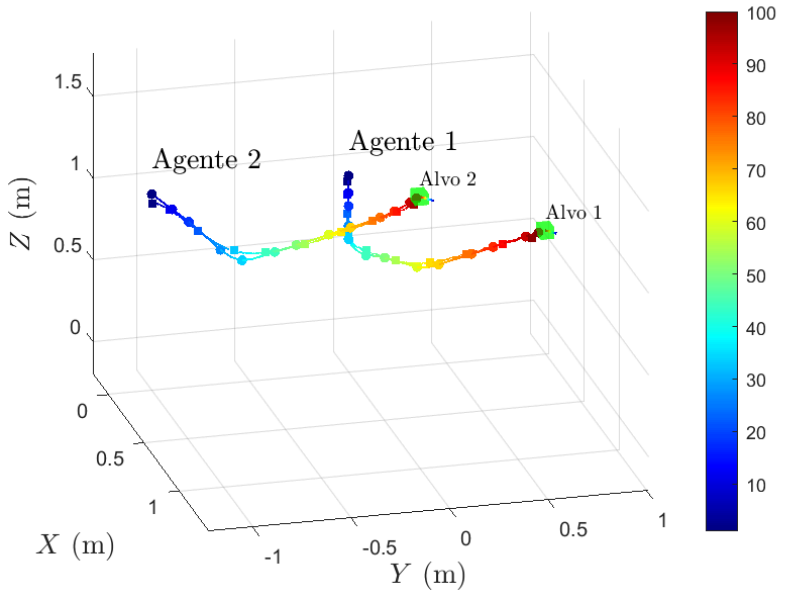
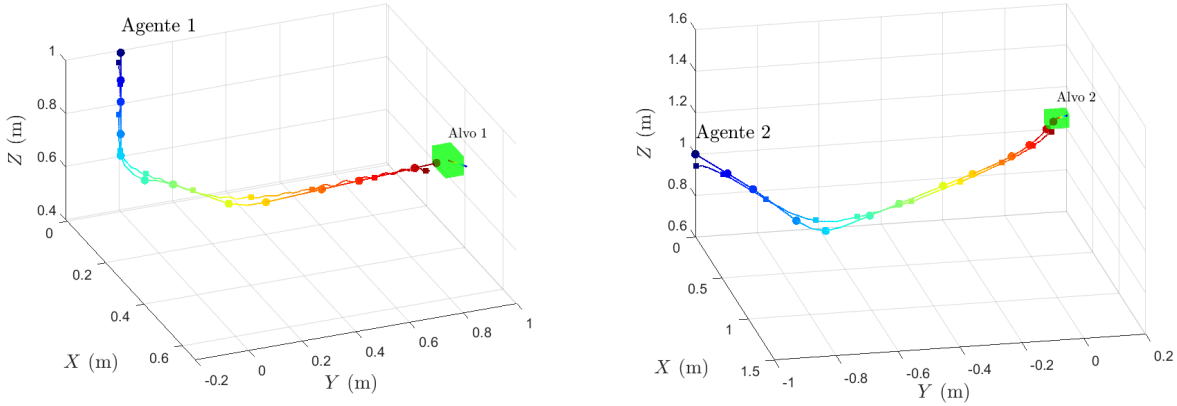



FIGURA 7.9 – Posições reais e otimizadas dos agentes na arena de voo para o experimento com dois drones. As trajetórias reais são comparadas com as posições geradas pela otimização, enquanto as posições dos alvos ao longo do tempo também são exibidas. A coloração das trajetórias indica a evolução temporal da missão, expressa em porcentagem de 0% a 100%. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo.

Para facilitar a visualização, as posições reais e simuladas de cada agente também foram representadas individualmente na Figura 7.10, destacando as variações nos três eixos ao longo do tempo.

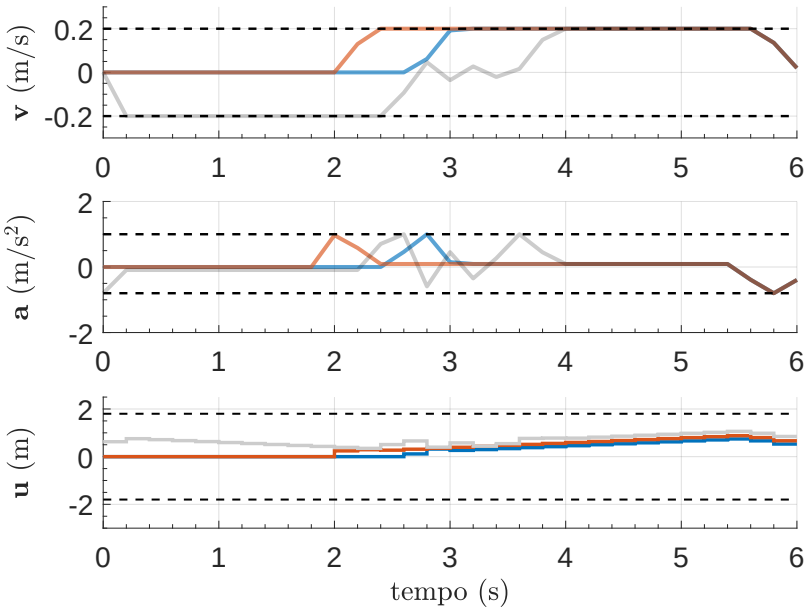



(1) Agente 1. (2) Agente 2.

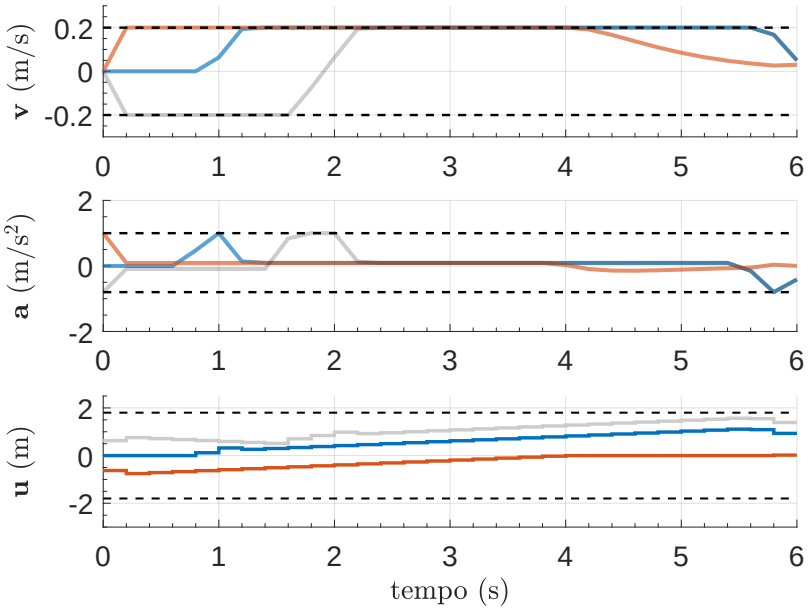
FIGURA 7.10 – Posições individuais de cada agente e alvo, apresentando uma visão mais próxima do cenário com dois agentes. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo.

A Figura 7.11 apresenta os gráficos de velocidade, aceleração e ação de controle (re-

ferência de posição) dos agentes 1 e 2 durante a simulação. A Figura 7.12 apresenta a carga remanescente da bateria simulada para cada agente.

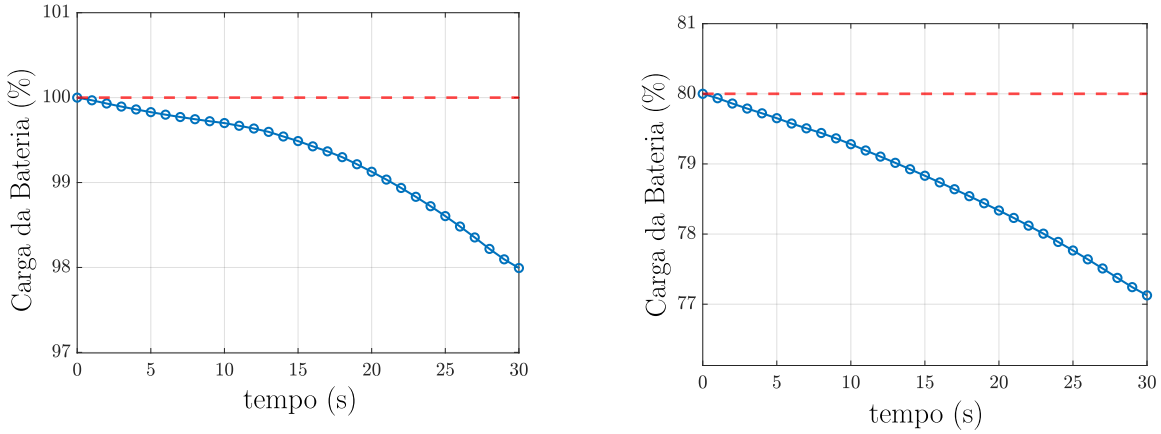



(1) Agente 1.




(2) Agente 2.

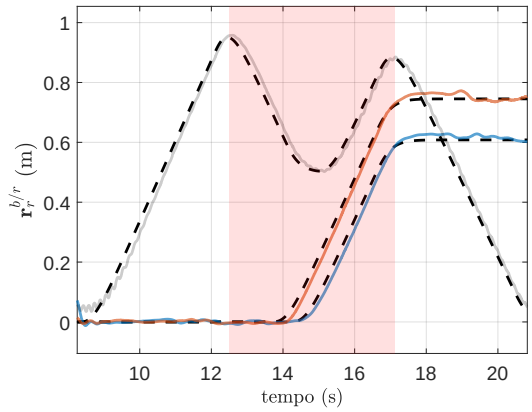
FIGURA 7.11 – Velocidades, acelerações e ações de controle dos dois agentes, obtidas durante o planejamento de trajetória. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e - -- Limite imposto pelas restrições. Todos os valores permaneceram dentro dos limites definidos pelas restrições.



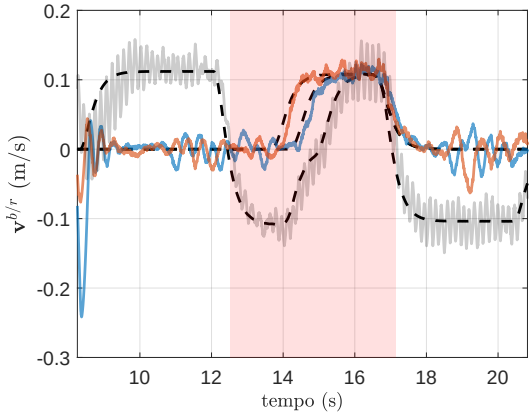

(1) Agente 1. (2) Agente 2.

FIGURA 7.12 – Carga remanescente da bateria dos agentes com o modelo de bateria implementado no planejamento de trajetória. Legenda: ○ Carga remanescente da bateria ao longo do tempo e --- Bateria inicial do agente.

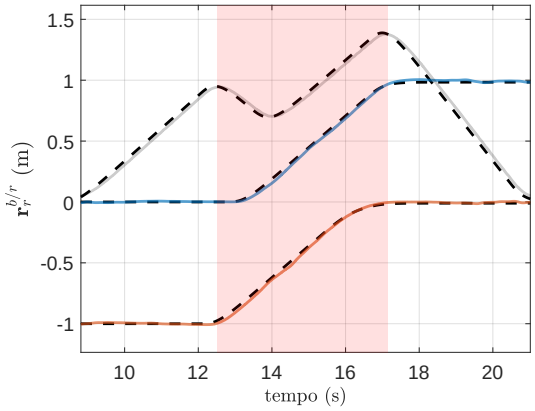
A Figura 7.13 apresenta os dados registrados na arena experimental com dois drones em operação. São exibidas as posições reais captadas pelo OptiTrack, bem como as velocidades estimadas por diferenciação numérica dessas posições. Esses dados são comparados às posições otimizadas geradas pelo planejador, as quais fazem parte do vetor de estados obtido pela solução do problema de otimização. Também são apresentados os comandos de referência enviados aos drones durante a execução, calculados a partir das posições otimizadas e processados pela arena experimental para garantir o rastreamento adequado. A faixa sombreada destaca o intervalo de execução ativa da trajetória planejada, enquanto os trechos anteriores e posteriores representam, respectivamente, a aproximação inicial e o retorno para pouso.



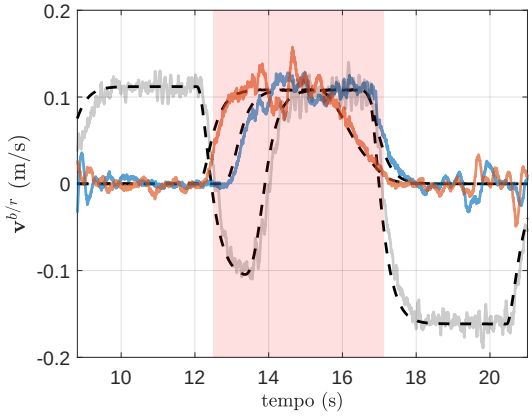

(1) Posição do agente 1.




(2) Velocidade do agente 1.




(3) Posição do agente 2.




(4) Velocidade do agente 2.

FIGURA 7.13 – Posições e velocidades dos agentes registradas pelo sistema de captura de movimento. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Referência gerada a partir dos estados de posição do problema de otimização (Eq. (4.31)) e aplicada via arena experimental. A faixa sombreada em vermelho indica o intervalo de aplicação das posições otimizadas; os demais trechos referem-se ao deslocamento inicial e ao retorno final.

A fim de validar o cumprimento da restrição de não colisão entre os agentes, foi monitorada continuamente a distância relativa entre os dois drones ao longo da execução da missão. A Figura 7.14 apresenta esse valor em função do tempo.

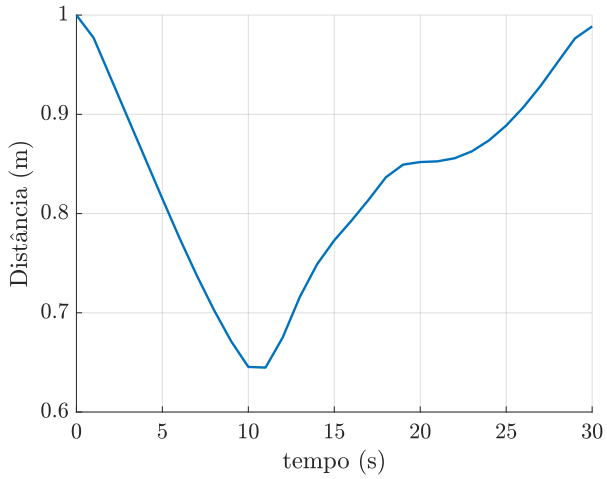



FIGURA 7.14 – Distância relativa entre o Agente 1 e o Agente 2 ao longo do tempo. Legenda: — Distância medida durante o voo.

Esse resultado confirma a eficácia da abordagem na prevenção de colisões, mesmo em cenários com múltiplos agentes operando simultaneamente em um espaço compartilhado.

### 7.2.3 Demonstração com Três Drones

Na última etapa de validação, foram realizadas duas demonstrações com três drones operando simultaneamente no ambiente experimental. A primeira configuração utilizou dois drones reais e um drone simulado, operando de forma cooperativa, caracterizando um cenário de realidade mista. Essa abordagem permitiu avaliar a integração entre agentes físicos e virtuais dentro da arena de voo. Na segunda configuração, foram utilizados três drones reais. Ambas as demonstrações seguiram os mesmos parâmetros e restrições das etapas anteriores, com a adição de um terceiro drone, com estado inicial definido como posição $(0,\ 1,\ 1)$ m e velocidades nulas o objetivo foi avaliar a escalabilidade da arena, sua capacidade de manter a integridade dos agentes e o cumprimento das restrições dinâmicas e de não colisão em um cenário mais complexo.

#### 7.2.3.1 Dois Drones Reais e Um Simulado

Nesta demonstração, foram utilizados dois drones reais e um agente simulado operando de forma integrada em um cenário de realidade mista. O objetivo foi validar a capacidade da arena experimental em coordenar múltiplos agentes físicos e virtuais em tempo real, assegurando o rastreamento das posições e o cumprimento das restrições operacionais previamente estabelecidas.

A Figura 7.15 apresenta a comparação entre as posições simuladas e as posições reais registradas para os três agentes durante a execução da missão. As posições de referência foram geradas de forma coordenada, respeitando as condições iniciais de cada agente e evitando sobreposição nas rotas planejadas.

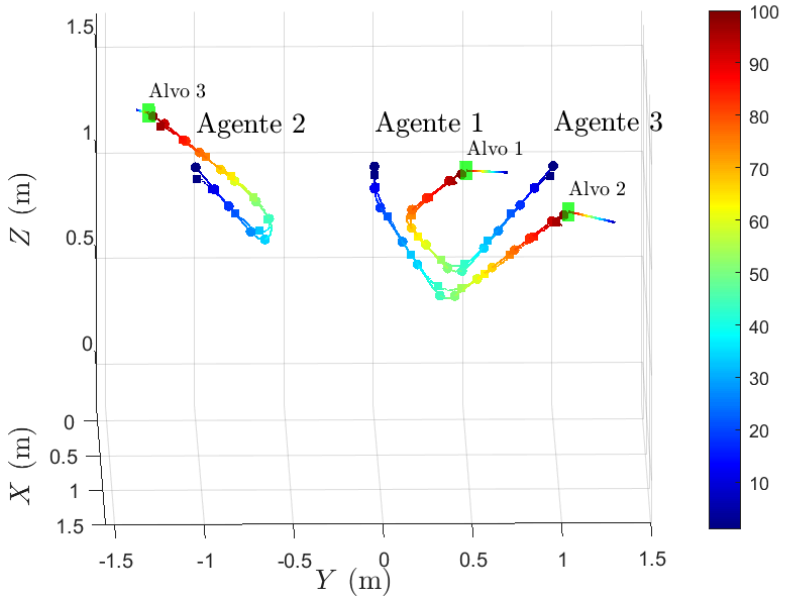
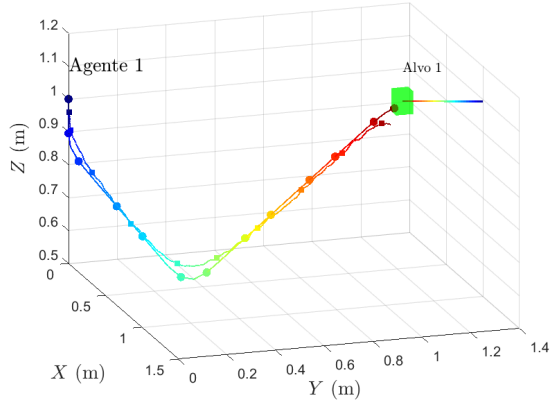
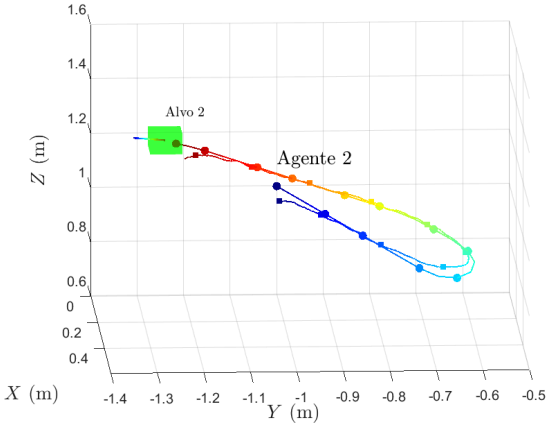



FIGURA 7.15 – Posições reais e otimizadas dos agentes na arena de voo, para o experimento usando dois agentes reais e um agente simulado (Agente 3), atuando de forma cooperativa em um ambiente em realidade mista, bem como a posição simulada do alvo ao longo do tempo. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo.

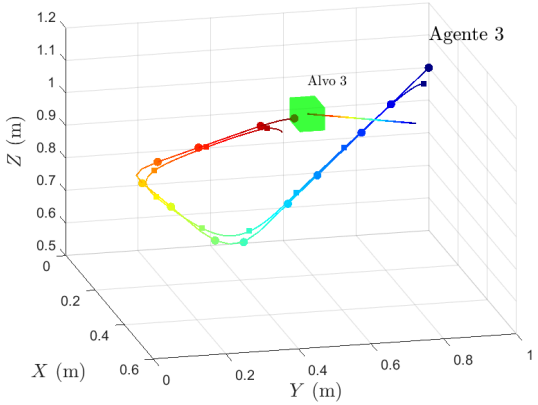
As posições individuais de cada agente, tanto reais quanto planejadas, são apresentadas na Figura 7.16. Ressalta-se que o Agente 3 é simulado, enquanto os Agentes 1 e 2 são físicos. Pequenas discrepâncias entre as trajetórias planejadas e executadas são esperadas, resultantes de fatores como ruídos externos, atrasos de comunicação, limitações dos atuadores e imprecisões na medição de posição pelo sistema de captura de movimento (OptiTrack). Além disso, desvios numéricos introduzidos no processamento das posições e na discretização dos comandos também contribuem para a diferença entre o comportamento planejado e a execução real observada na arena experimental.




(1) Agente 1.



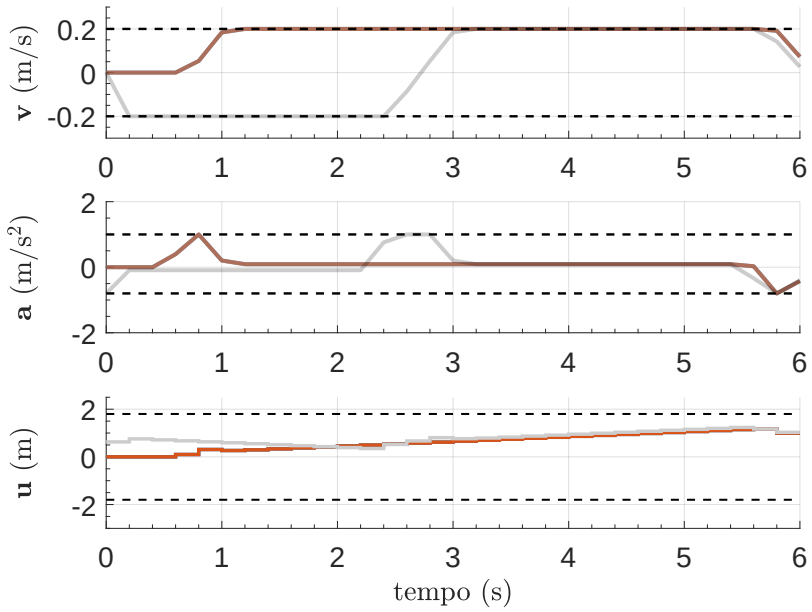

(2) Agente 2.



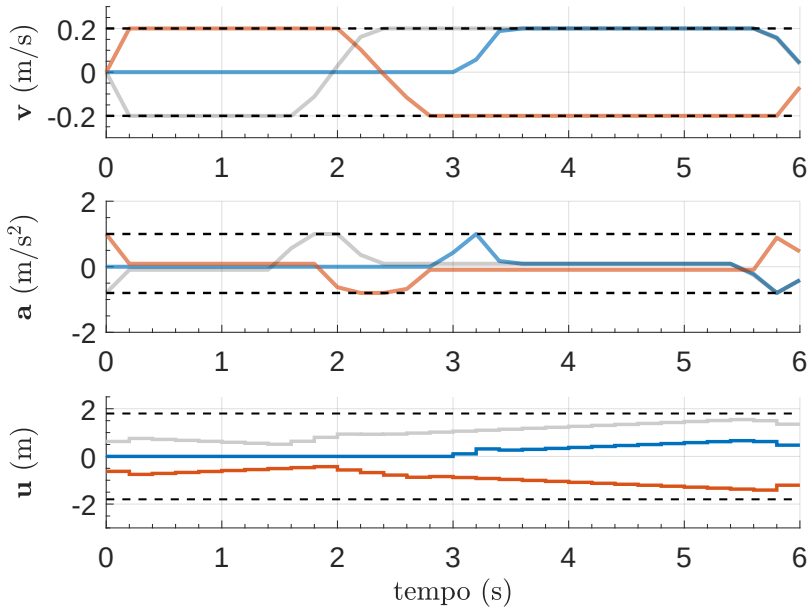

(3) Agente 3.

FIGURA 7.16 – Posições individuais de cada um dos três agentes e alvos no cenário com dois agentes reais e um agente simulado (Agente 3). Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo.

As restrições dinâmicas de velocidade, aceleração e controle foram respeitadas por todos os agentes durante o experimento, como mostra as Figuras 7.17 e 7.18.

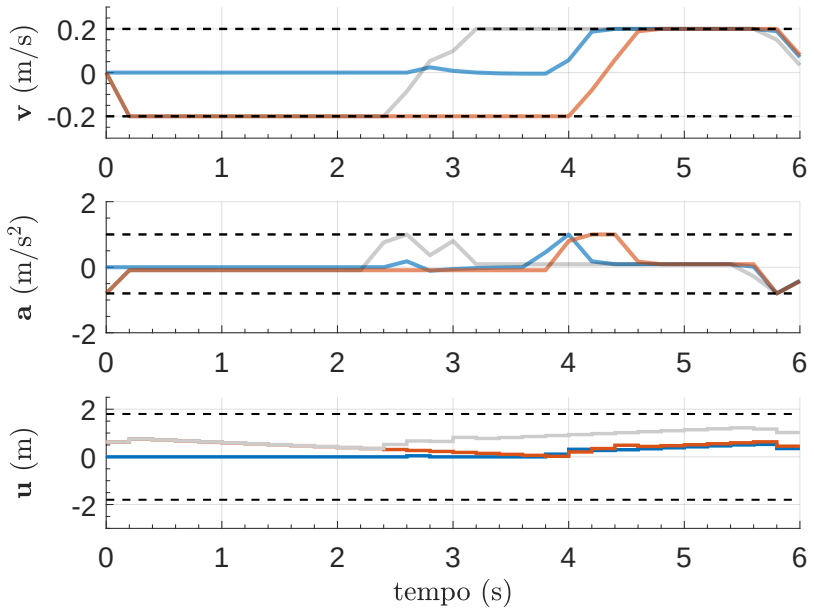



(1) Agente 1.




(2) Agente 2.

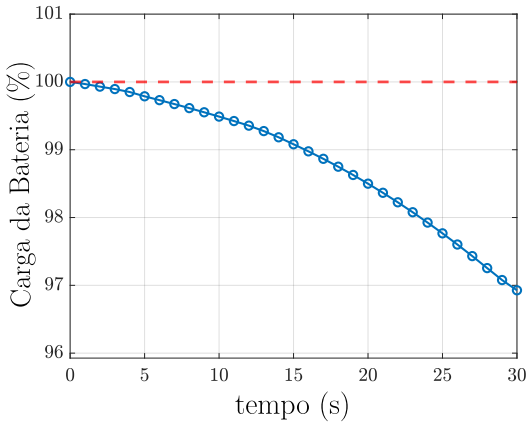
FIGURA 7.17 – Velocidades, acelerações e ações de controle dos Agentes 1 e 2 durante o planejamento de trajetória. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições.



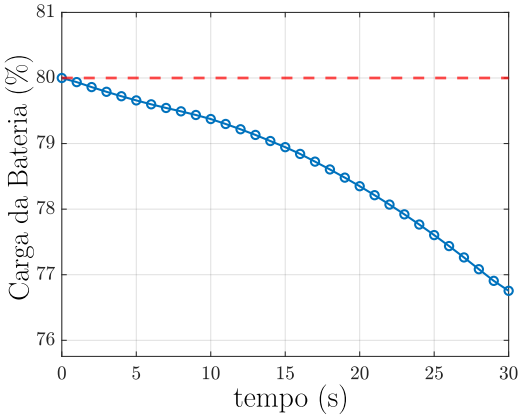

(3) Agente 3.

FIGURA 7.18 – Velocidade, aceleração e ações de controle do Agente 3 durante o planejamento de trajetória. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Limite imposto pelas restrições.

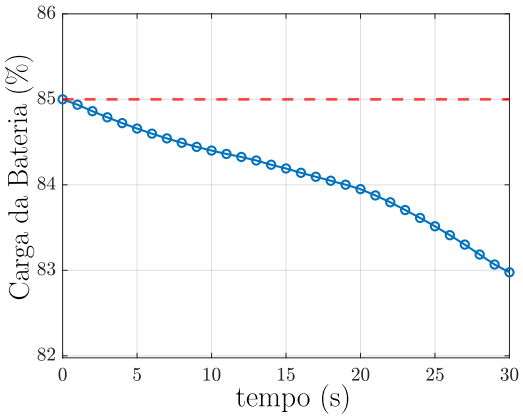
A Figura 7.19 mostra a carga remanescente da bateria simulada dos três agentes.




(1) Agente 1.



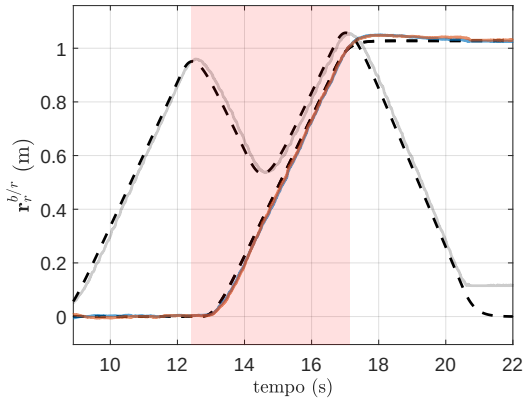

(2) Agente 2.



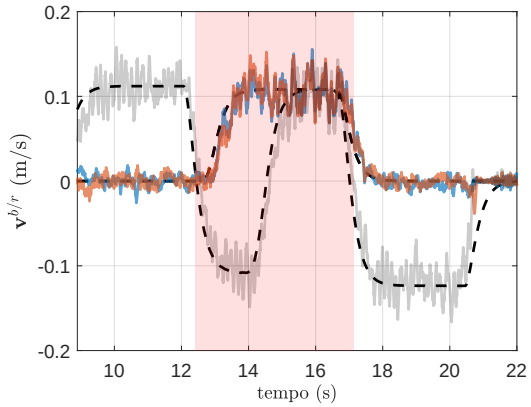

(3) Agente 3.

FIGURA 7.19 – Carga remanescente da bateria dos três agentes com o modelo de bateria implementado. Legenda: ○ Carga remanescente da bateria ao longo do tempo e --- Bateria inicial do agente.

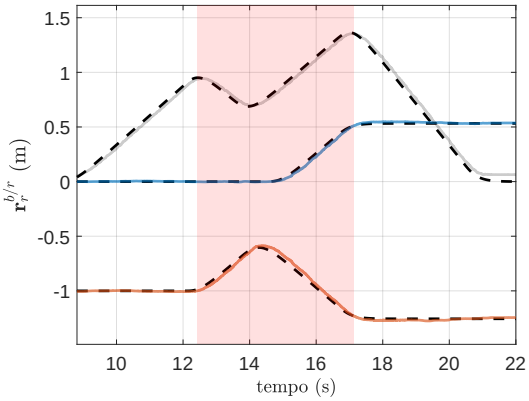
A Figura 7.20 apresenta os dados de rastreamento de posição e velocidade dos três agentes durante a execução da trajetória planejada. Os agentes 1 e 2 correspondem aos drones reais monitorados pelo OptiTrack, enquanto o agente 3 é um drone simulado, cujo comportamento foi calculado diretamente pelas equações dinâmicas da arena. Como esperado, os sinais de velocidade dos agentes reais apresentam pequenas flutuações devido a ruídos de medição, atrasos de comunicação e distúrbios do ambiente. Em contraste, a velocidade do agente simulado é livre dessas perturbações, refletindo unicamente o resultado da simulação numérica com base no modelo dinâmico, sem interferências externas.



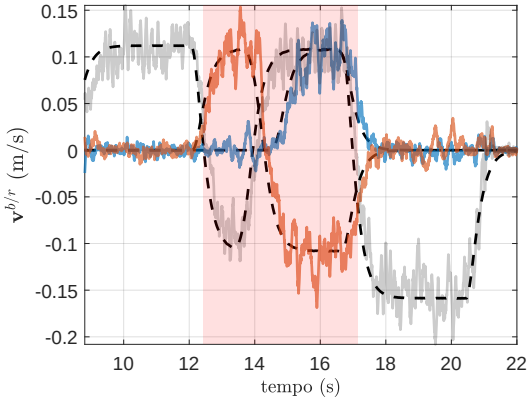

(1) Posição de agente 1.



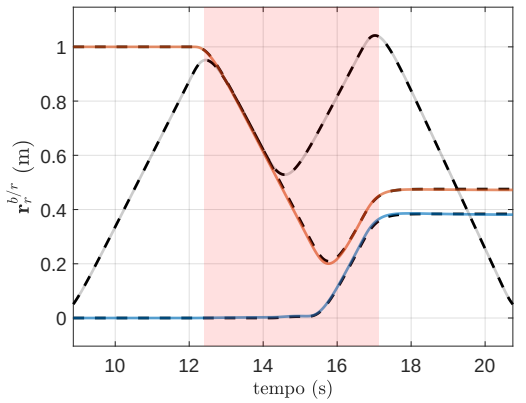

(2) Velocidade do agente 1.



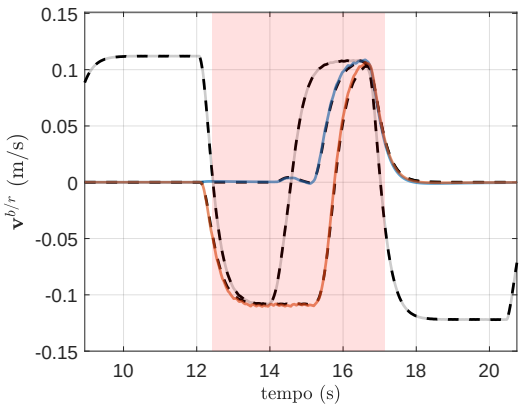

(3) Posição de agente 2.




(4) Velocidade do agente 2.




(5) Posição de agente 3.




(6) Velocidade do agente 3.

FIGURA 7.20 – Posições e velocidades de cada um dos três agentes registradas pelo OptiTrack. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Referência gerada a partir dos estados de posição do problema de otimização (Eq. (4.31)) e aplicada via arena experimental. A faixa sombreada em vermelho indica o intervalo de aplicação das posições otimizadas; os demais trechos referem-se ao deslocamento inicial e ao retorno final.

Para garantir o cumprimento da restrição de não colisão, a distância relativa entre os pares de agentes foi monitorada. A Figura 7.21 mostra a evolução da distância ao longo do tempo para cada par de agentes.

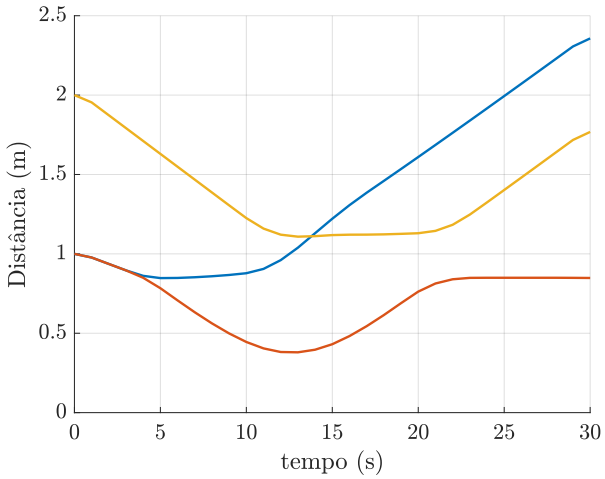



FIGURA 7.21 – Distância relativa entre os agentes durante o experimento. — Agente 1 – Agente 2, — Agente 1 – Agente 3 e — Agente 2 – Agente 3.

#### 7.2.3.2 Três Drones Reais

Nesta última demonstração, o planejador de trajetórias foi testado com três drones reais operando simultaneamente em ambiente compartilhado. Essa configuração teve como objetivo avaliar a escalabilidade da solução em um cenário totalmente físico, com todos os agentes sujeitos a ruídos, perturbações externas e limitações reais de comunicação e controle. O teste permite comparar diretamente os resultados com a configuração anterior, que envolvia um agente simulado, destacando o impacto da transição para um cenário completamente real.

A Figura 7.22 apresenta as posições gerais dos três drones, comparando as posições de referência simuladas com as posições reais capturadas pelo OptiTrack. As trajetórias foram planejadas para evitar cruzamentos e garantir a separação mínima entre os agentes durante toda a missão.

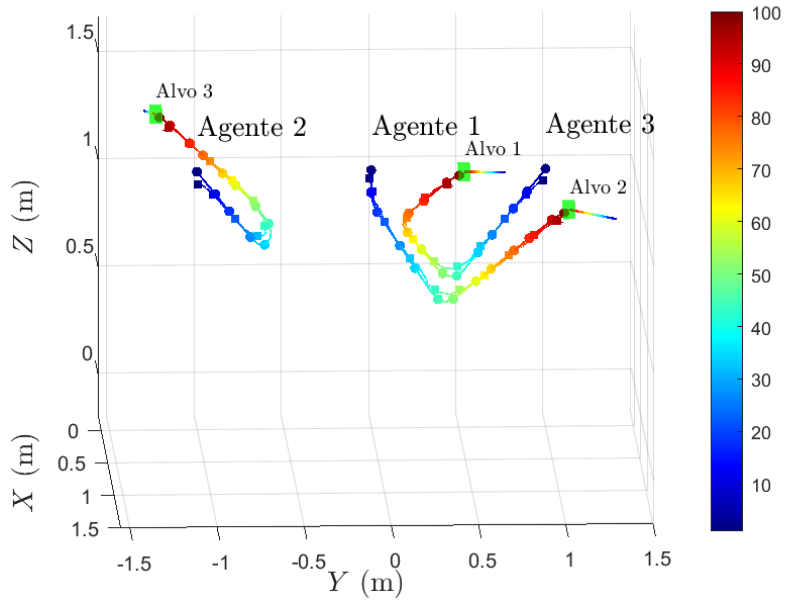


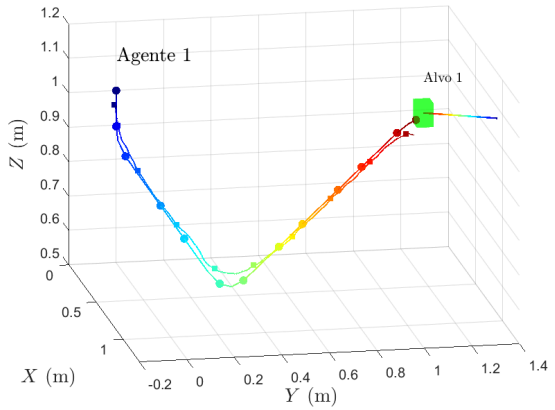

FIGURA 7.22 – Posições reais e planejadas dos agentes na arena de voo, para o experimento usando três agentes reais e a posição simulada do alvo ao longo do tempo. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo.

A Figura 7.23 apresenta, de forma separada, as posições individuais de cada um dos três agentes envolvidos na missão. Essa visualização permite uma análise mais detalhada do comportamento de cada drone ao longo do tempo, facilitando a observação do seguimento da trajetória planejada, bem como das variações em cada um dos eixos $x$, $y$ e $z$.

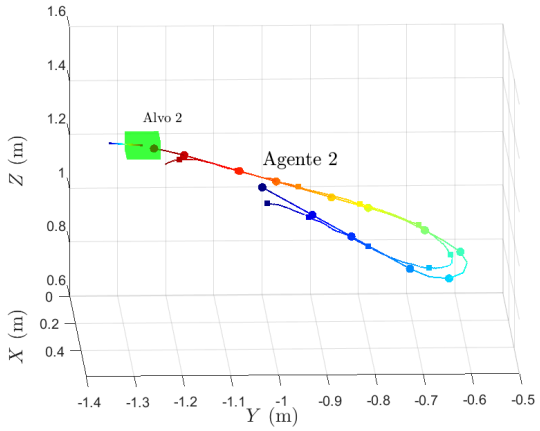
É importante destacar que os dados de simulação, incluindo as restrições dinâmicas e os perfis de carga da bateria são exatamente os mesmos da demonstração anterior com dois drones reais e um simulado, uma vez que as trajetórias de referência foram geradas offline. A única diferença entre as demonstrações está na substituição do agente simulado por um drone real, permitindo observar os efeitos práticos dessa transição no comportamento dinâmico e na resposta dos agentes em ambiente físico.

A Figura 7.24 apresenta os dados registrados de posição e velocidade para os três drones reais, capturados pelo OptiTrack. Ao comparar com o experimento anterior (Subseção 7.2.3.1), nota-se que o agente 3 agora apresenta perfis de velocidade com variações típicas de um sistema físico, incluindo ruídos, pequenas oscilações e atrasos. Isso contrasta com o comportamento suavizado e idealizado observado no caso do agente simulado.

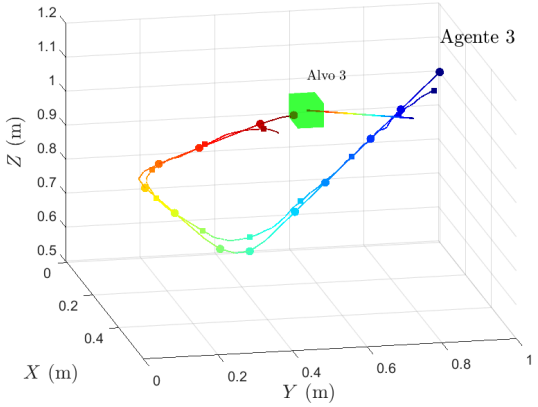
Os experimentos práticos conduzidos com até três drones em voo simultâneo comprovaram a eficácia do planejador de trajetórias proposto em ambiente real. Verificou-se que a arena manteve estabilidade operacional, seguiu as trajetórias planejadas, respeitou as restrições físicas e operacionais previamente definidas, e apresentou capacidade de adap-




(1) Agente 1.



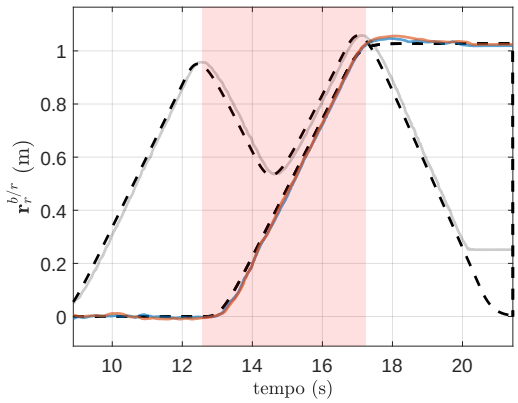

(2) Agente 2.



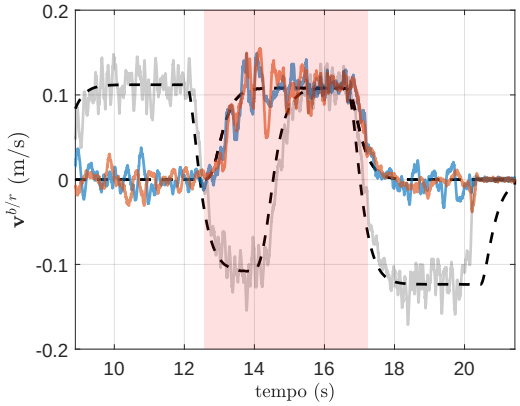

(3) Agente 3.

FIGURA 7.23 – Posições individuais de cada um dos três agentes reais e alvos simulados. Legenda: ○ Posição Planejada, □ Posição Real e ■ Alvo.

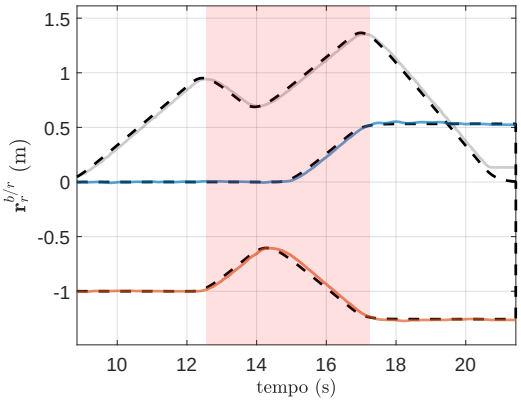
tação frente a diferentes condições de missão. A integração entre o planejador, a lógica de tomada de decisão e a execução embarcada confirmou a executabilidade da abordagem em cenários reais, mesmo sob limitações estruturais e dinâmicas. Os resultados reforçam o potencial da metodologia para aplicações cooperativas e críticas, como missões de defesa, inspeções autônomas ou operações de monitoramento em larga escala.



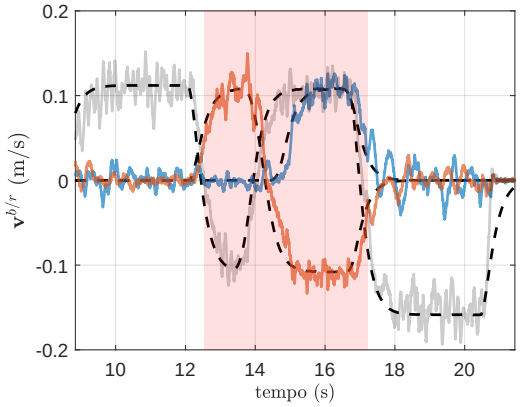

(1) Posição de agente 1.



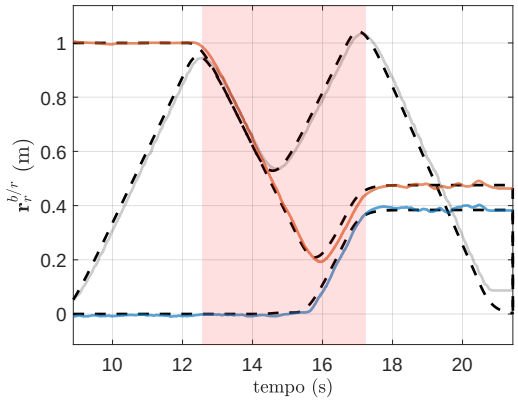

(2) Velocidade do agente 1.



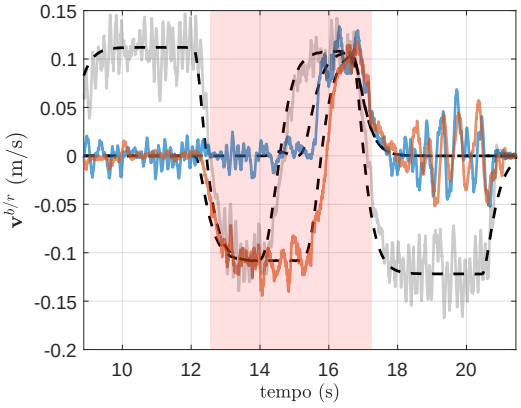

(3) Posição de agente 2.




(4) Velocidade do agente 2.




(5) Posição de agente 3.




(6) Velocidade do agente 3.

FIGURA 7.24 – Posições e velocidades de cada um dos três agentes registradas pelo OptiTrack. Legenda: — Eixo $x$, — Eixo $y$, — Eixo $z$ e --- Referência gerada a partir dos estados de posição do problema de otimização (Eq. (4.31)) e aplicada via arena experimental. A faixa sombreada em vermelho indica o intervalo em que as referências obtidas a partir da solução do problema de otimização foram aplicadas.

# 8 Conclusão e Trabalhos Futuros

Este trabalho apresentou uma metodologia de planejamento de trajetórias, baseada em planejadores ótimos, para CMAS operando em ambientes tridimensionais restritos. A abordagem integra restrições físicas, evitamento de obstáculos, limitações energéticas e uma estratégia dinâmica de alocação agente-alvo, considerando simultaneamente a distância e o nível de energia disponível de cada agente.

Um dos principais avanços desta pesquisa é a incorporação do mecanismo de tomada de decisão diretamente na estrutura do otimizador, permitindo a reavaliação contínua da alocação de agentes conforme a evolução do cenário. Essa integração viabiliza replanejamentos adaptativos, garantindo decisões eficientes e viáveis diante de mudanças nas posições relativas, nos níveis de energia e na presença de obstáculos.

A possibilidade de ativar ou desativar restrições ao longo do horizonte de predição conferiu flexibilidade ao otimizador, permitindo adaptar o planejamento a diferentes condições operacionais e mantendo a viabilidade da solução mesmo em cenários complexos. As simulações confirmaram a capacidade do método em gerar trajetórias factíveis e alocar recursos de forma otimizada, mesmo sob múltiplas limitações. A métrica de alocação priorizou agentes com melhores condições operacionais, promovendo eficiência energética e desempenho global da missão. A demonstração prática, realizada em ambiente de realidade mista, comprovou a aplicabilidade da solução, com os agentes seguindo as trajetórias de referência dentro dos limites físicos e operacionais estabelecidos.

## 8.1 Trabalhos Futuros

Embora a metodologia proposta tenha apresentado resultados consistentes, existem diversas possibilidades de aprimoramento e expansão que podem ser exploradas em pesquisas futuras:

- **Aprimoramento da Estratégia de Alocação**: desenvolver métricas mais sofisticadas, incorporando fatores como prioridades de missão, avaliação de riscos e estado de saúde dos agentes, permitindo decisões mais contextualizadas e alinhadas

aos objetivos operacionais. Adicionalmente, o modelo de bateria atual pode ser melhorado, pois apresenta uma penalização progressiva em relação ao tempo, que não reflete exatamente o comportamento físico correspondente.

- **Decisões Pós-Interceptação**: integrar mecanismos para definir ações após a interceptação do alvo, como neutralização, monitoramento ou redirecionamento. Essa funcionalidade aumentaria a autonomia e a flexibilidade do sistema em cenários dinâmicos.

- **Operação em Malha Fechada com Agentes Reais**: implementar o planejamento de trajetória em ambiente real com controle em malha fechada, integrando o sistema de captura de movimento, o planejamento e o controle diretamente na operação dos drones. Para contornar o tempo de otimização atual, propõe-se a utilização de técnicas de otimização em tempo real (real-time iteration), ou pré-cálculo de soluções em forma de política de controle por meio de aprendizado de máquina ou aproximação paramétrica, possibilitando a aplicação prática com latência compatível com os requisitos da malha fechada.

Essas propostas de continuidade buscam ampliar a aplicabilidade prática da metodologia em cenários operacionais reais. O aprimoramento da alocação visa aumentar a robustez das decisões em situações com múltiplas restrições e variáveis contextuais. A definição de ações pós-interceptação permite estender o ciclo de missão de cada agente, aumentando a utilidade operacional. Já a viabilização da operação em malha fechada com drones reais é um passo essencial para validar a eficácia do sistema sob restrições físicas e temporais reais, aproximando o modelo teórico da sua aplicação em tempo real.

# Referências


ACHTERBERG, T. Scip: solving constraint integer programs. **Mathematical Programming Computation**, Springer, v. 1, p. 1–41, 2009.

ADMINISTRATION, F. A. **Drones by the Numbers | Federal Aviation Administration**. Feb 2024. Disponível em: <https://www.faa.gov/node/54496>.

AFONSO, R. J. M.; GALVÃO, R. K. H.; SOUZA, G. A.; MAXIMO, M. R. O. A.; CAREGNATO-NETO, A. Linear constraints for ensuring k-hop connectivity using mixed-integer programming for multi-agent systems. **International Journal of Robust and Nonlinear Control**, Wiley Online Library, v. 34, n. 2, p. 1433–1447, 2024.

AFONSO, R. J. M.; MAXIMO, M. R. O. A.; GALVAO, R. K. H. Task allocation and trajectory planning for multiple agents in the presence of obstacle and connectivity constraints with mixed-integer linear programming. **International Journal of Robust and Nonlinear Control**, Wiley Online Library, v. 30, n. 14, p. 5464–5491, 2020.

AMMOUR, M.; ORJUELA, R.; BASSET, M. A MPC combined decision making and trajectory planning for autonomous vehicle collision avoidance. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, v. 23, n. 12, p. 24805–24817, 2022.

AVELLA, P.; CALAMITA, A.; PALAGI, L. A computational study of off-the-shelf minlp solvers on a benchmark set of congested capacitated facility location problems. **arXiv preprint arXiv:2303.04216v3**, 2023. Disponível em: <https://arxiv.org/abs/2303.04216v3>.

BALLESTEROS-TOLOSANA, I.; OLARU, S.; RODRIGUEZ-AYERBE, P.; PITA-GIL, G.; DEBORNE, R. Collision-free trajectory planning for overtaking on highways. In: **2017 IEEE 56th Annual Conference on Decision and Control (CDC)**. Melbourne, Australia: IEEE, 2017. p. 2551–2556.

BAZARAA, M. S.; SHERALI, H. D.; SHETTY, C. M. **Nonlinear Programming: Theory and Algorithms**. Hoboken, NJ: John Wiley & Sons, 2006.

BELLINGHAM, J.; RICHARDS, A.; HOW, J. P. Receding horizon control of autonomous aerial vehicles. In: **Proceedings of the 2002 American Control Conference (ACC)**. Anchorage, AK, USA: IEEE, 2002. v. 5, p. 3741–3746.

BELOTTI, P.; KIRCHES, C.; LEYFFER, S.; LINDEROTH, J.; LUEDTKE, J.; MAHAJAN, A. Mixed-integer nonlinear optimization. **Acta Numerica**, Cambridge University Press, v. 22, p. 1–131, 2013.

BEMPORAD, A.; MORARI, M. Robust model predictive control: a survey. In: **GARULLI, A.; TESI, A. (Ed). Robustness in Identification and Control**. Berlin, Heidelberg: Springer, 2007.

BEMPORAD, A.; MORARI, M.; DUA, V.; PISTIKOPOULOS, E. N. The explicit linear quadratic regulator for constrained systems. **Automatica**, Elsevier, v. 38, n. 1, p. 3–20, 2002.

BEN-TAL, A.; NEMIROVSKI, A. **Lectures on modern convex optimization: analysis, algorithms, and engineering applications**. Philadelphia, PA, USA: SIAM, 2001. ISBN 978-0-89871-491-3.

BERTSIMAS, D.; TSITSIKLIS, J. N. **Introduction to linear optimization**. Belmont, MA, USA: Athena Scientific, 1997. ISBN 978-1-886529-19-3.

BETHKE, B.; VALENTI, M.; HOW, J. P. Uav task assignment. **IEEE robotics & automation magazine**, IEEE, v. 15, n. 1, p. 39–44, 2008.

BIEGLER, L. T. **Nonlinear Programming: Concepts, Algorithms, and Applications to Chemical Processes**. Philadelphia, PA: SIAM, 2010.

BITCRAZE. **CrazyRadio**. 2013. `https://www.bitcraze.io/products/crazyradio-2-0/` (Acesso em: 13 jul. 2024).

BORRELLI, F.; BEMPORAD, A.; MORARI, M. **Predictive Control for Linear and Hybrid Systems**. Cambridge, UK: Cambridge University Press, 2017.

BOYD, S.; VANDENBERGHE, L. **Convex Optimization**. Cambridge, UK: Cambridge University Press, 2004.

CAMACHO, E. F.; BORDONS, C. **Constrained Model Predictive Control**. Berlin, Heidelberg: Springer, 2007.

CAREGNATO-NETO, A.; MAXIMO, M. R. O. A.; AFONSO, R. J. M. A novel line of sight constraint for mixed-integer programming models with applications to multi-agent motion planning. In: **2023 European Control Conference (ECC)**. Bucharest, Romania: IEEE, 2023. p. 1–6.

CARVALHO, D. F. Controlador preditivo otimizado aplicado ao controle de velocidade de motor cc. In: **XII Congresso de Pesquisa, Ensino e Extensão da UFG (CONPEEX)**. Goiânia, Brasil: Universidade Federal de Goiás, 2015.

CHEN, M.; SHIH, J. C.; TOMLIN, C. J. Multi-vehicle collision avoidance via hamilton-jacobi reachability and mixed integer programming. In: **2016 IEEE 55th Conference on Decision and Control (CDC)**. Las Vegas, NV, USA: IEEE, 2016. p. 1695–1700.

CHEN, Y. Q.; WANG, Z. Formation control: a review and a new consideration. In: **Proceedings of the 2005 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)**. Edmonton, Alberta, Canada: IEEE, 2005. p. 3181–3186.

CONFORTI, M.; CORNUÉJOLS, G.; ZAMBELLI, G. **Integer Programming**. Cham, Switzerland: Springer, 2014. ISBN 978-3-319-11007-0.

CRUZ, B. B.; RICARDO JR, J. A.; AFONSO, R. J. M.; SANTOS, D. A. Optimal trajectory planning for aerial threat neutralization using a multi-drone system with limited resources. Submitted to the 28th International Congress of Mechanical Engineering (COBEM). 2025.

CRUZ, B. B.; RICARDO JR, J. A.; SANTOS, D. A. A mixed-reality experimental indoor testbed for evaluation of drone flight control methods. **CBA - Congresso Brasileiro de Automática 2024**, p. 6, 2024. Disponível em: <https://www.sba.org.br/cba2024/papers/paper_9955.pdf>.

DEFESA, A. M. e. **Drones já fazem parte de 63% das forças de segurança no Brasil**. abr 2023. Disponível em: <https://www.edrotacultural.com.br/drones-ja-fazem-parte-de-63-das-forcas-de-seguranca-no-brasil/>.

DEITS, R.; TEDRAKE, R. Efficient mixed-integer planning for uavs in cluttered environments. In: **2015 IEEE International Conference on Robotics and Automation (ICRA)**. Seattle, WA, USA: IEEE, 2015. p. 42–49.

DING, T.; BO, R.; GU, W.; SUN, H. Big-M based MIQP method for economic dispatch with disjoint prohibited zones. **IEEE Transactions on Power Systems**, IEEE, v. 29, n. 2, p. 976–977, 2013.

FLETCHER, R. **Practical Methods of Optimization**. Chichester, England: John Wiley & Sons, 2000.

FLOUDAS, C. A. **Nonlinear and Mixed-Integer Optimization: Fundamentals and Applications**. New York, NY, USA: Oxford University Press, 1995.

Gurobi Optimization, LLC. **Gurobi Optimizer Reference Manual**. Houston, Texas, USA, 2024. `https://www.gurobi.com/documentation/` (Acesso em: 12 ago. 2024).

IBM. **IBM ILOG CPLEX Optimization Studio CPLEX User's Manual**. Armonk, NY, USA, 2023. `https://www.ibm.com/products/ilog-cplex-optimization-studio` (Acesso em: 12 ago. 2024).

IOAN, D.; PRODAN, I.; OLARU, S.; STOICAN, F.; NICULESCU, S.-I. Mixed-integer programming in motion planning. **Annual Reviews in Control**, Elsevier, v. 51, p. 65–87, 2021.

JANEČEK, F.; KLAUČO, M.; KVASNICA, M. Trajectory planning and following for uavs with nonlinear dynamics. In: **2017 21st International Conference on Process Control (PC)**. Štrbské Pleso, Slovakia: IEEE, 2017. p. 333–338.

KERRIGAN, E. C.; MACIEJOWSKI, J. M. Designing model predictive controllers with prioritised constraints and objectives. In: **Proceedings of the IEEE International Symposium on Computer Aided Control System Design (CACSD)**. Glasgow, Scotland: IEEE, 2002. p. 33–38.

KIRK, D. E. **Optimal Control Theory: An Introduction**. Mineola, NY, USA: Dover Publications, 2004.

KONG, F.; CHEN, H.; LI, H.; YAN, J.; WANG, X.; FANG, J. Flocking with obstacle avoidance for fixed-wing unmanned aerial vehicles via nonlinear model predictive control. In: **Proceedings of the 2023 42nd Chinese Control Conference (CCC)**. Wuhan, China: IEEE, 2023. p. 5957–5962.

KOUVARITAKIS, B.; CANNON, M. Model predictive control. **Switzerland: Springer International Publishing**, Springer, v. 38, 2016.

KUWATA, Y.; TEO, J.; FIORE, G.; KARAMAN, S.; FRAZZOLI, E.; HOW, J. P. Real-time motion planning with applications to autonomous urban driving. **IEEE Transactions on Control Systems Technology**, v. 17, n. 5, p. 1105–1118, 2009.

LIU, W.; WANG, A.; YANG, W.; SHI, Q. Mixed-integer linear optimization via learning-based two-layer large neighborhood search. **arXiv preprint arXiv:2412.08206**, 2024. Version-v1 posted 11 Dec 2024. Disponível em: <https://arxiv.org/abs/2412.08206>.

LUENBERGER, D. G.; YE, Y. **Linear and Nonlinear Programming**. New York: Springer, 1984.

LUIS, C. E.; VUKOSAVLJEV, M.; SCHOELLIG, A. P. Online trajectory generation with distributed model predictive control for multi-robot motion planning. **IEEE Robotics and Automation Letters**, v. 5, n. 2, p. 604–611, 2020.

LUPPOLD, A.; OEHLERT, D.; FALK, H. **Evaluating the Performance of Solvers for Integer-Linear Programming**. Hamburg, Germany, 2018. Disponível em: <https://doi.org/10.15480/882.1839>.

MAIA, M. H.; GALVAO, R. K. On the use of mixed-integer linear programming for predictive control with avoidance constraints. **International Journal of Robust and Nonlinear Control: IFAC-Affiliated Journal**, Wiley Online Library, v. 19, n. 7, p. 822–828, 2009.

MATHWORKS, T. **MATLAB version: R2024b**. Natick, Massachusetts, United States: The MathWorks Inc., 2024. `https://www.mathworks.com` (Acesso em: 07 ffev. 2025).

MUKAI, M.; NATORI, H.; FUJITA, M. Model predictive control with a mixed integer programming for merging path generation on motor way. In: **2017 IEEE Conference on Control Technology and Applications (CCTA)**. Kohala Coast, HI, USA: IEEE, 2017. p. 2214–2219.

NEMHAUSER, G.; WOLSEY, L. Integer programming and combinatorial optimization. In: SPRINGER. **Proceedings of the IPCO: International Conference on Integer**

**Programming and Combinatorial Optimization, Houston, TX, USA**. Houston, TX, USA: Springer, 1998. p. 22–24.

NOCEDAL, J.; WRIGHT, S. J. **Numerical optimization**. New York, NY, USA: Springer, 1999.

OPTITRACK. **Prime Cameras**. 1996. `https://optitrack.com/cameras/` (Acesso em: 12 jul. 2024).

PICHIERRI, L.; TESTA, A.; NOTARSTEFANO, G. Crazychoir: Flying swarms of crazyflie quadrotors in ros 2. **IEEE Robotics and Automation Letters**, v. 8, n. 8, p. 4713–4720, 2023. Disponível em: <https://ieeexplore.ieee.org/document/10153630>.

PICKRELL, R. **Nearly 100 countries have military drones, and it's changing the way the world prepares for war**. 2019. `https://www.businessinsider.com/world-rethinks-war-as-nearly-100-countries-field-military-drones-2019-9` (Acesso em: 21 fev. 2025).

PREISS, J. A.; HÖNIG, W.; SUKHATME, G. S.; AYANIAN, N. Crazyswarm: A large nano-quadcopter swarm. In: **IEEE International Conference on Robotics and Automation (ICRA)**. IEEE, 2017. p. 3299–3304. Software available at `https://github.com/USC-ACTLab/crazyswarm`. Disponível em: <https://doi.org/10.1109/ICRA.2017.7989376>.

PRODAN, I.; OLARU, S.; STOICA, C.; NICULESCU, S.-I. Predictive control for trajectory tracking and decentralized navigation of multi-agent formations. **International Journal of Applied Mathematics and Computer Science**, De Gruyter Poland, v. 23, n. 1, p. 91–100, 2013.

PRODAN, I.; STOICAN, F.; OLARU, S.; NICULESCU, S.-I. Control problems involving mixed-integer decision making. In: **PRODAN, I.; STOICAN, F.; OLARU, S.; NICULESCU, S.-I. Mixed-Integer Representations in Control Design: Mathematical Foundations and Applications**. Cham, Switzerland: Springer, 2016. p. 57–89.

QUIRYNEN, R.; SAFAOUI, S.; CAIRANO, S. D. Real-time mixed-integer quadratic programming for vehicle decision-making and motion planning. **IEEE Transactions on Control Systems Technology**, v. 33, n. 1, p. 77–91, 2025.

RICARDO JR, J. A.; SANTOS, D. A. Robust collision avoidance for mobile robots in the presence of moving obstacles. **IEEE Control Systems Letters**, v. 7, p. 1584–1589, 2023.

RICHARDS, A.; HOW, J. Mixed-integer programming for control. In: IEEE. **Proceedings of the 2005, American Control Conference, 2005.** Portland, OR, USA, 2005. p. 2676–2683.

RICHARDS, A.; HOW, J. P. Robust variable horizon model predictive control for vehicle maneuvering. **International Journal of Robust and Nonlinear Control: IFAC-Affiliated Journal**, Wiley Online Library, v. 16, n. 7, p. 333–351, 2006.

RICHARDS, A.; TURNBULL, O. Inter-sample avoidance in trajectory optimizers using mixed-integer linear programming. **International Journal of Robust and Nonlinear Control**, Wiley Online Library, v. 25, n. 4, p. 521–526, 2015.

RUSZCZYNSKI, A. **Nonlinear Optimization**. Princeton, NJ: Princeton University Press, 2011.

SANTOS, D. A.; LAGOA, C. M. Wayset-based guidance of multirotor aerial vehicles using robust tube-based model predictive control. **ISA transactions**, Elsevier, v. 128, p. 123–135, 2022.

SORIA, E.; SCHIANO, F.; FLOREANO, D. Distributed predictive drone swarms in cluttered environments. **IEEE Robotics and Automation Letters**, v. 7, n. 1, p. 73–80, 2022.

SOUZA, G. de A. **K-hop connectivity constraints for multi-agent systems trajectory planning**. Dissertação (Mestrado) — Instituto Tecnológico de Aeronáutica, 2023.

Unity Technologies. **Unity**. 2023. Game development platform. `https://unity.com/` (Acesso em: 27 jun. 2024).

VARGAS, S.; BECERRA, H. M.; HAYET, J.-B. MPC-based distributed formation control of multiple quadcopters with obstacle avoidance and connectivity maintenance. **Control Engineering Practice**, Elsevier, v. 121, p. 105054, 2022.

WALLACE, R. J.; LOFFI, J. M. Examining unmanned aerial system threats & defenses: a conceptual analysis. **International Journal of Aviation, Aeronautics, and Aerospace**, v. 2, n. 4, p. 1, 2015.

FOLHA DE REGISTRO DO DOCUMENTO

| 1. CLASSIFICAÇÃO/TIPO | 2. DATA | 3. DOCUMENTO Nº | 4. Nº DE PÁGINAS |
|---|---|---|---|
| DM | 06 de Agosto de 2025 | DCTA/ITA/DM-047/2025 | 133 |

5. TÍTULO E SUBTÍTULO:

Planejamento Ótimo de Trajetórias para Neutralização de Ameaças Aéreas com Sistema Multidrones e Recursos Limitados

6. AUTOR(ES):

**Benicio Barbosa Cruz**

7. INSTITUIÇÃO(ÕES)/ÓRGÃO(S) INTERNO(S)/DIVISÃO(ÕES):

Instituto Tecnológico de Aeronáutica – ITA

8. PALAVRAS-CHAVE SUGERIDAS PELO AUTOR:

Sistemas autônomos; Sistemas multi-drone; Planejamento de trajetória; Controle preditivo de modelos; Tomada de decisão; Engajamento cooperativo de ameaças.

9. PALAVRAS-CHAVE RESULTANTES DE INDEXAÇÃO:

Planejamento de trajetória; Tomada de decisões; Controle preditivo; Aeronaves não-tripulada; Avaliação de ameaças; Defesa aérea; Sistemas multiagentes; Otimização; Engenharia aeronáutica; Controle.

10. APRESENTAÇÃO: (**X**) **Nacional** ( ) **Internacional**

ITA, São José dos Campos. Curso de Mestrado. Programa de Pós-Graduação em Engenharia Eletrônica e Computação. Área de Sistemas e Controle. Orientador: Prof. Dr. Rubens Junqueira Magalhães Afonso . Coorientador: Prof. Dr. Davi Antônio dos Santos. Defesa em 28/07/2025. Publicada em 2025.

11. RESUMO:

Este trabalho apresenta uma abordagem integrada para o planejamento de trajetórias e tomada de decisão em sistemas autônomos cooperativos compostos por múltiplos drones, operando em ambientes tridimensionais com restrições dinâmicas e operacionais. O cenário envolve a interceptação de alvos móveis na presença de obstáculos estáticos, exigindo que os agentes executem suas missões de forma eficiente, segura e dentro dos limites físicos e energéticos da plataforma. A metodologia proposta é baseada em planejamento ótimo, respeitando as restrições de velocidade, aceleração, área de operação e prevenção de colisões, tanto com obstáculos quanto entre os próprios agentes. Um diferencial da abordagem é a integração da alocação dos drones aos alvos diretamente no problema de otimização, considerando níveis de energia remanescente. Restrições específicas, como a de velocidade terminal, asseguram que os drones alcancem os alvos de forma adequada para possíveis ações subsequentes, como acompanhamento ou manutenção da posição relativa. A validação da proposta foi realizada por meio de simulações em cenários com múltiplos agentes e obstáculos, além de experimentos em ambiente de realidade mista, integrando drones reais e simulados em uma operação coordenada. Os resultados demonstraram a eficácia do otimizador no planejamento de trajetórias viáveis e na tomada de decisões, assegurando o cumprimento dos objetivos da missão com otimização do uso de recursos e respeito às limitações operacionais.
Este trabalho apresenta uma abordagem integrada para o planejamento de trajetórias e tomada de decisão em sistemas autônomos cooperativos compostos por múltiplos drones, operando em ambientes tridimensionais com restrições dinâmicas e operacionais. O cenário envolve a interceptação de alvos móveis na presença de obstáculos estáticos, exigindo que os agentes executem suas missões de forma eficiente, segura e dentro dos limites físicos e energéticos da plataforma. A metodologia proposta é baseada em planejamento ótimo, respeitando as restrições de velocidade, aceleração, área de operação e prevenção de colisões, tanto com obstáculos quanto entre os próprios agentes. Um diferencial da abordagem é a integração da alocação dos drones aos alvos diretamente no problema de otimização, considerando níveis de energia remanescente. Restrições específicas, como a de velocidade terminal, asseguram que os drones alcancem os alvos de forma adequada para possíveis ações subsequentes, como acompanhamento ou manutenção da posição relativa. A validação da proposta foi realizada por meio de simulações em cenários com múltiplos agentes e obstáculos, além de experimentos em ambiente de realidade mista, integrando drones reais e simulados em uma operação coordenada. Os resultados demonstraram a eficácia do otimizador no planejamento de trajetórias viáveis e na tomada de decisões, assegurando o cumprimento dos objetivos da missão com otimização do uso de recursos e respeito às limitações operacionais.

12. GRAU DE SIGILO:

(**X**) **OSTENSIVO** ( ) **RESERVADO** ( ) **SECRETO**